

单位代码： 10293 密 级：

南京邮电大学

专业学位硕士学位论文



论文题目： Swift: 基于强化学习的多信号融合自适应网络拥塞控制算法

学 号	1224045520
姓 名	杭天铖
导 师	王俊昌教授
专业学位类别	电子信息
类 型	全日制
专 业（领域）	计算机技术
论文提交日期	2026 年 3 月

摘要

随着云计算、移动互联网、人工智能和物联网技术的快速发展，端到端网络传输正在从单一固定终端和局域高质量链路，扩展到跨地域远距离传输、蜂窝/无线/卫星等多接入网络，以及手机、笔记本、台式机和边缘设备等多模态终端并存的复杂场景。传统基于丢包的拥塞控制算法（如 TCP NewReno、CUBIC）存在拥塞信号滞后、高带宽延迟积（Bandwidth-Delay Product, BDP）网络收敛缓慢、无法区分拥塞程度等固有缺陷；而基于延迟的算法（如 TCP Vegas、BBR）则面临往返时延（Round-Trip Time, RTT）测量不稳定、与丢包算法共存时公平性差等问题。本文提出 Swift 算法——一种基于强化学习辅助的多信号融合自适应网络拥塞控制方法。该算法名称寓意“雨燕”，象征着高吞吐量（High Throughput）与低延迟（Low Latency）的设计目标，如同雨燕般轻盈敏捷、反应迅速。

Swift 算法的核心创新收敛为三点：（1）面向远距离与异构终端传输的 11 维有效 RL 观测子空间设计，该子空间嵌入于 15 元素 OpenGym Box 传输容器，另含 4 项跨进程路由用的元数据通道，将显式拥塞通知（Explicit Congestion Notification, ECN）状态、拥塞控制状态机（Congestion Algorithm State）状态、拥塞事件类型、RTT 和在途字节等协议栈信息纳入强化学习状态表示；（2）多信号融合拥塞判定与差异化响应机制，在协议栈的显式降窗回调内部按拥塞状态机状态与 ECN 状态完成“超时/ECN 驱动的窗口缩减/普通丢包”三路语义判别，并针对三类信号分别采用 0.50、0.75、0.70 的窗口保留因子（Window Retention Factor），同时引入最多连续 3 次缩减后保持窗口的连续缩减保护与降窗后 4 个 ACK 事件冻结机制，以区分拥塞信号的性质和严重程度并抑制窗口快速反弹；（3）强化学习辅助的自适应融合控制策略，根据最小 RTT 感知的 RTT 膨胀阈值、奖励信号快慢双指数移动平均（Exponential Moving Average, EMA）的基线相对偏离以及连续增长趋势动态调整乘性增加因子 α （取值范围 [0.85, 1.30]，基准值 1.10），并以“时间窗口投递速率采样加窗口化最大值过滤（Windowed Max-filter）”两级结构估计带宽延迟积（Bandwidth-Delay Product, BDP），在拥塞避免阶段围绕 $\alpha \times BDP$ 目标窗口进行有界步长的渐进拉升或回落。

本文基于 ns-3.40 网络仿真平台和 ns3-gym/OpenGym 强化学习框架实现了 Swift 算法，采用 ZeroMQ 进程间通信实现仿真进程与决策进程的同步协作。实验矩阵覆盖近端高速、共享收敛链路、无线局域网接入、蜂窝移动接入、城域与跨域广域网及 GEO 卫星通信共 36 个场景，并通过 enable_udp_burst 开关构建“纯 TCP”与“TCP + 800 Mbps UDP Burst”的 A/B 严格对照，共 288 次仿真。全部指标由 ns-3 FlowMonitor 产物重新导出并仅在前向数据流上定义，以消除既有汇总文件将反向 ACK 流计入时延与吞吐所造成的系统性偏差。经数据质量审计（识别并排除指标定义缺陷、同一场景内混用两个仿真器修订、重复的场景配置、以及 BBR 在微秒级 RTT 路径上的实现层面退化，全部排除留痕于 logs/error.txt），纯 TCP 设

置保留 19 个、UDP Burst 设置保留 15 个可用于严格四协议对照的场景。需要前置说明的是，归档实验的瓶颈队列为丢尾队列且不产生 CE 标记，故 ECN 分支在本文数据中未被触发，下述结论均刻画 Swift 在纯丢包信号条件下的行为；当前版本已将默认队列规则改为 RED 并对全协议对称开启 ECN，ECN 通路的评估留待重跑。**稳态实验结果**表明：在排队主导且缓冲区与 BDP 匹配的场景中，Swift 在吞吐量与 NewReno/CUBIC 等价（差异 $\leq 0.3\%$ ）的同时将平均单向时延降低 13.6%~93.1%，其中近端高速低 RTT 场景（10G/25G/20G）达 83.3%~93.1%（由 3.79~4.51 ms 降至 0.28~0.71 ms）；Swift 在全部 19 个场景中丢包率均为 0.00%，是四种协议中唯一实现全场景零丢包者，且 Jain 公平性均值 1.000 为四者最高；在 GEO 卫星长距离场景中，零丢包转化为相对 NewReno/CUBIC 均值 +29.85% 的吞吐量优势。**跨流量鲁棒性实验**进一步表明：在全部 15 个配对场景中 Swift 仍唯一维持零丢包（同条件下 CUBIC 最大新增丢包 +5.92 个百分点、BBR +2.57 个百分点），吞吐量回落幅度的均值（19.46%）与最差值（33.49%）均为四协议最小（BBR 分别为 60.93% 与 90.31%），14 个场景吞吐量领先，且 GEO 卫星场景的吞吐优势由 +29.85% 放大至 +87.81%。本文同时如实披露三项负面或混合结果：跨域 WAN 场景吞吐量回落 28.97%，其机理已定位为生成数据时所用的单次确认投递速率公式对带宽的系统性低估（v3.0.0 已替换为时间窗口形式）；十个缓冲区相对 BDP 过深的低速场景中时延抬升 21.3%~123.3%，其结构性原因是 $200 \times MSS$ 兜底上界在低 BDP 路径上旁路了 $\alpha \times BDP$ 目标机制；跨流量条件下平均时延抬升 14.33%，须与零丢包联合解读。相应的改进方向与证据范围限制（单一随机种子、实现修订边界）已在第 5 章给出。

关键词：拥塞控制，强化学习，多信号融合，显式拥塞通知，自适应参数调优，远距离传输，异构终端

Abstract

With the rapid development of cloud computing, mobile Internet, artificial intelligence, and Internet-of-Things technologies, end-to-end network transmission is expanding from fixed terminals and local high-quality links to long-distance cross-region paths, cellular/wireless/satellite access networks, and heterogeneous endpoint environments involving phones, laptops, desktops, edge devices, and other terminal classes. Traditional loss-based congestion control algorithms (such as TCP NewReno and CUBIC) suffer from delayed congestion signals, slow convergence in high Bandwidth-Delay Product (BDP) networks, and inability to distinguish congestion severity. Meanwhile, delay-based algorithms (such as TCP Vegas and BBR) face unstable Round-Trip Time (RTT) measurements and poor fairness when coexisting with loss-based algorithms.

This paper proposes Swift, a reinforcement-learning-assisted multi-signal fusion adaptive network congestion control algorithm. The name “Swift” symbolizes the design goals of High Throughput and Low Latency, like a swift that is light, agile, and responsive. The core innovations of Swift are consolidated into three aspects: (1) an 11-dimensional effective RL observation subspace for long-distance and heterogeneous endpoint transmission, embedded in a 15-element OpenGym Box transport container with four additional metadata channels for inter-process routing, which incorporates Explicit Congestion Notification (ECN) status, Congestion Algorithm (CA) state, congestion event types, RTT, and bytes in flight into the reinforcement learning state representation; (2) a multi-signal congestion determination and differentiated response mechanism that, inside the protocol stack’s explicit window-reduction callback, performs a three-way semantic classification into timeout, ECN-driven window reduction, and ordinary loss according to the CA state and the ECN state, applying window retention factors of 0.50, 0.75, and 0.70 respectively, together with a consecutive-decrease guard that holds the window after at most three successive reductions and a four-ACK post-decrease freeze; and (3) a reinforcement-learning-assisted adaptive fusion control strategy that adjusts the multiplicative increase factor $\alpha \in [0.85, 1.30]$ (baseline 1.10) from min-RTT-aware RTT-inflation thresholds, the *baseline-relative* deviation between a fast and a slow reward Exponential Moving Average (EMA), and consecutive growth trends, and that estimates the Bandwidth-Delay Product (BDP) through a two-stage structure combining time-window delivery-rate sampling with a windowed max-filter, moving the congestion window toward the $\alpha \times BDP$ target with bounded pull-up or drain steps during congestion avoidance.

We implemented Swift on the ns-3.40 network simulation platform with the ns3-gym/OpenGym reinforcement learning framework, using ZeroMQ inter-process communication for synchronous in-

teraction between the simulation and decision processes. The experiment matrix spans 36 scenarios covering near-end high-speed links, shared oversubscribed links, wireless LAN access, cellular mobile access, metropolitan and inter-region wide area networks, and GEO satellite communication, and an `enable_udp_burst` switch constructs a strict A/B comparison between “pure TCP” and “TCP + 800 Mbps UDP Burst”, for 288 simulation runs in total. All metrics were re-derived from the ns-3 FlowMonitor artifacts and are defined *on the forward data flows only*, which removes the systematic bias introduced by the existing summary files that also counted the reverse ACK flows into delay and throughput. After a data quality audit that identified and excluded a metric-definition defect, scenarios mixing two simulator revisions across protocols, duplicated scenario configurations, and an implementation-level BBR breakdown on microsecond-RTT paths (all exclusions recorded in `logs/error.txt`), 19 scenarios remain admissible for strict four-protocol comparison under the pure-TCP setting and 15 under the UDP-burst setting. One scope note must be stated up front: the archived runs used a drop-tail bottleneck queue that never sets the CE codepoint, so the ECN branch was *never triggered* in this data, and the results below characterise Swift under loss-only signalling; the current revision defaults to RED with symmetric ECN for all protocols, and evaluating the ECN path is left to the pending rerun. **Steady-state results** show that, in queueing-dominated scenarios whose buffer is matched to the path BDP, Swift reduces the mean one-way delay by 13.6%–93.1% while keeping throughput equivalent to NewReno/CUBIC (difference $\leq 0.3\%$); in the near-end high-speed low-RTT scenarios (10G/25G/20G) the reduction reaches 83.3%–93.1% (from 3.79–4.51 ms down to 0.28–0.71 ms). Swift attains 0.00% loss in all 19 scenarios, the only protocol of the four to do so, and its mean Jain fairness of 1.000 is the highest; in the GEO satellite scenario the zero-loss behavior translates into a +29.85% throughput gain over the NewReno/CUBIC mean. **Cross-traffic robustness experiments** further show that Swift remains the *only* protocol with zero loss across all 15 paired scenarios (under the same conditions CUBIC adds up to +5.92 percentage points of loss and BBR +2.57), that both its mean throughput degradation (19.46%) and its worst case (33.49%) are the smallest of the four (BBR: 60.93% and 90.31%), that it leads in throughput in 14 of the 15 scenarios, and that its GEO satellite advantage widens from +29.85% to +87.81%. Three negative or mixed results are reported faithfully: the inter-region WAN scenario shows a 28.97% throughput regression, traced to the single-ACK delivery-rate formula used by the revision that generated the data, which systematically under-estimated bandwidth and has been replaced by the time-window form in v3.0.0; ten low-rate scenarios whose buffer is far deeper than the path BDP show a 21.3%–123.3% delay uplift, structurally caused by the $200 \times MSS$ safety bound bypassing the $\alpha \times BDP$ target on low-BDP paths; and the mean delay increases by 14.33% under cross traffic, which must be read jointly with the zero-loss result. The corresponding refinement directions and the two evidence-scope limits (a

single random seed and the implementation-revision boundary) are discussed in Chapter 5.

Key Words: Congestion Control, Reinforcement Learning, Multi-signal Fusion, Explicit Congestion Notification, Adaptive Parameter Tuning, Long-distance Transmission, Heterogeneous Endpoints

目 录

摘要	I
Abstract	III
插图索引	XI
表格索引	XII
专用术语注释表	XIII
第一章 绪论	1
1.1 研究背景与动机	1
1.2 研究目标与主要贡献	2
1.3 论文组织结构	3
第二章 相关工作	4
2.1 传统拥塞控制算法	4
2.1.1 基于丢包的拥塞控制算法	4
2.1.2 基于延迟的拥塞控制算法	6
2.1.3 混合拥塞控制算法	7
2.2 显式拥塞通知机制	8
2.2.1 ECN 工作原理	8
2.2.2 ECN 相关拥塞控制算法	8
2.3 基于机器学习的拥塞控制方法	10
2.3.1 监督学习方法	10
2.3.2 强化学习方法	10
2.4 远距离与异构终端网络特性分析	11
2.4.1 路径与接入特性	11
2.4.2 流量特性分析	12
2.4.3 应用延迟需求分析	12
2.4.4 网络设备与反馈机制特性	12
2.5 拥塞控制的理论基础	13
2.5.1 网络流量模型	13
2.5.2 排队论分析	14
2.5.3 控制论视角	14
2.6 强化学习在网络中的应用综述	15
2.6.1 路由优化	15
2.6.2 资源分配	16
2.6.3 安全防护	16
2.6.4 与 Swift 的关系	16
2.7 本章小结	17
第三章 Swift 算法设计与实现	18
3.1 系统架构概述	18
3.2 强化学习问题建模	20
3.2.1 状态空间设计理论	20
3.2.2 动作空间设计理论	21
3.2.3 奖励函数设计理论	21
3.2.4 策略表示理论	21

3.3	11 维观测空间详细设计	22
3.3.1	连接标识参数 (索引 0、3)	22
3.3.2	时间信息参数 (索引 1、2)	23
3.3.3	窗口状态参数 (索引 4、5)	23
3.3.4	传输性能参数 (索引 6、7、8)	23
3.3.5	延迟测量参数 (索引 9、10)	24
3.3.6	回调类型参数 (索引 11)	24
3.3.7	拥塞控制状态参数 (索引 12、13、14)	24
3.4	多信号融合拥塞检测算法	25
3.4.1	拥塞信号分类	26
3.4.2	分层优先级机制	26
3.4.3	信号优先级与误判抑制策略	27
3.4.4	完整拥塞检测算法	28
3.5	差异化拥塞响应机制	29
3.5.1	窗口保留因子设计	29
3.5.2	差异化响应的理论依据	29
3.5.3	慢启动阈值更新	30
3.5.4	差异化拥塞响应算法	31
3.6	强化学习驱动的自适应参数调优	31
3.6.1	乘性增加因子的作用	32
3.6.2	多因素调整机制	32
3.6.3	参数边界约束	33
3.6.4	自适应参数调优算法	34
3.7	融合控制策略	34
3.7.1	带宽延迟积估计	34
3.7.2	慢启动阶段策略	36
3.7.3	拥塞避免阶段策略	37
3.7.4	窗口边界约束	38
3.7.5	融合控制策略算法	38
3.8	每流独立状态管理	38
3.8.1	状态数据结构	38
3.8.2	状态查找与更新	40
3.8.3	状态生命周期管理	41
3.9	实现细节与优化技术	41
3.9.1	系统架构设计	41
3.9.2	核心算法伪代码	41
3.9.3	数据结构设计	41
3.9.4	性能优化技术	43
3.9.5	OpenGym/ZeroMQ 同步交互路径	43
3.9.6	正确性保证机制	44
3.10	本章小结	44

第四章 实验评估	46
4.1 实验环境配置	46
4.1.1 硬件环境	46
4.1.2 软件环境	46
4.1.3 网络拓扑与队列配置	46
4.1.4 仿真参数	48
4.1.5 随机种子与重复性说明	48
4.1.6 UDP Burst 干扰流量与实验矩阵	48
4.2 评测指标	49
4.2.1 指标的流向界定	49
4.2.2 吞吐量 (Throughput)	50
4.2.3 延迟 (Latency)	50
4.2.4 丢包率 (Loss Rate)	50
4.2.5 公平性 (Fairness)	51
4.3 对比算法	51
4.3.1 TCP NewReno	51
4.3.2 TCP CUBIC	51
4.3.3 TCP BBR	51
4.4 实验场景设计	52
4.4.1 场景矩阵与覆盖范围	52
4.4.2 数据质量审计与排除规则	53
4.5 实验方法论	54
4.5.1 实验设计原则	54
4.5.2 统计分析方法	55
4.6 实验结果分析	55
4.6.1 吞吐量对比	55
4.6.2 延迟对比	56
4.6.3 丢包率与公平性对比	58
4.6.4 延迟抖动对比	59
4.7 深入分析	60
4.7.1 场景分类讨论	60
4.7.2 机制有效性分析	61
4.7.3 关键参数的作用边界	62
4.8 UDP Burst 跨流量鲁棒性评估	62
4.8.1 聚合鲁棒性指标	62
4.8.2 配对场景逐一验证	64
4.8.3 鲁棒性机理分析	65
4.8.4 算法优势与适用边界总结	65
4.9 本章小结	66
第五章 讨论	67
5.1 设计考量	67
5.1.1 11 维观测空间的设计原理	67
5.1.2 差异化窗口保留因子的选择	67
5.1.3 自适应参数调优的设计	68

5.2	理论分析	68
5.2.1	收敛性分析	68
5.2.2	公平性分析	68
5.2.3	复杂度分析	68
5.3	适用边界与改进方向	68
5.3.1	缓冲区相对 BDP 过深场景中的延迟抬升	68
5.3.2	跨域广域网场景的吞吐量回落	69
5.3.3	实验证据的范围限制	70
5.3.4	参数自动调优	70
5.3.5	深度强化学习增强	70
5.3.6	真实部署验证	70
5.4	与相关工作的比较	71
5.4.1	与 Aurora 的比较	71
5.4.2	与 DCTCP 的比较	71
5.4.3	与 BBR 的比较	71
5.4.4	与 PCC 的比较	71
5.5	敏感性分析	72
5.5.1	窗口保留因子的理论依据	72
5.5.2	连续递减保护阈值的数学分析	72
5.5.3	RTT 膨胀比阈值的设计考量	73
5.6	计算开销分析	73
5.6.1	时间复杂度	73
5.6.2	空间复杂度	73
5.6.3	工程开销来源	73
5.7	理论分析深入探讨	74
5.7.1	多信号融合的信息论基础	74
5.7.2	差异化响应的最优控制分析	74
5.7.3	自适应参数调优的强化学习视角	75
5.7.4	收敛性的 Lyapunov 分析	75
5.7.5	公平性的博弈论分析	75
5.8	本章小结	76
第六章	结论与展望	77
6.1	研究总结	77
6.2	研究展望	80
6.2.1	中低速与中等 RTT 延迟抬升、广域网吞吐量进一步上探	80
6.2.2	策略表达能力扩展	80
6.2.3	多目标优化扩展	81
6.2.4	真实网络部署与验证	81
6.2.5	安全性、鲁棒性与跨层协同	81
6.2.6	异构网络与新兴传输协议适配	81
6.2.7	可解释性与能效扩展	82
6.3	应用场景展望	82
6.4	研究意义与社会价值	82

参考文献 84

附录 A 程序清单 86

附录 B 攻读专业学位硕士期间撰写的论文 87

附录 C 攻读专业学位硕士期间申请的专利 88

附录 D 攻读专业学位硕士期间参加的科研项目 89

致谢 90

插图索引

图 1.1	Swift 算法核心贡献概览	2
图 2.1	拥塞控制算法分类体系	4
图 2.2	ECN 信号传递工作流程	9
图 3.1	Swift 系统架构	18
图 4.1	哑铃型 (Dumbbell) 实验网络拓扑	47

表格索引

表 2.1	代表性拥塞控制算法综合对比	16
表 3.1	Swift 11 维观测空间参数定义	22
表 3.2	差异化窗口保留因子	29
表 4.1	默认仿真参数	48
表 4.2	审计后保留的 19 个对照场景配置	52
表 4.3	聚合前向吞吐量对比 (Mbps)	55
表 4.4	平均单向前向时延对比 (ms)	57
表 4.5	丢包率 (%) 与 Jain 公平性指数对比	58
表 4.6	平均延迟抖动对比 (ms)	59
表 4.7	UDP Burst 跨流量鲁棒性聚合指标	63
表 4.8	15 个配对场景的吞吐量变化 ΔT (%) 与 Burst 丢包率 L (%)	64
表 4.9	Swift 算法优势与适用边界	65
表 5.1	Swift 与 Aurora 的详细对比	71
表 5.2	Swift 与 DCTCP 的详细对比	71
表 5.3	Swift 与 BBR 的详细对比	72

专用术语注释表

符号说明

$cwnd$	拥塞窗口 (Congestion Window), TCP 发送端在未收到确认的情况下最多可以发送的数据量 (字节)
$ssthresh$	慢启动阈值 (Slow Start Threshold), 区分慢启动和拥塞避免阶段的临界值 (字节)
α	乘性增加因子 (Multiplicative Increase Factor), 控制拥塞避免阶段窗口增长速度, 取值范围 $[0.85, 1.30]$, 基准值 1.10
γ	加性增加因子 (Additive Increase Factor), 控制窗口的加性增量, 默认值为 1.0
ρ	窗口保留因子 (Window Retention Factor), 拥塞响应后新窗口与原窗口的比值
ρ_{loss}	丢包保留因子, 默认值 0.70
ρ_{ecn}	ECN 保留因子, 默认值 0.75
$\rho_{timeout}$	超时保留因子, 默认值 0.50
η	奖励信号指数移动平均 (EMA) 衰减系数, 默认值 0.1
BDP	带宽延迟积 (Bandwidth-Delay Product), 网络链路能够容纳的最大在途数据量 (字节)
MSS	最大报文段长度 (Maximum Segment Size), 本文取 1440 字节
RTT	往返时延 (Round-Trip Time), 数据包从发送端到接收端再返回的总时间
$W(t)$	时刻 t 的拥塞窗口大小
W_{max}	上次拥塞事件前的最大窗口大小
K	CUBIC 算法中恢复到 W_{max} 所需的时间
C	链路容量或 CUBIC 缩放因子
β	窗口缩减因子
δ	延迟惩罚权重参数
λ	丢包惩罚权重参数
H	Hurst 参数, 描述流量自相似性

$\bar{Q}$	平均队列长度
$\bar{W}$	平均等待时间
τ	反馈延迟（约等于 RTT）

缩略词

TCP	传输控制协议 (Transmission Control Protocol)
ECN	显式拥塞通知 (Explicit Congestion Notification)
RTT	往返时延 (Round-Trip Time)
BDP	带宽延迟积 (Bandwidth-Delay Product)
MDP	马尔可夫决策过程 (Markov Decision Process)
RL	强化学习 (Reinforcement Learning)
AIMD	加性增乘性减 (Additive Increase Multiplicative Decrease)
MSS	最大报文段长度 (Maximum Segment Size)
DCTCP	数据中心 TCP (Data Center TCP)
BBR	瓶颈带宽和往返传播时间 (Bottleneck Bandwidth and Round-trip propagation time)
CUBIC	三次函数拥塞控制算法
ACK	确认 (Acknowledgment)
SACK	选择性确认 (Selective Acknowledgment)
CE	拥塞经历 (Congestion Experienced)
ECE	ECN 回显 (ECN-Echo)
CWR	拥塞窗口缩减 (Congestion Window Reduced)
RED	随机早期检测 (Random Early Detection)
CA	拥塞算法 (Congestion Algorithm)
PPO	近端策略优化 (Proximal Policy Optimization)
DQN	深度 Q 网络 (Deep Q-Network)
PCC	面向性能的拥塞控制 (Performance-oriented Congestion Control)
ZMQ	ZeroMQ 消息队列
SDN	软件定义网络 (Software Defined Networking)
QoS	服务质量 (Quality of Service)

QUIC	快速 UDP 互联网连接 (Quick UDP Internet Connections)
RDMA	远程直接内存访问 (Remote Direct Memory Access)
PFC	优先级流量控制 (Priority Flow Control)
INT	带内网络遥测 (In-band Network Telemetry)
HPCC	高精度拥塞控制 (High Precision Congestion Control)
WAN	广域网 (Wide Area Network)
Pod	交换机组 (Point of Delivery)
EMA	指数移动平均 (Exponential Moving Average)
IPC	进程间通信 (Inter-Process Communication)

第一章 绪论

1.1 研究背景与动机

随着云计算、大数据、人工智能、移动互联网和物联网技术的蓬勃发展，端到端网络传输的服务对象正在从固定主机扩展到手机、笔记本、台式机、边缘节点和传感设备等多模态终端，传输路径也从近端局域链路延伸到跨城、跨域、蜂窝接入、无线局域网和卫星通信等远距离复杂网络。传输控制协议（Transmission Control Protocol, TCP）作为互联网传输层的核心协议，承载了大量关键业务流量，其拥塞控制机制的性能直接影响网络资源利用效率、应用响应延迟和用户服务质量。网络拥塞控制是计算机网络领域最具挑战性的研究课题之一，自互联网诞生以来一直是学术界和工业界持续关注的焦点问题。

在现代端到端网络中，链路与终端条件呈现出更强的异构性。一方面，城域/广域网、蜂窝网络、WiFi 与卫星链路具有不同的 RTT 量级、丢包背景、可用带宽和链路抖动；另一方面，手机、电脑、边缘设备等终端在处理能力、无线接入方式、移动性和业务负载上差异显著。这种长距离、多接入、多终端并存的网络环境对传统拥塞控制算法提出了前所未有的严峻挑战。

现代网络应用承载着多种类型的业务负载，这些业务对网络性能有着截然不同的需求。移动视频、实时会议和云游戏需要稳定的低延迟与低抖动；分布式存储、内容分发和大文件同步需要高吞吐量以支持大规模数据传输；边缘计算、工业物联网和车联网则同时关注可靠性、实时性和终端资源约束。单一的拥塞控制策略难以同时满足这些多样化的性能需求。

更为复杂的是，远距离和多接入传输中的拥塞信号更难解释。丢包可能来自真实队列溢出，也可能来自无线误码、链路切换或终端侧调度抖动；RTT 升高既可能表示排队，也可能来自路径变化、接入链路波动或终端处理延迟；移动终端后台同步、视频传输、RPC 突发、备份任务和多租户共享链路还会造成短时间带宽挤占。传统单一信号驱动的拥塞控制方法难以在这些场景中稳定区分拥塞程度。

传统的 TCP 拥塞控制算法在这种复杂的网络环境中显露出诸多不足。基于丢包的算法（如 TCP NewReno^[1]、TCP CUBIC^[2]）将数据包丢失作为拥塞信号，但丢包是拥塞的滞后指示器，通常意味着网络缓冲区已经溢出，排队延迟已经积累到较高水平。基于延迟的算法（如 TCP Vegas^[3]、TCP BBR^[4]）尝试通过监测 RTT 变化提前感知拥塞，但 RTT 测量易受多种因素干扰，且在与基于丢包算法共存时存在公平性问题。

显式拥塞通知（Explicit Congestion Notification, ECN）机制为解决上述问题提供了新的思路。ECN 允许网络设备在队列长度超过阈值时标记数据包而非丢弃，从而实现更早、更精确的拥塞信号传递。数据中心 TCP（DCTCP^[5]）验证了 ECN 细粒度反馈在特定低时延网络中的有效性，但其适用前提较强；在远距离、多接入和多模态终端并存的环境中，现有算法对

ECN、RTT、丢包和协议栈状态的联合利用仍不充分，大多采用静态参数配置，缺乏对动态网络环境的自适应能力。

近年来，机器学习特别是强化学习技术的快速发展为网络拥塞控制带来了革命性的新思路^[6]。强化学习（Reinforcement Learning, RL）是一种通过与环境交互来学习最优策略的机器学习方法。在强化学习框架中，智能体（Agent）通过观察环境状态、执行动作并获得奖励来不断优化决策策略。将强化学习应用于网络拥塞控制，理论上能够实现：（1）自适应地学习网络环境特征，无需人工设计复杂的控制规则；（2）综合利用多种拥塞信号进行决策；（3）根据网络条件动态调整控制参数；（4）良好的可扩展性和通用性。

然而，现有基于强化学习的拥塞控制方案仍存在诸多问题：状态空间设计不完善，通常只使用 4-6 维的有限状态参数；奖励函数设计不合理，难以平衡多个优化目标；缺乏对 ECN 信号的分级利用；算法验证效率低下等。这些问题限制了强化学习在拥塞控制领域的实际应用效果。

1.2 研究目标与主要贡献

针对上述问题，本文提出了 Swift 算法——一种基于强化学习的多信号融合自适应网络拥塞控制方法。”Swift”意为”雨燕”，雨燕以其轻盈敏捷的飞行姿态和清脆悦耳的歌声著称。选用”Swift”作为算法名称，寓意本算法追求的设计目标：如同雨燕般轻盈敏捷，实现高吞吐量（High Throughput）与低延迟（Low Latency）的完美平衡；如同雨燕对环境变化的敏锐感知，实现对多种拥塞信号的快速响应和智能融合。

图1.1展示了 Swift 算法的三项核心贡献及各组件之间的逻辑关系。




图 1.1 Swift 算法核心贡献概览

本文的主要研究贡献如下：

(1) 面向远距离与异构终端的多信号状态感知

本文设计了一个 11 维有效 RL 观测子空间（嵌入于 15 元素 OpenGym Box 传输容器，另含套接字 UUID、环境类型、仿真时间、节点 ID 四项跨进程路由用的元数据通道），将显式拥塞通知（ECN）状态、拥塞控制状态机状态、拥塞事件类型、RTT 和在途字节等 TCP 协议栈信息纳入强化学习状态表示。与现有方案通常采用的 4–6 维简化状态空间相比，Swift 的观测空间能够为手机、电脑、边缘节点和长距离链路中的 TCP 连接提供更全面、更精细的状态感知能力，为精准的拥塞控制决策奠定基础。

(2) 多信号融合拥塞判定与差异化响应

本文提出了一种多信号融合的拥塞判定方法，采用分层优先级机制综合分析丢包、超时、ECN 和拥塞控制状态信号。该方法的核心思想是：不同类型的拥塞信号具有不同的可靠性、时序特征和严重程度，应当采用差异化处理策略。具体而言，丢包和超时代表较严重的拥塞或路径异常，ECN 标记代表队列溢出前的早期预警，拥塞控制状态机则提供协议栈内部语义。基于该判定结果，Swift 针对丢包、ECN 和超时分别采用 0.70、0.75 和 0.50 的窗口保留因子，并引入连续缩减保护机制，限制最多 3 次连续缩减后保持窗口不变，避免因连续拥塞事件导致窗口过度收缩。

(3) 强化学习辅助的自适应融合控制

本文实现了强化学习辅助的自适应融合控制策略，根据 RTT 膨胀比、奖励信号指数移动平均和连续增长趋势动态调整乘性增加因子 α ，并将其限制在 $[0.85, 1.30]$ 范围内以保证控制稳定性。在窗口计算中，Swift 采用窗口化最大值过滤方法估计 BDP，并围绕 $\alpha \times BDP$ 目标窗口进行有界步长的渐进拉升或回落；同时结合 RTT 约束下的管道利用率感知加性递增机制，在吞吐量、延迟和稳定性之间实现自适应折中。上述策略在 ns-3 与 ns3-gym/OpenGym 框架中实现，并通过 ZeroMQ 进程间通信和多场景对照实验完成验证。

1.3 论文组织结构

本文的其余部分组织如下：

第 2 章介绍相关工作，包括传统拥塞控制算法、基于机器学习的拥塞控制方法、显式拥塞通知机制、强化学习在网络领域的应用等。

第 3 章详细描述 Swift 算法的设计与实现，包括系统架构、观测空间设计、多信号融合拥塞检测、差异化拥塞响应、自适应参数调优、融合控制策略等核心组件。

第 4 章介绍实验评估，包括实验环境配置、评测指标、对比算法、实验场景设计以及详细的实验结果分析。

第 5 章讨论 Swift 算法的适用边界和未来研究方向。

第 6 章总结全文并展望未来工作。

第二章 相关工作

网络拥塞控制是计算机网络领域的核心研究课题之一，自互联网诞生以来一直是学术界和工业界关注的焦点。本章从传统拥塞控制算法、显式拥塞通知机制、基于机器学习的拥塞控制方法三个方面综述相关研究工作，并分析各方法的优缺点及其对 **Swift** 算法设计的启示。

图2.1展示了拥塞控制算法的分类体系及其演进关系。




图 2.1 拥塞控制算法分类体系

2.1 传统拥塞控制算法

传统的 TCP 拥塞控制算法根据其使用的拥塞信号类型，可以分为基于丢包的算法、基于延迟的算法和混合算法三大类。

2.1.1 基于丢包的拥塞控制算法

基于丢包的拥塞控制算法将数据包丢失作为网络拥塞的主要判断信号。这类算法的核心思想是：当发送端检测到数据包丢失（通过超时或重复确认判断）时，认为网络发生了拥塞，需要降低发送速率以缓解拥塞。

TCP Tahoe 和 **TCP Reno** 是最早的拥塞控制算法，由 Van Jacobson 于 1988 年提出^[7]。TCP Tahoe 引入了慢启动(Slow Start)、拥塞避免(Congestion Avoidance)和快速重传(Fast Retransmit)三个核心机制。慢启动机制在连接建立初期指数级增加拥塞窗口，快速探测可用带宽；拥塞避免机制在窗口达到阈值后线性增加窗口，谨慎探测额外带宽；快速重传机制在收到三个重复确认时立即重传丢失的数据包，而无需等待超时。TCP Reno 在 Tahoe 的基础上增加了快速恢复(Fast Recovery)机制，在快速重传后将窗口减半而非重置为 1，提高了丢包后的恢复效率。

TCP NewReno^[1] 是对 TCP Reno 的改进，主要解决了 Reno 在多个数据包丢失时性能下降的问题。NewReno 修改了快速恢复机制的行为：在快速恢复期间，如果收到部分确认(Partial

ACK, 确认了部分但非全部已发送数据), 则继续保持在快速恢复状态, 直到所有丢失的数据包都被成功重传。这种改进使得 NewReno 能够更高效地处理突发丢包情况, 成为 RFC 6582 中定义的标准 TCP 拥塞控制算法之一。

TCP CUBIC^[2] 是目前 Linux 操作系统的默认拥塞控制算法, 自 Linux 2.6.19 版本开始采用。CUBIC 的核心创新是采用三次函数 (Cubic Function) 模型调整拥塞窗口大小:

$$W(t) = C \cdot (t - K)^3 + W_{max} \quad (2.1)$$

其中, $W(t)$ 是时刻 t 的窗口大小, C 是缩放因子, $K = \sqrt[3]{\frac{W_{max} \cdot \beta}{C}}$ 是从上次拥塞事件恢复到 W_{max} 所需的时间, W_{max} 是上次拥塞事件前的窗口大小, β 是窗口缩减因子。

CUBIC 的三次函数模型具有以下特点: (1) 在远离 W_{max} 时快速增长, 在接近 W_{max} 时缓慢增长, 实现了对可用带宽的稳定探测; (2) 窗口增长速度与 RTT 无关, 避免了传统 AIMD 算法在高 RTT 链路上收敛缓慢的问题; (3) 在 W_{max} 附近有一个“平台期”, 减少了在最优工作点附近的窗口振荡。

TCP BIC^[8] 是 CUBIC 的前身, 采用二分搜索 (Binary Search) 算法调整拥塞窗口。BIC 的基本思想是: 上次拥塞发生时的窗口 W_{max} 是带宽上限的估计, 当前窗口是带宽下限的估计, 通过二分搜索在两者之间寻找最优窗口。BIC 算法的窗口增长函数如下:

$$W_{new} = W_{current} + \frac{W_{max} - W_{current}}{2} \quad (2.2)$$

当窗口接近 W_{max} 时, BIC 采用加性增加策略以避免过冲。BIC 算法在高带宽延迟积网络中表现良好, 但其窗口增长行为对 RTT 不敏感, 在与其他 TCP 变体共存时可能产生公平性问题。

基于丢包的算法存在以下共同缺陷:

(1) **拥塞信号滞后**: 丢包是网络拥塞的滞后指示器。网络设备的缓冲区在溢出丢包前已经积累了大量排队数据, 导致排队延迟显著增加。在深缓冲区 (Deep Buffer) 网络环境中, 这种延迟可能达到数十甚至数百毫秒级别, 严重影响延迟敏感型应用的性能。

(2) **缓冲区膨胀**: 基于丢包算法的典型行为是持续增加发送速率直到发生丢包, 这会导致网络缓冲区长期处于高占用状态, 产生“Bufferbloat” (缓冲区膨胀) 问题^[9]。缓冲区膨胀不仅增加了网络延迟, 还降低了网络的整体吞吐量, 因为大量带宽被用于传输最终会被丢弃的数据包。

(3) **无法区分拥塞程度**: 基于丢包算法只能检测“有丢包”或“无丢包”两种状态, 无法区分轻度拥塞和严重拥塞。因此, 无论拥塞程度如何, 算法都采用统一的窗口缩减策略, 在轻度拥塞时可能响应过度, 在严重拥塞时又可能响应不足。

(4) **高 BDP 网络收敛缓慢**: 在高带宽延迟积网络中, 基于丢包算法的收敛速度极为缓慢。以 10Gbps 带宽、100 微秒 RTT 的链路为例, BDP 约为 125KB, 需要约 86 个 MSS 的窗口才能充分利用带宽。从初始窗口增长到 86 个 MSS 需要较长时间, 丢包后的恢复更是如此。

2.1.2 基于延迟的拥塞控制算法

基于延迟的拥塞控制算法通过监测往返时延 (RTT) 的变化来推断网络拥塞状态, 试图在丢包发生前就感知到拥塞并采取措施。这类算法的核心假设是: 网络拥塞会导致队列积累, 进而导致 RTT 增加。

TCP Vegas^[3] 是最早的基于延迟拥塞控制算法之一, 由 Lawrence Brakmo 和 Larry Peterson 于 1994 年提出。Vegas 通过比较期望吞吐量和实际吞吐量来估计网络中的排队数据量。期望吞吐量定义为:

$$Expected = \frac{cwnd}{BaseRTT} \quad (2.3)$$

实际吞吐量定义为:

$$Actual = \frac{cwnd}{RTT} \quad (2.4)$$

其中, $BaseRTT$ 是测量到的最小 RTT, 被认为是无排队情况下的传播延迟。差值 $\Delta = Expected - Actual$ 表示网络中排队的的数据量。Vegas 根据 Δ 的大小调整拥塞窗口:

$$cwnd = \begin{cases} cwnd + 1 & \text{如果 } \Delta < \alpha \\ cwnd - 1 & \text{如果 } \Delta > \beta \\ cwnd & \text{否则} \end{cases} \quad (2.5)$$

其中, α 和 β 是预设的阈值参数, 通常设置为 $\alpha = 1$ 、 $\beta = 3$ 。

TCP BBR^[4] (Bottleneck Bandwidth and Round-trip propagation time) 是 Google 于 2016 年提出的基于延迟算法, 是近年来最具影响力的拥塞控制算法之一。BBR 的核心思想是通过显式估计瓶颈带宽 (Bottleneck Bandwidth, BtlBw) 和最小 RTT (RTT_{prop}), 以带宽延迟积为目标调整发送速率。

BBR 通过维护一个滑动窗口来跟踪最大投递率 (作为 BtlBw 的估计) 和最小 RTT (作为 RTT_{prop} 的估计)。发送速率和拥塞窗口按以下方式计算:

$$pacing_rate = \frac{pacing_gain \times BtlBw}{6} \quad (2.6)$$

$$cwnd = cwnd_gain \times BDP = cwnd_gain \times BtlBw \times RTT_{prop} \quad (2.7)$$

BBR 采用周期性的增益调整策略，在不同阶段采用不同的 $pacing_gain$ 和 $cwnd_gain$ 值，以实现带宽探测和 RTT 测量。

TCP Copa^[10] 是 MIT 于 2018 年提出的基于延迟算法，采用了与 Vegas 类似但更精细的 RTT 监测机制。Copa 将目标排队延迟设定为 $RTT_{standing} - RTT_{min}$ 的函数，其中 $RTT_{standing}$ 是最近一个 RTT 窗口内的最小 RTT。Copa 采用以下窗口调整规则：

$$cwnd = cwnd + \frac{1}{cwnd \cdot \delta} \quad \text{或} \quad cwnd = cwnd - \frac{1}{cwnd \cdot \delta} \quad (2.8)$$

其中， δ 是目标延迟参数，默认值为 0.5。Copa 还引入了“竞争模式”检测机制，当检测到与基于丢包算法的流竞争时，会切换到更激进的发送策略。

基于延迟的算法存在以下共同问题：

(1) **RTT 测量不稳定**：RTT 测量受多种因素影响，包括操作系统调度延迟、网络路径抖动、网络拓扑变化、对端主机处理延迟等。在高速网络中，这些干扰因素可能与实际排队延迟处于同一数量级，导致基于 RTT 的拥塞推断不可靠。

(2) **公平性问题**：基于延迟算法在与基于丢包算法共存时存在严重的公平性问题。由于基于延迟算法对拥塞信号更敏感，会在 RTT 增加时提前降低发送速率，而基于丢包算法继续增加窗口直到丢包。研究表明，在与 CUBIC 流共存时，BBR 流的吞吐量可能下降 30% 以上^[11]。

(3) **参数敏感性**：基于延迟算法的性能对参数设置较为敏感。例如，Vegas 的 α 和 β 参数、Copa 的 δ 参数都需要根据具体网络环境进行调优，而静态参数难以适应动态变化的网络条件。

2.1.3 混合拥塞控制算法

混合拥塞控制算法综合利用丢包和延迟两种信号进行拥塞控制，试图结合两类算法的优点。

Compound TCP^[12] 是 Microsoft 开发的混合算法，在 Windows Vista 及后续版本中使用。Compound TCP 在传统的基于丢包的窗口增长之上叠加了一个基于延迟的“快速”窗口分量，在网络空闲时快速增长，在队列积累时减速增长。

TCP Illinois^[13] 根据 RTT 变化调整 AIMD 参数，在低延迟时采用更激进的增加策略，在高延迟时采用更保守的增加策略和更激进的减少策略。

TCP Westwood^[14] 通过测量 ACK 到达率来估计可用带宽，在丢包时根据估计的带宽而非固定比例调整慢启动阈值。

混合算法在一定程度上缓解了单一信号类型的局限性，但也增加了算法复杂性，且参数调优更加困难。

2.2 显式拥塞通知机制

显式拥塞通知（Explicit Congestion Notification, ECN）是由 IETF 在 RFC 3168^[15] 中定义的一种网络层辅助拥塞控制机制。ECN 通过修改 IP 报头中的服务类型字段（Type of Service, ToS）来传递拥塞信息，实现了比隐式丢包信号更早、更精确的拥塞通知。

2.2.1 ECN 工作原理

ECN 在 IP 报头中使用两个比特（ECN 字段），定义了四种码点：

- 00: Non-ECT（非 ECN 能力传输），表示端点不支持 ECN
- 01: ECT(1)（ECN 能力传输 1），表示端点支持 ECN
- 10: ECT(0)（ECN 能力传输 0），表示端点支持 ECN
- 11: CE（Congestion Experienced，拥塞经历），由路由器标记，表示经历了拥塞

ECN 的工作流程如下：发送端在发送数据包时将 ECN 字段设置为 ECT(0) 或 ECT(1)，表明该数据包支持 ECN。当网络设备（如路由器）检测到队列长度超过预设阈值时，将 ECN 字段从 ECT(0/1) 修改为 CE，而不是丢弃数据包。接收端收到 CE 标记的数据包后，在 TCP 报头中设置 ECE（ECN-Echo）标志，将拥塞信息反馈给发送端。发送端收到 ECE 标志后，采取拥塞响应措施（如降低发送速率），并在随后的数据包中设置 CWR（Congestion Window Reduced）标志，通知接收端已经响应了拥塞通知。图2.2展示了 ECN 信号传递的完整工作流程。

2.2.2 ECN 相关拥塞控制算法

DCTCP^[5]（Data Center TCP）是 Microsoft 和 Stanford 于 2010 年提出的面向数据中心环境的拥塞控制算法，是 ECN 应用的典范。DCTCP 的核心创新是利用 ECN 标记的**比例**（而非仅仅是有无）来进行细粒度的窗口调整。DCTCP 维护一个指数加权移动平均（EWMA）的 ECN 标记比例 α ：

$$\alpha = (1 - g) \cdot \alpha + g \cdot F \quad (2.9)$$




图 2.2 ECN 信号传递工作流程

其中, g 是平滑因子 (通常为 $1/16$), F 是最近一个 RTT 内被标记的数据包比例。拥塞窗口根据 α 进行调整:

$$cwnd = cwnd \times \left(1 - \frac{\alpha}{2}\right) \quad (2.10)$$

这种设计使得 DCTCP 能够根据拥塞程度进行比例响应: 轻度拥塞时 (α 较小) 轻微降低窗口, 严重拥塞时 (α 较大) 大幅降低窗口。

DCTCP 要求网络交换机配置适当的 ECN 标记阈值, 通常使用 RED (Random Early Detection) 或其变体。推荐的配置是将标记阈值设置为较低的值 (如 20 个数据包或 BDP 的 10%), 以实现早期拥塞通知。

ECN++^[16] 是对 DCTCP 的改进, 引入了更精细的 ECN 标记策略和响应机制。ECN++ 在接收端累积 ECN 标记计数, 而非仅使用二元 ECE 标志, 从而传递更丰富的拥塞信息。

HPCC^[17] (High Precision Congestion Control) 是阿里巴巴于 2019 年提出的高精度拥塞控制算法, 利用网络设备提供的精确拥塞信息 (如队列长度、带宽利用率) 进行拥塞控制。HPCC 要求网络设备支持 INT (In-band Network Telemetry) 功能。

ECN 机制的主要优势在于: (1) 能够在丢包发生前提供明确的拥塞信号; (2) 避免了因丢包导致的重传开销; (3) 信号来自网络设备的显式标记, 比推测性的 RTT 测量更可靠。然而, ECN 的有效使用需要网络设备的支持和正确配置, 且现有算法对 ECN 信号的利用还不够充分。

2.3 基于机器学习的拥塞控制方法

近年来，机器学习技术在网络拥塞控制领域的应用受到了广泛关注。根据所采用的学习范式，可以分为监督学习方法、强化学习方法和其他方法。

2.3.1 监督学习方法

监督学习方法通过从标记数据中学习拥塞控制策略。

Remy^[18] 是 MIT 于 2013 年提出的开创性工作，采用离线优化方法生成拥塞控制规则。Remy 将拥塞控制问题形式化为一个优化问题，在给定网络模型的情况下，搜索最优的窗口调整规则。Remy 的规则形式为：在特定状态下（由 RTT 测量、ACK 间隔等特征定义），执行特定的窗口增量和发送间隔调整。

Remy 的优点是能够针对特定网络环境生成最优规则，在目标场景下表现优异。其局限性在于：（1）需要准确的网络模型，对模型误差敏感；（2）离线生成的规则难以适应动态变化的网络环境；（3）状态空间划分的粒度影响算法性能和复杂度。

2.3.2 强化学习方法

强化学习方法通过与网络环境的交互来学习最优的拥塞控制策略，能够适应动态变化的网络条件。

Aurora^[19] 是 CMU 于 2019 年提出的基于深度强化学习的拥塞控制算法。Aurora 采用 PPO (Proximal Policy Optimization) 算法训练神经网络策略，输入网络状态特征（延迟梯度、延迟比率、发送比率等），输出发送速率调整因子。Aurora 的状态空间包含 10 个特征，涵盖延迟、吞吐量和丢包率的历史统计信息。

Aurora 的奖励函数设计为吞吐量和延迟的加权组合：

$$reward = throughput - \delta \cdot delay - \lambda \cdot loss \quad (2.11)$$

其中， δ 和 λ 是权重参数，控制延迟和丢包的惩罚程度。

Orca^[20] 是 UC Berkeley 于 2020 年提出的强化学习拥塞控制算法，采用经典的 AIMD 框架，但使用强化学习来动态调整 AIMD 参数。Orca 的核心思想是：AI 参数（增加因子 α 和减少因子 β ）不应是固定值，而应根据网络状态动态调整。

PCC^[21] (Performance-oriented Congestion Control) 是 UIUC 提出的基于在线学习的拥塞控制算法。PCC 采用实用函数 (Utility Function) 指导发送速率调整，通过在线实验探索最优速率。

$$U(x) = T \cdot x^\alpha - \delta \cdot L \cdot x - \beta \cdot D \cdot x \quad (2.12)$$

其中, x 是发送速率, T 是吞吐量, L 是丢包率, D 是延迟, α 、 δ 、 β 是参数。PCC 通过梯度上升方法最大化实用函数。

现有基于强化学习的方法存在以下共同问题:

- (1) **状态空间设计不完善**: 现有方案通常只使用 4-6 维的简化状态参数, 未能充分利用 TCP 协议栈提供的丰富状态信息, 特别是 ECN 相关状态和拥塞控制事件信息。
- (2) **奖励函数设计困难**: 吞吐量、延迟、公平性、丢包率等多个优化目标之间存在权衡关系, 设计能够平衡多目标的奖励函数是一个挑战。
- (3) **训练效率低下**: 网络仿真的计算开销较大, 限制了强化学习算法的训练效率。
- (4) **泛化能力有限**: 在特定网络环境下训练的策略可能难以泛化到其他环境。

2.4 远距离与异构终端网络特性分析

为了更好地理解 Swift 算法的设计动机, 本节分析远距离传输、多接入链路与异构终端并存环境中的网络特性。此类环境通常同时包含手机、笔记本电脑、台式机、边缘节点和云端服务等端系统, 端到端路径可能跨越无线接入、城域网、广域网和卫星链路, 网络条件随终端能力、接入方式和路径拥塞状态动态变化。

2.4.1 路径与接入特性

远距离与异构终端传输场景具有以下特点:

- (1) **往返时延跨度大**: 不同路径的 RTT 可能从毫秒级扩展到数百毫秒级。较大的带宽时延积使发送端需要更准确地估计可容纳的在途数据量, 否则容易出现带宽利用不足或队列持续驻留。
- (2) **接入链路异构**: 终端可能通过有线以太网、Wi-Fi、蜂窝网络或卫星链路接入网络。不同接入链路在带宽、误码、调度粒度和队列管理方式上差异显著, 使固定参数的拥塞控制难以同时适配多类路径。
- (3) **终端能力差异明显**: 手机、笔记本电脑、桌面终端和边缘设备在处理能力、网卡能力、缓冲区规模和操作系统协议栈配置方面存在差异, 这会影响 ACK 反馈节奏、突发发送行为和拥塞窗口恢复速度。
- (4) **路径状态动态变化**: 无线信道波动、移动性、跨流量突发和路由变化会导致 RTT、吞吐量和丢包风险快速变化。拥塞控制算法需要利用多维状态信号进行及时感知, 而不能仅依赖单一丢包反馈。

2.4.2 流量特性分析

远距离与多终端网络中的流量负载具有明显的多样性：

(1) **业务类型多样**：文件同步、视频会议、网页访问、远程桌面、云游戏、在线备份和模型数据传输等业务可能同时存在，对吞吐量、时延和稳定性的要求不同。

(2) **突发跨流量普遍**：非响应式 UDP 流、周期性上报、后台同步和多媒体码流可能在短时间内占用瓶颈队列，放大 RTT 抖动并干扰 TCP 长流的窗口控制。

(3) **长短流混合**：短流关注完成时间，长流关注持续吞吐量和稳定性。若拥塞控制响应过慢，短流可能受到排队延迟影响；若响应过激，长流又可能出现带宽利用不足。

(4) **反馈信号不完全一致**：丢包、ECN、RTT 膨胀和协议栈状态分别反映不同层面的网络变化。多信号融合能够降低单一信号误判带来的风险。

2.4.3 应用延迟需求分析

不同应用对网络延迟和吞吐量的需求并不相同：

(1) **实时交互业务**：视频会议、云游戏和远程协作要求持续低延迟，拥塞控制需要避免队列长期驻留。

(2) **大文件与数据同步业务**：云盘同步、备份和数据分发更关注带宽利用率，需要在不引发持续拥塞的前提下充分填充高 BDP 路径。

(3) **移动终端业务**：移动设备受无线链路波动和终端能耗约束影响，更需要平滑、稳定且可自适应的窗口调节策略。

(4) **边缘与云服务访问**：边缘计算、远程推理和跨区域服务调用同时关注时延、吞吐量和鲁棒性，需要算法在多目标之间动态权衡。

Swift 算法的“高吞吐、低排队、强鲁棒”设计目标正是为了适应上述复杂场景：在路径条件良好时保持较高带宽利用率，在拥塞或突发跨流量出现时及时降低排队和丢包风险。

2.4.4 网络设备与反馈机制特性

网络设备和协议栈反馈机制对拥塞控制算法有重要影响：

(1) **缓冲区规模差异**：不同接入设备和中间节点的缓冲区规模差异较大，浅缓冲链路更容易丢包，深缓冲链路更容易产生排队时延。

(2) **ECN 支持程度不一**：部分网络设备支持 ECN 标记，可以在队列溢出前提供早期拥塞信号。算法需要在可获得 ECN 信号时充分利用该信号，同时也在无 ECN 场景下仍保持基于丢包和 RTT 的稳健响应。

(3) **终端协议栈可观测性增强**：现代协议栈能够暴露拥塞状态、拥塞事件、RTT 样本和在途字节等信息，为强化学习辅助的多维状态建模提供基础。

(4) **部署形态多样**：拥塞控制逻辑既可以在内核 TCP 栈中实现，也可以在用户态传输协议或仿真环境中验证。统一的状态感知和窗口控制框架有助于后续迁移与工程化。

2.5 拥塞控制的理论基础

本节介绍网络拥塞控制的理论基础，包括流量模型、排队论分析和控制论视角，为理解 Swift 算法的设计决策提供理论支撑。

2.5.1 网络流量模型

网络流量建模是拥塞控制研究的基础。常用的流量模型包括：

(1) **泊松模型**：传统上假设数据包到达服从泊松过程，即到达间隔服从指数分布。泊松模型的数学性质简单，便于分析，但实际网络流量通常表现出更强的突发性。

(2) **自相似模型**：研究表明，网络流量具有自相似（Self-Similar）特性，即在不同时间尺度上呈现相似的统计特性。自相似流量可以用分数布朗运动（Fractional Brownian Motion）或 Pareto 分布建模。设流量过程为 $X(t)$ ，其自相似性定义为：

$$X(t) \stackrel{d}{=} m^{-H} X(mt), \quad \forall m > 0 \quad (2.13)$$

其中 H 是 Hurst 参数 ($0.5 < H < 1$)， $\stackrel{d}{=}$ 表示同分布。

(3) **ON-OFF 模型**：TCP 流量可以用 ON-OFF 模型描述，其中 ON 状态对应数据传输，OFF 状态对应等待。如果 ON 和 OFF 的持续时间服从重尾分布，聚合流量将表现出自相似特性。

(4) **流体模型**：在分析大规模网络时，可以将离散的数据包流近似为连续的流体流。设发送速率为 $x(t)$ ，队列长度为 $q(t)$ ，链路容量为 C ，则流体模型为：

$$\dot{q}(t) = x(t) - C, \quad \text{当 } q(t) > 0 \text{ 或 } x(t) > C \quad (2.14)$$

Swift 算法的设计考虑了流量的突发性特征。当前实现优先使用显式丢包回调和 ECN 状态作为拥塞判定信号，并将 RTT 膨胀用于 α 参数自适应调节，从而在突发跨流量和路径 RTT 波动下避免仅依赖单一信号作出窗口决策。

2.5.2 排队论分析

排队论为分析网络缓冲区行为提供了理论工具。考虑单个瓶颈链路，可以建模为 M/M/1 队列（泊松到达、指数服务时间、单服务器）或更一般的 G/G/1 队列。

M/M/1 队列的稳态性质：设到达率为 λ ，服务率为 μ ，负载为 $\rho = \lambda/\mu$ （ $\rho < 1$ 时队列稳定），则：

平均队列长度：

$$\bar{Q} = \frac{\rho}{1 - \rho} \quad (2.15)$$

平均等待时间（Little 公式）：

$$\bar{W} = \frac{\bar{Q}}{\lambda} = \frac{1}{\mu - \lambda} \quad (2.16)$$

队列长度分布：

$$P(Q = k) = (1 - \rho)\rho^k, \quad k = 0, 1, 2, \dots \quad (2.17)$$

从排队论角度，Swift 的低延迟特性源于其维持较低的平均负载 ρ 。通过对 ECN 信号的敏感响应，Swift 在 ρ 接近 1 之前就降低发送速率，从而保持 $\bar{Q}$ 和 $\bar{W}$ 在较低水平。

ECN 标记概率：设队列长度为 Q ，ECN 标记阈值为 K ，则在 RED (Random Early Detection) 策略下：

$$P(\text{标记}|Q) = \begin{cases} 0 & Q < \text{min_th} \\ \frac{Q - \text{min_th}}{\text{max_th} - \text{min_th}} & \text{min_th} \leq Q < \text{max_th} \\ 1 & Q \geq \text{max_th} \end{cases} \quad (2.18)$$

Swift 对 ECN 的利用采用直接状态检测机制：当 `ecnState` 为 `ECN_CE_RCVD` 或 `ECN_ECE_RCVD` 时，判定存在 ECN 拥塞信号，触发保留因子为 0.75 的早期预警窗口缩减。这种直接检测方式避免了基于事件率的间接测量，具有更低的响应延迟。

2.5.3 控制论视角

从控制论角度，TCP 拥塞控制可以建模为反馈控制系统。系统框图包括：

- 被控对象：网络（包括链路、路由器、队列）
- 控制器：拥塞控制算法
- 反馈信号：ACK、RTT、ECN 标记、丢包
- 控制输入：发送窗口或发送速率

- 干扰：跨流量、背景噪声

线性化分析：在稳态点附近，TCP 系统可以线性化。设稳态发送速率为 x^* ，稳态队列长度为 q^* ，令 $\delta x = x - x^*$ ， $\delta q = q - q^*$ ，则线性化系统为：

$$\dot{\delta q} = \delta x \quad (2.19)$$

$$\delta x(t) = -K \cdot \delta q(t - \tau) \quad (2.20)$$

其中 K 是控制增益， τ 是反馈延迟（约等于 RTT）。

系统的特征方程为：

$$s + Ke^{-s\tau} = 0 \quad (2.21)$$

稳定性条件（小增益定理）：

$$K\tau < \frac{\pi}{2} \quad (2.22)$$

这意味着在高延迟网络中，控制增益 K 必须足够小以保证稳定性，但过小的 K 会导致收敛缓慢。Swift 的自适应参数调优机制可以理解为根据 τ （通过 RTT 测量）动态调整 K （通过 α 参数）。

时滞系统分析：网络的反馈延迟（RTT）使得拥塞控制成为时滞系统。时滞系统的稳定性分析比常微分方程系统更复杂。Swift 通过综合使用多种拥塞信号，减少了对单一信号（如 RTT）的依赖，提高了系统的鲁棒性。

2.6 强化学习在网络中的应用综述

强化学习技术在网络领域的应用日益广泛。本节综述强化学习在路由优化、资源分配、安全防护等方面的研究进展，为 Swift 算法的强化学习设计提供参考。

2.6.1 路由优化

强化学习可以用于学习最优路由策略。Q-routing 算法将每个路由器建模为智能体，学习到各目的地的最优下一跳。Deep Q-Network (DQN) 被应用于软件定义网络 (SDN) 中的流量工程，学习全局最优的路由配置。

与路由优化相比，拥塞控制的特点是：（1）时间尺度更细（毫秒级 vs. 秒级）；（2）状态空间更大（每个流独立状态）；（3）实时性要求更高。这些特点决定了 Swift 采用基于规则的决策机制，而非深度神经网络。

2.6.2 资源分配

在云计算和边缘计算中，强化学习被用于动态资源分配。例如，使用深度强化学习进行虚拟机放置、容器调度、带宽分配等。这些应用的决策周期通常在秒级到分钟级，对实时性要求较低。

Swift 算法借鉴了资源分配中的多目标优化思想，通过差异化响应机制平衡吞吐量和延迟两个目标。

2.6.3 安全防护

强化学习在网络安全领域也有应用，如入侵检测、DDoS 防护等。与安全应用不同，拥塞控制需要处理合法流量，不能简单地丢弃可疑流量，需要更精细的控制策略。

2.6.4 与 Swift 的关系

Swift 算法继承了强化学习的核心思想——通过与环境交互学习最优策略，但在具体实现上做了以下调整：

- 采用基于规则的策略而非神经网络策略，保证实时性和可解释性
- 将观测空间扩展到 11 维，充分利用 TCP 协议栈信息
- 实现每流独立状态管理，支持大规模并发场景
- 通过自适应参数调优实现策略的在线优化

表2.1从多个维度对比了上述代表性拥塞控制算法与 Swift 的技术特性。

表 2.1 代表性拥塞控制算法综合对比

特性	NewReno	CUBIC	BBR	DCTCP	Swift
拥塞信号类型	丢包	丢包	RTT	ECN 比例	多信号融合
ECN 利用	否	否	否	是	是
差异化响应	否	否	否	部分	是
参数自适应	否	否	否	否	是
BDP 估计	否	否	是	否	是
每流状态管理	是	是	是	是	是
可解释性	高	高	中	高	高
学习能力	无	无	无	无	在线自适应

2.7 本章小结

本章综述了网络拥塞控制领域的相关研究工作。传统的基于丢包算法（如 NewReno、CU-BIC）虽然成熟稳定，但存在拥塞信号滞后、缓冲区膨胀等问题；基于延迟算法（如 Vegas、BBR）能够提前感知拥塞，但 RTT 测量不稳定且公平性较差；ECN 机制提供了更精确的拥塞信号，但现有算法的利用还不够充分；基于机器学习的方法展现出自适应学习的潜力，但仍存在状态空间设计、奖励函数设计、训练效率等方面的问题。

Swift 算法在现有工作的基础上，通过设计完整的 11 维观测空间、提出多信号融合拥塞检测方法、实现差异化拥塞响应机制和自适应参数调优，试图解决上述问题，实现高吞吐量和低延迟的拥塞控制目标。

第三章 Swift 算法设计与实现

本章详细介绍 Swift 算法的设计与实现，包括系统架构概述、强化学习问题建模、11 维观测空间设计、多信号融合拥塞检测算法、差异化拥塞响应机制、强化学习驱动的自适应参数调优、融合控制策略以及每流独立状态管理机制。

3.1 系统架构概述

Swift 算法的系统架构如图3.1所示，由四个核心模块组成：网络仿真模块、拥塞控制环境模块、智能决策模块和进程间通信模块。




图 3.1 Swift 系统架构

网络仿真模块基于 ns-3 (Network Simulator 3) 离散事件仿真平台构建, 实现完整的 TCP/IP 协议栈。ns-3 是目前学术界和工业界广泛使用的网络仿真工具, 提供了丰富的网络协议模型和灵活的可扩展架构。网络仿真模块负责构建哑铃型等可控拓扑、模拟数据包传输过程、执行离散事件驱动的仿真调度, 并通过 FlowMonitor 等工具记录吞吐量、时延、丢包和公平性指标。

主动队列管理与 ECN 信号通路。仿真器 contrib/opengym/examples/swift-tcp/sim.cc 将瓶颈两侧网关的默认队列规则设为 `ns3::RedQueueDisc`, 并按队列容量的比例配置标记门限: $MinTh = 0.3 \times Q$ 、 $MaxTh = 0.9 \times Q$, 其中 $Q = \max(BDP \times n_{leaf} / MTU, 100)$ 为按带宽延迟积自动定尺的队列长度 (单位为数据包)。同时置 `RedQueueDisc::UseEcn` 为真, 使 RED 在队列长度进入 $[MinTh, MaxTh]$ 区间时对 ECT 数据包置 CE 码点而非直接丢弃。

该配置对本文的算法评估具有决定性意义。ns-3 默认的 `PfifoFastQueueDisc` 是纯

FIFO 丢尾队列, 永不设置 CE 码点; 若沿用该默认值, 则协议栈上报的 `ecnState` 将始终停留在 `ECN_IDLE`, 第 3.4 节所述 ECN 分支及其 0.75 保留因子在整个仿真过程中都不会被触发, 算法退化为纯丢包驱动, ECN 早期预警的作用也就无从验证。第四章说明, 本文归档实验正是在该默认值下生成的, 因此其结论仅刻画纯丢包信号条件下的算法行为。此外, `ns3::TcpSocketBase::UseEcn` 被统一置为 `on` 并作用于全部四种被比较协议, 而不是仅对 Swift 开启: ECN 协商能力直接影响拥塞信号的到达时刻, 若仅令待评估算法具备该能力, 则对照实验中观测到的延迟与丢包差异将无法区分算法设计的贡献与信号通路配置的差异。统一开启 ECN 是保证四协议对照公平性的必要条件。

本研究中的 Swift 实验采用 `ns3-gym` 提供的 `OpenGym` 接口与 Python 智能决策模块交互。仿真进程在 TCP 回调处同步发送观测向量, Python 侧根据观测向量返回慢启动阈值和拥塞窗口动作。由于 `OpenGym/ZeroMQ` 采用同步请求-应答交互路径, 本文实现未将该路径与 MTP 多线程并行仿真机制结合使用。

拥塞控制环境模块基于 `OpenGym` 框架实现, 负责在 TCP 协议栈与强化学习智能体之间建立桥梁。`OpenGym` 是 `ns3-gym` 项目提供的强化学习环境接口, 遵循 `OpenAI Gym` 的标准 API 规范。拥塞控制环境模块在 TCP 协议栈的关键回调点采集状态参数, 构建 11 维观测空间, 并将智能体的决策动作应用于 TCP 连接。

拥塞控制环境模块实现了以下回调接口:

- `GetSsThresh()`: 慢启动阈值获取回调, 在检测到丢包时调用
- `IncreaseWindow()`: 窗口增加回调, 在收到正常确认时调用
- `PktsAcked()`: 数据包确认回调, 用于 RTT 测量和吞吐量计算
- `CongestionStateSet()`: 拥塞状态设置回调, 用于跟踪拥塞控制状态机变化
- `CwndEvent()`: 拥塞窗口事件回调, 用于捕获 ECN 标记等事件

智能决策模块采用 Python 实现, 负责执行 Swift 算法的核心逻辑: 多信号融合拥塞检测、差异化拥塞响应、自适应参数调优和融合控制策略计算。智能决策模块维护每个 TCP 连接的独立状态, 包括历史度量缓冲区、ECN 事件跟踪数据、性能指标数据和自适应参数数据。

进程间通信模块采用 `ZeroMQ (ZMQ)` 消息队列实现仿真进程和决策进程之间的高效通信。通信协议采用请求-应答 (`Request-Reply`) 模式: 仿真进程在每个回调点发送观测数据请求, 决策进程返回控制动作应答。消息格式采用 `Protocol Buffers` 序列化, 保证了通信效率和跨语言兼容性。

3.2 强化学习问题建模

Swift 算法将网络拥塞控制问题建模为马尔可夫决策过程(Markov Decision Process, MDP)。MDP 是强化学习的标准数学框架, 由五元组 $\langle S, A, P, R, \gamma \rangle$ 定义:

- S : 状态空间, 表示所有可能的网络状态
- A : 动作空间, 表示所有可能的控制动作
- P : 状态转移概率函数, $P(s'|s, a)$ 表示在状态 s 执行动作 a 后转移到状态 s' 的概率
- R : 奖励函数, $R(s, a, s')$ 表示状态转移的即时奖励
- γ : 折扣因子, $0 \leq \gamma \leq 1$, 表示未来奖励的衰减程度

3.2.1 状态空间设计理论

状态空间的设计是强化学习问题建模的关键环节。一个良好设计的状态空间应当满足以下理论要求:

马尔可夫性 (Markov Property): 当前状态应包含做出最优决策所需的全部信息, 即给定当前状态, 未来的状态和奖励与过去的状态序列条件独立。数学形式化表示为:

$$P(s_{t+1}, r_{t+1} | s_t, a_t, s_{t-1}, a_{t-1}, \dots, s_0, a_0) = P(s_{t+1}, r_{t+1} | s_t, a_t) \quad (3.1)$$

在网络拥塞控制场景中, 完全满足马尔可夫性是困难的, 因为网络状态可能依赖于较长的历史。Swift 通过在状态中包含 ECN 状态、CA 状态等协议栈内部状态, 在实际应用中近似满足马尔可夫性。

信息充分性 (Information Sufficiency): 状态应包含做出最优决策所需的充分信息。信息不足会导致智能体无法区分需要不同动作的情况, 从而影响学习效果。Swift 的 11 维状态空间涵盖了 TCP 协议栈提供的所有关键信息, 保证了信息充分性。

维度可扩展性 (Dimensional Scalability): 状态空间的维度不应过高, 否则会导致维度灾难 (Curse of Dimensionality) 问题。Swift 的 11 维状态空间在现有方案中属于较高维度, 但在可处理范围内。基于规则的决策机制避免了维度灾难问题。

可观测性 (Observability): 状态应能够从环境中直接或间接观测获得。Swift 的 15 个状态参数均可从 ns-3 TCP 模块的标准回调接口直接获取, 满足可观测性要求。

3.2.2 动作空间设计理论

动作空间的设计决定了智能体能够执行的控制操作范围。Swift 采用连续动作空间，直接输出新的 `ssthresh` 和 `cwnd` 值。这种设计的理论考量如下：

控制粒度 (Control Granularity)：连续动作空间提供了最细的控制粒度，允许智能体精确调整控制参数。相比之下，离散动作空间（如“增加 10%”、“减少 10%”）限制了控制的精确性。

探索效率 (Exploration Efficiency)：连续动作空间的探索效率取决于动作的参数化形式。Swift 通过直接输出绝对值而非增量，避免了累积误差问题。

约束满足 (Constraint Satisfaction)：动作应满足 TCP 协议的约束条件。Swift 通过在动作输出后应用边界约束，保证输出的控制参数始终有效。

3.2.3 奖励函数设计理论

奖励函数是强化学习的核心组件，决定了智能体的优化目标。奖励函数设计的理论要求包括：

稀疏性问题 (Sparsity Problem)：如果奖励只在特定事件（如完成文件传输）时给出，智能体可能难以学习中间步骤的价值。Swift 采用即时奖励（每次决策都给出奖励），避免了稀疏性问题。

多目标权衡 (Multi-objective Trade-off)：网络拥塞控制需要平衡多个目标（吞吐量、延迟、公平性、丢包率）。Swift 的奖励函数将吞吐量和延迟结合，通过权重参数控制优化偏好。

奖励塑形 (Reward Shaping)：适当的奖励塑形可以使奖励信号既反映吞吐收益，也反映排队和拥塞代价。当前实现中，正常确认事件的奖励由确认段数带来的吞吐收益减去 RTT 膨胀惩罚组成；ECN、普通丢包和超时丢包分别施加不同强度的负奖励。Python 侧再通过奖励 EMA 参与 α 微调。

3.2.4 策略表示理论

策略 (Policy) 定义了状态到动作的映射。Swift 采用基于规则的确定性策略，而非随机策略或神经网络策略。这种选择的理论考量如下：

确定性 vs. 随机性：确定性策略在给定状态下总是执行相同的动作，具有更好的可预测性和可解释性。随机策略可以提供更好的探索能力，但在部署阶段通常不需要探索。

参数化 vs. 非参数化：神经网络策略是参数化策略，具有强大的表示能力，但训练和推理有计算开销。基于规则的策略是非参数化策略，计算效率高但表示能力有限。Swift 选择基于规则的策略，牺牲部分表示能力换取实时性和可解释性。

在线学习 vs. 离线设计：Swift 的规则是离线设计的，不需要在线学习过程。这避免了在线学习可能带来的不稳定性，但也限制了算法对未知环境的适应能力。

3.3 11 维观测空间详细设计

本节详细描述 Swift 算法的 11 维观测空间设计，这是 Swift 区别于现有方案的核心创新之一。

记法约定：为与 ns-3 侧 OpenGym 实现 (contrib/opengym/examples/swift-tcp/tcp-swift-env.cc 中 parameterNum = 15) 保持一致，每次回调实际通过 Box 跨进程传输的是 15 个元素，其中前 4 个 (socketUuid、envType、simTime、nodeId) 为跨进程路由用的元数据通道，不参与 AIMD/ECN 响应/ α 自适应等窗口决策；后 11 个 (ssthresh、cwnd、segSize、segmentsAacked、bytesInFlight、lastRtt、minRtt、callbackType、caState、caEvent、ecnState) 构成参与决策的有效 RL 观测子空间。故下文所称“11 维观测空间”特指该有效 RL 子空间；表 3.1 同时列出元数据通道以便审阅者核对完整布局。

表 3.1 Swift 11 维观测空间参数定义

索引	参数名称	数据类型	说明
0	socketUuid	uint64	套接字唯一标识符
1	envType	uint64	环境类型 (0= 事件驱动, 1= 时间驱动)
2	simTime	uint64	仿真时间 (微秒)
3	nodeId	uint64	节点标识符
4	ssthresh	uint64	慢启动阈值 (字节)
5	cwnd	uint64	拥塞窗口大小 (字节)
6	segSize	uint64	TCP 报文段大小 (字节)
7	segmentsAacked	uint64	本次确认的报文段数量
8	bytesInFlight	uint64	在途字节数
9	lastRtt	uint64	最近往返时延 (微秒)
10	minRtt	uint64	最小往返时延 (微秒)
11	callbackType	uint64	回调函数类型
12	caState	uint64	拥塞算法状态
13	caEvent	uint64	拥塞算法事件
14	ecnState	uint64	ECN 状态

3.3.1 连接标识参数 (索引 0、3)

socketUuid (索引 0) 是套接字的唯一标识符，用于区分不同的 TCP 连接。在多流并发场景下，每个流需要维护独立的状态信息，socketUuid 是实现每流状态隔离的关键。socketUuid 在连接建立时由系统分配，在连接生命周期内保持不变。

nodeId (索引 3) 是网络节点的标识符，用于区分不同的发送端节点。在多节点仿真场景下，不同节点可能运行不同的拥塞控制算法或具有不同的网络条件，nodeId 用于识别当前决

策所属的节点。

3.3.2 时间信息参数（索引 1、2）

envType（索引 1）是环境类型标识符。当前 OpenGym 事件驱动实现中该字段固定为 0，用于标识观测来自 TCP 回调事件路径。

simTime（索引 2）是当前仿真时间，单位为微秒。仿真时间用于标识观测发生的事件顺序，并为跨进程观测和动作交互提供时间上下文。

3.3.3 窗口状态参数（索引 4、5）

ssthresh（索引 4）是慢启动阈值（Slow Start Threshold），单位为字节。**ssthresh** 是 TCP 拥塞控制的核心状态变量之一，用于区分慢启动阶段和拥塞避免阶段：当 $cwnd < ssthresh$ 时处于慢启动阶段，窗口指数增长；当 $cwnd \geq ssthresh$ 时进入拥塞避免阶段，窗口线性增长。

cwnd（索引 5）是拥塞窗口（Congestion Window）大小，单位为字节。**cwnd** 是 TCP 拥塞控制的另一核心状态变量，决定了发送端在未收到确认的情况下最多可以发送的数据量。**cwnd** 的调整是拥塞控制的核心任务。

3.3.4 传输性能参数（索引 6、7、8）

segSize（索引 6）是 TCP 报文段大小（Maximum Segment Size, MSS），单位为字节。本文仿真器按 $mtu_bytes - 20 - (IPv4 \text{ 首部} + TCP \text{ 首部})$ 计算应用层数据单元，在 MTU 为 1500 字节、IPv4 与 TCP 首部各 20 字节的默认配置下得到 1440 字节，其中额外扣除的 20 字节为仿真器为 TCP 选项字段预留的余量。**segSize** 用于将以字节为单位的窗口度量换算为以报文段为单位的度量，并且是慢启动增量、加性递增步长以及窗口上下界的共同基准单位，因此该值的准确性直接决定全部窗口计算的量纲一致性。

segmentsAcked（索引 7）是本次确认的报文段数量。在收到累积确认（Cumulative ACK）或选择性确认（Selective ACK, SACK）时，**segmentsAcked** 表示新确认的报文段数量。**segmentsAcked** 用于计算窗口增长量，例如在慢启动阶段，窗口增长量为 $segmentsAcked \times MSS$ 。

bytesInFlight（索引 8）是在途字节数（Bytes in Flight），即已发送但尚未确认的数据量。**bytesInFlight** 用于计算管道利用率（Pipeline Utilization）：

$$utilization = \frac{bytesInFlight}{cwnd} \quad (3.2)$$

当 **utilization** 较低时，表明发送端未能充分利用拥塞窗口，可能是因为应用层数据不足或

接收端通告窗口限制。

3.3.5 延迟测量参数（索引 9、10）

lastRtt（索引 9）是最近测量的往返时延（Round-Trip Time），单位为微秒。RTT 是端到端延迟的直接度量，包括传播延迟（Propagation Delay）、排队延迟（Queuing Delay）、处理延迟（Processing Delay）和传输延迟（Transmission Delay）四个组成部分。

minRtt（索引 10）是历史最小往返时延，单位为微秒。minRtt 作为路径传播时延的保守下界，用于估计带宽延迟积（BDP）和计算 RTT 膨胀程度。RTT 膨胀比定义为：

$$inflation_ratio = \frac{lastRtt}{minRtt} \quad (3.3)$$

当 inflation_ratio 接近 1 时，表明网络排队延迟较小；当 inflation_ratio 较大时，表明网络存在显著的排队延迟。

3.3.6 回调类型参数（索引 11）

callbackType（索引 11）标识当前回调的类型，用于区分不同类型的事件。定义如下：

- 值为 0：GetSsThresh 回调，表示检测到丢包事件，需要更新慢启动阈值
- 值为 1：IncreaseWindow 回调，表示收到正常确认，可以增加拥塞窗口

callbackType 是多信号融合拥塞检测的关键输入之一。当 callbackType 为 0 时，可以明确判断发生了丢包，这是最高优先级的拥塞信号。

3.3.7 拥塞控制状态参数（索引 12、13、14）

caState（索引 12）是拥塞算法状态（Congestion Algorithm State），反映 TCP 拥塞控制状态机的当前状态。Linux TCP 实现定义了以下状态：

- CA_OPEN（值为 0）：开放状态，正常传输，无拥塞迹象
- CA_DISORDER（值为 1）：无序状态，收到重复确认或乱序确认
- CA_CWR（值为 2）：拥塞窗口缩减状态，响应 ECN 标记
- CA_RECOVERY（值为 3）：恢复状态，快速恢复过程中

- CA_LOSS (值为 4): 丢失状态, 检测到超时丢包

caEvent (索引 13) 是拥塞算法事件 (Congestion Algorithm Event), 表示最近发生的拥塞相关事件。Linux TCP 实现定义了以下事件:

- CA_EVENT_TX_START (值为 0): 传输开始事件
- CA_EVENT_CWND_RESTART (值为 1): 拥塞窗口重启事件
- CA_EVENT_COMPLETE_CWR (值为 2): CWR 完成事件
- CA_EVENT_LOSS (值为 3): 丢失事件
- CA_EVENT_ECN_NO_CE (值为 4): 无 CE 标记的 ECN 事件
- CA_EVENT_ECN_IS_CE (值为 5): 有 CE 标记的 ECN 事件

ecnState (索引 14) 是显式拥塞通知状态 (ECN State), 反映 ECN 协商和标记的状态。定义如下:

- ECN_DISABLED (值为 0): ECN 禁用
- ECN_IDLE (值为 1): ECN 空闲
- ECN_CE_RCVD (值为 2): 收到 CE 标记
- ECN_SENDING_ECE (值为 3): 正在发送 ECE 标志
- ECN_ECE_RCVD (值为 4): 收到 ECE 标志
- ECN_CWR_SENT (值为 5): 已发送 CWR 标志

这三个拥塞控制状态参数是 Swift 观测空间的核心创新。现有强化学习拥塞控制方案通常不包含这些协议栈内部状态, 导致智能体对网络拥塞状况的感知不完整。Swift 通过将 caState、caEvent、ecnState 纳入观测空间, 使智能体能够感知 TCP 协议栈的完整状态信息, 从而做出更精准的控制决策。

3.4 多信号融合拥塞检测算法

Swift 算法的核心创新之一是多信号融合拥塞检测方法。该方法综合利用丢包回调、ECN 状态和 TCP 拥塞状态机信息, 采用显式信号优先级判断拥塞类型, 并将 RTT 膨胀保留给参数自适应调节, 而不把 RTT 膨胀作为独立降窗触发条件。

3.4.1 拥塞信号分类

Swift 将拥塞信号分为四个类别，每一类信号在”发生时刻—可靠性—语义粒度”三个维度上具有不同特征，这构成了后续差异化响应的判据基础。

(1) 显式降窗信号：当 `callbackType` 为 0 (`GetSsThresh` 回调) 时，表明 ns-3 的 TCP 协议栈已经自行判定需要缩减发送窗口并向拥塞控制算法索取新的慢启动阈值。该回调是协议栈内部唯一的”权威降窗入口”，其触发条件包含快速重传检测到的丢包、重传超时以及 ECN 回显驱动的 CWR 进入三种情形，因此不能笼统地等同于”丢包”。Swift 在该回调内部再依据 `caState` 和 `ecnState` 做二次判别，这是本文与既有方案在信号解释粒度上的关键差异。

(2) ECN 拥塞经历信号：当 `ecnState` 取值为 `ECN_CE_RCVD` (值为 2，本端收到被标记 CE 的数据包) 或 `ECN_ECE_RCVD` (值为 4，本端收到对端回显的 ECE 标志) 时，表明路径上的队列长度已经越过 AQM 的标记门限，但尚未溢出。ECN 是唯一由网络设备主动生成、且不依赖丢包或 RTT 推断的拥塞证据，其时序显著早于丢包，因此适合作为早期预警。Swift 直接读取协议栈的 ECN 状态字段，而不维护标记事件的时间戳队列与标记率统计，从而避免了标记率阈值这一额外的敏感参数。

(3) 拥塞控制状态机信号：`caState` 刻画了协议栈当前所处的恢复阶段。其中 `CA_LOSS` (值为 4) 指示重传超时，是严重程度最高的信号；`CA_CWR` (值为 2) 指示协议栈正因 ECN 回显而缩减窗口，在语义上属于 ECN 响应而非丢包响应；`CA_DISORDER` 与 `CA_RECOVERY` 则指示乱序或快速恢复过程，不构成独立的降窗触发条件。将 `caState` 纳入观测使智能体能够在同一个 `GetSsThresh` 回调内区分”超时””ECN 驱动的 CWR”与”普通丢包”三条语义完全不同的路径。

(4) 延迟膨胀信号：RTT 膨胀比 (`lastRtt/minRtt`) 反映瓶颈队列的驻留程度。该信号连续可微、采样密度高，适合驱动参数的渐进调节；但它同时混杂了无线调度抖动、ACK 压缩、路径切换和终端侧处理延迟等非拥塞因素，在远距离与异构终端场景中误判概率明显高于前三类信号。因此 Swift 不将其用作独立的乘性递减触发条件，而仅用于 α 自适应与慢启动退出判定。

3.4.2 分层优先级机制

不同类型的拥塞信号具有不同的可靠性和紧迫程度，Swift 采用分层优先级机制进行处理：

第一优先级：显式降窗回调的三路语义判别

`GetSsThresh` 回调本身只说明”协议栈决定降窗”，并不说明降窗的原因。ns-3 的 `TcpSocketBase` 在三种情形下都会进入该回调：快速重传确认丢包、重传定时器超时（此时 `caState` 被置为

Algorithm 1 显式降窗回调的三路语义判别**Require:** 回调类型 *callbackType*, 拥塞算法状态 *caState*, ECN 状态 *ecnState*

```

1: if callbackType = 0 then                                ▷ GetSsThresh 回调
2:   is_congested  $\leftarrow$  True
3:   if caState = CA_LOSS then
4:     congestion_type  $\leftarrow$  TIMEOUT                    ▷ 重传超时
5:   else if ecnState  $\in$  {ECN_CE_RCVD, ECN_ECE_RCVD} or caState = CA_CWR
     then
6:     congestion_type  $\leftarrow$  ECN                        ▷ ECN 回显驱动的 CWR
7:   else
8:     congestion_type  $\leftarrow$  LOSS                        ▷ 快速重传丢包
9:   end if
10:  return (is_congested, congestion_type)
11: end if

```

CA_LOSS)、以及收到 ECE 回显后调用 EnterCwr (此时 *caState* 被置为 CA_CWR)。若不加以区分地把整个回调映射为“丢包”，则 ECN 提供的早期预警在响应环节会被当作队列已溢出处理，从而抵消 ECN 机制本应带来的时序优势——这正是本算法早期版本存在的语义缺陷。当前实现在回调内部按“超时优先、ECN 次之、普通丢包兜底”的顺序完成三路判别：CA_LOSS 对应最严重的路径级异常；*ecnState* 处于 CE_RCVD 或 ECE_RCVD、或 *caState* 已进入 CA_CWR 的情形归入 ECN 类；其余情形归入普通丢包类。三类判别结果分别驱动 0.50、0.75、0.70 三个窗口保留因子，使响应力度与信号严重程度保持单调一致。

第二优先级：ECN 拥塞经历信号检测**Algorithm 2** ECN 拥塞经历信号检测**Require:** ECN 状态 *ecnState*

```

1: if ecnState  $\in$  {ECN_CE_RCVD, ECN_ECE_RCVD} then
2:   is_congested  $\leftarrow$  True
3:   congestion_type  $\leftarrow$  ECN
4:   return (is_congested, congestion_type)
5: end if

```

当 *ecnState* 为 ECN_CE_RCVD (收到 CE 标记) 或 ECN_ECE_RCVD (收到 ECE 回显) 时，判定发生 ECN 拥塞。ECN 拥塞采用早期预警响应策略，当前实现的保留因子为 0.75；该值比普通丢包响应更温和，同时能够更及时释放队列压力。

3.4.3 信号优先级与误判抑制策略

Swift 的拥塞检测采用显式信号优先级，而不是将所有协议栈状态都作为独立拥塞触发条件。当前实现中，显式丢包回调具有最高优先级；ECN CE/ECE 状态是第二优先级的早期拥塞信号；RTT 膨胀、CA_CWR 和 CA_RECOVERY 等状态不直接触发降窗，而用于解释网络状态或影响后续参数调节。

(1) **显式丢包优先**: 当回调类型为 `GetSsThresh` 时, 算法认为 TCP 协议栈已经进入丢包相关处理路径, 并根据 CA 状态区分普通丢包和超时丢包。

(2) **ECN 直接触发早期响应**: 当 ECN 状态为 `ECN_CE_RCVD` 或 `ECN_ECE_RCVD` 时, 算法将其视为有效早期拥塞信号并触发 ECN 响应, 同时累加 ECN 计数器用于后续状态分析。

(3) **RTT 膨胀不单独触发降窗**: RTT 膨胀容易受到无线调度、ACK 压缩和路径抖动影响。当前实现将其用于 α 自适应调节和慢启动退出判断, 而不是作为独立拥塞事件直接执行乘性递减。

(4) **降窗后冻结抑制反弹**: 每次显式拥塞响应后, 算法冻结后续若干 ACK 事件中的窗口增长, 避免刚降窗后立即增窗造成二次排队。

3.4.4 完整拥塞检测算法

综合上述机制, Swift 的完整多信号融合拥塞检测算法如下:

Algorithm 3 多信号融合拥塞检测算法

Require: 观测状态 *obs*, 流状态 *state*

Ensure: 是否拥塞 *is_congested*, 拥塞类型 *type*

```

1:                                     ▷ 第一优先级: 显式降窗回调的三路语义判别
2: if obs.callbackType = 0 then                                     ▷ GetSsThresh 回调
3:   if obs.caState = CA_LOSS then
4:     state.loss_count  $\leftarrow$  state.loss_count + 1
5:     return (True, TIMEOUT)                                     ▷ 重传超时
6:   end if
7:   if obs.ecnState  $\in$  {ECN_CE_RCVD, ECN_ECE_RCVD} or obs.caState =
   CA_CWR then
8:     state.ecn_count  $\leftarrow$  state.ecn_count + 1
9:     return (True, ECN)                                     ▷ ECN 回显驱动的 CWR
10:  end if
11:  state.loss_count  $\leftarrow$  state.loss_count + 1
12:  return (True, LOSS)                                     ▷ 快速重传丢包
13: end if
14:                                     ▷ 第二优先级: IncreaseWindow 路径上的 ECN 状态巡检
15: if obs.ecnState  $\in$  {ECN_CE_RCVD, ECN_ECE_RCVD} then
16:   state.ecn_count  $\leftarrow$  state.ecn_count + 1
17:   return (True, ECN)
18: end if
19:                                     ▷ 未检测到拥塞
20: return (False, NONE)

```

该算法的时间复杂度为 $O(1)$, 仅涉及常数次整型比较, 不引入任何队列扫描或统计窗口维护开销, 因此可以在每个 ACK 事件上无条件执行。算法的两级结构也决定了拥塞类型判定的互斥性: 一次回调最多产生一个拥塞类型, 不存在多个信号同时触发导致窗口被重复缩减的情形。

3.5 差异化拥塞响应机制

Swift 算法针对不同类型的拥塞信号采用差异化的响应策略，核心是差异化窗口保留因子（Window Retention Factor）机制。

3.5.1 窗口保留因子设计

窗口保留因子 ρ 定义为拥塞响应后新窗口与原窗口的比值：

$$new_cwnd = \rho \cdot cwnd$$

(3.4)

传统算法（如 TCP Reno、CUBIC）对所有拥塞信号采用统一的窗口保留因子（通常为 0.5，即窗口减半）。这种”一刀切”的策略无法区分不同类型和程度的拥塞，在轻度拥塞时响应过度，在严重拥塞时响应不足。

Swift 根据拥塞类型设计了差异化的窗口保留因子：

表 3.2 差异化窗口保留因子

拥塞类型	保留因子	设计理由
丢包（Loss）	0.70	丢包是严重拥塞信号，需要较大幅度降低窗口
ECN 标记（ECN）	0.75	ECN 是早期信号，提前释放队列压力
超时丢失（Timeout）	0.50	超时表示最严重拥塞，需最大幅度窗口缩减

3.5.2 差异化响应的理论依据

差异化窗口保留因子的设计基于以下理论分析：

（1）拥塞信号的时序特性

ECN 标记是最早的拥塞信号，通常在队列长度超过低阈值时触发，此时网络可能只是轻度拥塞。丢包是较晚的拥塞信号，通常在队列溢出时发生，表明网络已经严重拥塞。超时丢包是最晚也最严重的拥塞信号，通常意味着多个数据包连续丢失或网络路径严重中断，需要最大力度的窗口缩减。

根据时序关系和严重程度，Swift 设计了三级差异化响应：ECN 标记采用早期预警响应（保留因子 0.75），丢包采用较激进的响应（保留因子 0.70），超时采用最激进的响应（保留因子 0.50）。这种阶梯式的响应力度设计用于匹配不同严重程度的拥塞信号，同时通过降窗后冻结机制抑制窗口立即反弹。

（2）信号可靠性分析

丢包是最可靠的拥塞信号，几乎不会出现误报 (False Positive)。ECN 标记的可靠性取决于网络设备的配置和标记阈值。如果阈值设置不当，可能出现过早或过晚标记。基于可靠性考虑，对丢包信号的响应应更加坚决；对 ECN 信号的响应既不能等同于丢包，也不能过于宽松。当前实现采用 0.75 的 ECN 保留因子，在早期释放队列压力和维持吞吐量之间取得折中。

(3) 吞吐量-延迟权衡

较低的窗口保留因子能够更快地缓解拥塞、降低延迟，但会导致吞吐量下降。较高的窗口保留因子能够维持较高的吞吐量，但可能延长拥塞持续时间。Swift 的差异化设计试图在吞吐量和延迟之间取得最优平衡。

3.5.3 慢启动阈值更新

除了拥塞窗口，拥塞响应还需要更新慢启动阈值。当前实现首先以 $\rho \times cwnd$ 计算新的拥塞窗口，并设置最小窗口边界 $W_{min} = \max(4 \times MSS, 1)$ 。慢启动阈值采用 BDP 锚定但不奖励队列膨胀的策略：

$$ref = \min(cwnd, \max(BDP, W_{min})) \quad (3.5)$$

$$new_ssthresh = \max(\rho \times ref, W_{min}, new_cwnd) \quad (3.6)$$

该设计避免在队列已膨胀时把慢启动阈值设置到过高水平，同时保证阈值不低于新的拥塞窗口，防止拥塞恢复阶段出现窗口停滞。

此外，Swift 引入连续缩减保护和降窗后冻结两项稳定性机制，二者作用于不同的时间尺度且相互配合。

连续缩减保护针对的是“窗口死亡螺旋”：在突发拥塞或无线批量误码期间，协议栈可能在很短时间内连续触发多次降窗回调，若每次都执行乘性递减，窗口将以指数速度塌缩至下界，随后需要数十个 RTT 才能重新填满管道。算法为每条流维护连续缩减计数器 d ，每次执行拥塞响应时 d 自增；当 d 超过 $D_{max} = 3$ 时，响应退化为“保持当前窗口”而不再继续缩减。取 $D_{max} = 3$ 的依据是：连续三次丢包响应后窗口仅余 $0.70^3 \approx 34.3\%$ ，已经低于传统算法单次窗口减半的结果，继续缩减的边际收益迅速递减而恢复代价持续上升。

降窗后冻结针对的是“降窗即反弹”：乘性递减只减小了发送窗口，瓶颈队列中已经排队的数据仍需一段时间才能排空；若在此期间立即恢复窗口增长，新注入的数据会与残留队列叠加，导致排队延迟不降反升，并可能诱发第二次拥塞事件。因此任一显式降窗后，算法冻结后续 4 个 ACK 事件中的窗口增长，为队列排空留出时间窗口。

两项机制的交互存在一个容易被忽视的细节：连续缩减计数器 d 的清零时机。当前实现只在“窗口确实发生增长”时才把 d 置零，即清零动作位于冻结判断之后；若把清零动作前置到冻结判断之前，则冻结期内每个被冻结的 ACK 事件都会误将 d 清零， D_{max} 计数被反复复位，连续缩减保护实际失效——这恰是本算法早期版本存在的语义缺陷。将清零动作与真实的窗口增长绑定，保证了“只有当算法确认网络已经恢复到可以增窗的状态时，才认为连续拥塞序列已经结束”。

3.5.4 差异化拥塞响应算法

Algorithm 4 差异化拥塞响应算法

Require: 当前窗口 $cwnd$ ，当前阈值 $ssthresh$ ，拥塞类型 $type$ ，连续缩减计数 $consec_dec$

Ensure: 新窗口 new_cwnd ，新阈值 $new_ssthresh$

```

1:  $consec\_dec \leftarrow consec\_dec + 1$ 
2:                                     ▷ 连续缩减保护：超过 3 次后保持窗口
3: if  $consec\_dec > 3$  then
4:   return ( $cwnd, cwnd$ )                                     ▷ 保持当前窗口不再缩减
5: end if
6:                                     ▷ 根据拥塞类型选择窗口保留因子
7: if  $type = TIMEOUT$  then
8:    $\rho \leftarrow 0.50$                                          ▷ 超时：最严厉响应
9: else if  $type = LOSS$  then
10:   $\rho \leftarrow 0.70$                                          ▷ 丢包：较激进响应
11: else if  $type = ECN$  then
12:   $\rho \leftarrow 0.75$                                          ▷ ECN：早期预警响应
13: else
14:   $\rho \leftarrow 1.0$                                          ▷ 无拥塞，不调整
15: end if
16:                                     ▷ 计算新窗口
17:  $new\_cwnd \leftarrow \lfloor \rho \times cwnd \rfloor$ 
18:                                     ▷ 应用窗口下限约束
19:  $new\_cwnd \leftarrow \max(new\_cwnd, 4 \times MSS)$ 
20:                                     ▷ 计算新慢启动阈值：以 BDP 和当前窗口的较小有效参考为锚定
21:  $ref \leftarrow \min(cwnd, \max(bdp, 4 \times MSS))$ 
22:  $new\_ssthresh \leftarrow \max(\lfloor \rho \times ref \rfloor, new\_cwnd)$ 
23: return ( $new\_cwnd, new\_ssthresh$ )

```

3.6 强化学习驱动的自适应参数调优

Swift 算法实现了强化学习驱动的自适应参数调优机制，根据多种因素动态调整乘性增加因子（Multiplicative Increase Factor, α ）。

3.6.1 乘性增加因子的作用

在 Swift 的融合控制策略中，乘性增加因子 α 控制拥塞避免阶段的窗口增长速度：

$$target_ref = \alpha \times BDP + \gamma \times MSS \quad (3.7)$$

α 的取值决定了窗口围绕 BDP 目标的激进程度：较大的 α 使目标窗口更接近或略高于估计 BDP，能够更快地利用可用带宽，但也更容易形成排队；较小的 α 使目标窗口低于或接近 BDP，有利于排队释放和延迟恢复。

3.6.2 多因素调整机制

Swift 根据以下因素动态调整 α ：

(1) 基于 RTT 膨胀比的路径感知调整

RTT 膨胀比反映网络排队延迟程度：

$$inflation_ratio = \frac{lastRtt}{minRtt} \quad (3.8)$$

调整规则采用与最小 RTT 相关的动态阈值。首先根据最小 RTT 计算松弛量：

$$s = 0.3 + 0.15\sqrt{\max(0, RTT_{min,ms} - 1)} \quad (3.9)$$

并构造 $1 + s$ 、 $1 + 2s$ 和 $1 + 4s$ 三个路径感知阈值。短 RTT 路径对排队更敏感，阈值更紧；长 RTT 路径允许更大的正常抖动，阈值更宽。具体调整规则为：

- 当 $inflation_ratio < 1 + s$ 时，认为排队较小，增大 α ；若最小 RTT 超过 5 ms，则增长步长为 0.02，否则为 0.03。
- 当 $1 + s \leq inflation_ratio < 1 + 2s$ 时，认为排队适中，温和增大 α ： $\alpha \leftarrow \alpha + 0.01$ 。
- 当 $inflation_ratio > 1 + 4s$ 时，认为排队较重，减小 α ；若最小 RTT 超过 5 ms，则减小步长为 0.03，否则为 0.02。

这种路径感知响应机制能够避免固定阈值在远距离路径上过早收紧窗口，同时保留低 RTT 路径中对排队增长的敏感性。

(2) 基于奖励信号基线相对趋势的调整

Swift 利用环境反馈的奖励信号（Reward）评估当前控制策略的相对优劣。环境侧奖励在每个正常确认事件上由确认段数带来的吞吐收益减去 RTT 膨胀惩罚构成，因此在绝大多数

ACK 事件上取正值。这一分布特征决定了不能用固定的绝对阈值判断“奖励是否变好”：若采用形如 $R_{ema} > 0.5$ 的判据，则该条件在几乎每个 ACK 事件上都成立， α 会被持续推向上界 α_{max} ，自适应机制退化为单向棘轮，失去反馈意义。

当前实现改为**基线相对判据**，即同时维护快、慢两条指数移动平均，用快线相对慢线的偏离量而非绝对水平来判断趋势：

$$R_{fast} \leftarrow (1 - \eta_f) \times R_{fast} + \eta_f \times reward, \quad \eta_f = 0.15 \quad (3.10)$$

$$R_{base} \leftarrow (1 - \eta_b) \times R_{base} + \eta_b \times reward, \quad \eta_b = 0.02 \quad (3.11)$$

其中 R_{fast} 为快线，反映最近若干次决策的即时效果； R_{base} 为慢线基线，反映当前网络条件下的长期奖励水平。两条 EMA 在收到首个奖励时用同一数值初始化，避免冷启动阶段的虚假偏离。判定容差按基线幅值自适应缩放：

$$m = \max(0.25, 0.1 \times |R_{base}|) \quad (3.12)$$

调整规则为：

- 当 $R_{fast} > R_{base} + m$ 时，表明近期决策相对该路径的常态水平确有改善，适度提高激进度： $\alpha \leftarrow \alpha + 0.01$ 。
- 当 $R_{fast} < R_{base} - 4m$ 时，表明近期决策显著劣于常态水平，回退激进度： $\alpha \leftarrow \alpha - 0.01$ 。

下调阈值取 $4m$ 而上调阈值取 m ，构成有意的非对称设计：奖励序列的负向尖峰主要由单次丢包或超时惩罚引起，而这类事件已经由差异化拥塞响应机制单独处理，若在 α 层面再次同步收缩会造成响应叠加；采用较宽的下调死区可以把 α 的收缩限定在持续性劣化而非瞬时惩罚上。基线相对判据的另一优点是与路径无关：不同带宽和 RTT 的路径其奖励绝对幅值相差可达数个数量级，而相对偏离量是无量纲的，因此同一组超参数可以直接跨场景复用，无需按链路类型重新标定。

(3) 基于连续增长趋势的调整

当窗口连续增长超过 8 次时，表明网络状况持续良好，给予稳定增长奖励：

$$\alpha \leftarrow \alpha + 0.01 \quad \text{如果连续增长次数} > 8 \quad (3.13)$$

3.6.3 参数边界约束

为保证控制策略的稳定性， α 的取值被限制在预设范围内：

$$\alpha \in [\alpha_{min}, \alpha_{max}] = [0.85, 1.30] \quad (3.14)$$

α 的默认初始值为 1.10。下界 0.85 为无线、蜂窝或浅缓冲路径提供更强排队释放空间；上界 1.30 限制窗口相对于 BDP 的长期扩张幅度，避免慢性队列积累。

3.6.4 自适应参数调优算法

3.7 融合控制策略

Swift 采用融合控制策略计算目标拥塞窗口，将基于带宽延迟积（BDP）估计的速率控制与基于当前窗口的保守控制相结合。

3.7.1 带宽延迟积估计

带宽延迟积（Bandwidth-Delay Product, BDP）是网络链路能够容纳的最大在途数据量，是拥塞控制的重要参考指标：

$$BDP = Bandwidth \times RTT \quad (3.15)$$

Swift 采用“时间窗口投递速率采样 + 窗口化最大值过滤”两级结构估计瓶颈带宽，再与最小 RTT 相乘得到 BDP：

$$BDP = \max_{i \in W_{bw}} (DR_i) \times RTT_{min} \quad (3.16)$$

其中 W_{bw} 为容量 40 个样本的滑动窗口， RTT_{min} 为该流历史最小 RTT（同时接受协议栈上报的 minRtt 与本地观测的 lastRtt 作为候选下界）。

时间窗口投递速率采样。单个投递速率样本由累计确认字节数在一段时间窗口上的增量给出。算法为每条流维护累计确认字节数 $B(t)$ ，并在队列中记录二元组 $(t, B(t))$ ；每次收到确认后先更新 $B(t)$ ，再淘汰窗口左端超出时间跨度的样本，最后按下式计算样本：

$$DR = \frac{B(t) - B(t - \Delta)}{\Delta}, \quad \Delta = \text{clamp}(2 \times RTT_{min}, 5 \text{ ms}, 1 \text{ s}) \quad (3.17)$$

窗口跨度 Δ 取最小 RTT 的两倍，是为了让采样区间至少覆盖一个完整的 ACK 时钟周期：只有当窗口跨度不小于一个 RTT 时，窗口内的确认字节总量才等于瓶颈在该时段实际排空的数据量， DR 才具有“瓶颈排空速率”的物理含义。下界 5 ms 用于抑制微秒级 RTT 路径上因窗口过短而放大的采样噪声，上界 1 s 用于保证带宽下降时估计能够及时跟随。

Algorithm 5 自适应参数调优算法**Require:** 当前 α , 观测状态 obs , 奖励信号 $reward$, 历史状态 $history$ **Ensure:** 更新后的 α

```

1:                                     ▷ 因素 1: 基于 RTT 膨胀比的路径感知调整
2:  $inflation\_ratio \leftarrow obs.lastRtt / obs.minRtt$ 
3:  $min\_rtt\_ms \leftarrow obs.minRtt / 1000$ 
4:  $slack \leftarrow 0.3 + 0.15\sqrt{\max(0, min\_rtt\_ms - 1)}$ 
5:  $low \leftarrow 1 + slack, mid \leftarrow 1 + 2 \times slack, high \leftarrow 1 + 4 \times slack$ 
6: if  $inflation\_ratio < low$  then
7:    $ramp \leftarrow 0.02$  if  $min\_rtt\_ms > 5$  else  $0.03$ 
8:    $\alpha \leftarrow \alpha + ramp$ 
9:    $history.consecutive\_growth \leftarrow history.consecutive\_growth + 1$ 
10: else if  $inflation\_ratio < mid$  then
11:    $\alpha \leftarrow \alpha + 0.01$ 
12: else if  $inflation\_ratio > high$  then
13:    $step \leftarrow 0.03$  if  $min\_rtt\_ms > 5$  else  $0.02$ 
14:    $\alpha \leftarrow \alpha - step$ 
15:    $history.consecutive\_growth \leftarrow 0$ 
16: end if
17:                                     ▷ 因素 2: 基于奖励信号基线相对偏离的趋势调整
18: if 首次收到奖励 then
19:    $R_{fast} \leftarrow reward, R_{base} \leftarrow reward$ 
20: else
21:    $R_{fast} \leftarrow 0.85 \times R_{fast} + 0.15 \times reward$ 
22:    $R_{base} \leftarrow 0.98 \times R_{base} + 0.02 \times reward$ 
23: end if
24:  $m \leftarrow \max(0.25, 0.1 \times |R_{base}|)$ 
25: if  $R_{fast} > R_{base} + m$  then
26:    $\alpha \leftarrow \alpha + 0.01$ 
27: else if  $R_{fast} < R_{base} - 4 \times m$  then
28:    $\alpha \leftarrow \alpha - 0.01$ 
29: end if
30:                                     ▷ 因素 3: 基于连续稳定增长的奖励
31: if  $history.consecutive\_growth > 8$  then
32:    $\alpha \leftarrow \alpha + 0.01$ 
33: end if
34:                                     ▷ 应用边界约束
35:  $\alpha \leftarrow \max(\min(\alpha, 1.30), 0.85)$ 
36: return  $\alpha$ 

```

为何不能按单次确认计算投递速率。本算法早期版本采用形如 $DR = segmentsAcked \times segSize / lastRtt$ 的单次确认公式。该式的分子只包含本次确认的字节数，而分母却是整个 RTT，因此它实际估计的是“若一个 RTT 内只到达这一个确认时的速率”，与真实瓶颈速率相差约等于每 RTT 的确认个数 $N_{ack} \approx cwnd / (segSize \times b)$ （其中 b 为延迟确认因子）。在高 BDP 路径上 N_{ack} 可达数百，估计值因而被系统性压低同一量级，式 (3.16) 给出的 BDP 随之崩塌；此时拥塞避免阶段的目标窗口 $\alpha \times BDP$ 长期低于当前窗口，窗口只能停留在安全下界 $200 \times MSS$ 上，吞吐量被硬性锁定为 $200 \times MSS / RTT$ 。这一失效模式在第四章的跨域 WAN 场景中留下了可验证的痕迹，也是本文将该估计器整体替换为式 (3.17) 的直接原因。式 (3.17) 的分子与分母取自同一时间区间，量纲自洽，不再依赖每 RTT 确认个数。

窗口化最大值过滤。将 DR 样本压入容量 40 的滑动窗口并取窗口内最大值，其作用有三：(1) 投递速率样本天然为瓶颈能力的下界估计——确认稀疏、应用层供数不足或跨流量抢占都只会使样本偏小而不会偏大，因此取最大值是对真实瓶颈的一致估计；(2) 滑动窗口限制了历史记忆长度，使估计能够跟随带宽的真实下降，避免全局最大值带来的永久性高估；(3) 窗口容量取 40 而非较小值，是为了让长 RTT 路径在窗口内容纳足够多的采样周期——GEO 卫星链路单个 RTT 可达 600 ms，过短的窗口会在瓶颈被充分采样之前就发生淘汰，导致估计值在低位振荡。

此外，流级吞吐量趋势由指数移动平均跟踪，用于状态观察与性能记录：

$$throughput_ema \leftarrow 0.9 \times throughput_ema + 0.1 \times DR \quad (3.18)$$

BDP 估计的完整流程如算法 6 所示。当 $\max(DR)$ 尚未建立或 RTT_{min} 无效时，BDP 回退为当前拥塞窗口，使算法在连接建立初期退化为常规的窗口驱动行为而非产生无意义的目标值。

3.7.2 慢启动阶段策略

在慢启动阶段 ($cwnd < ssthresh$)，Swift 采用指数增长策略以快速探测可用带宽：

$$target_cwnd = 2 \times BDP \quad (3.19)$$

$$increment = segmentsAcked \times MSS \quad (3.20)$$

当窗口远低于 BDP 时，采用加速增长：

Algorithm 6 时间窗口投递速率与 BDP 估计**Require:** 流状态 *state*, 观测状态 *obs***Ensure:** BDP 估计值

```

1: if obs.lastRtt > 0 then
2:   state.min_rtt  $\leftarrow \min(\textit{state.min\_rtt}, \textit{obs.lastRtt})$ 
3: end if
4: if  $0 < \textit{obs.minRtt} < \textit{state.min\_rtt}$  then
5:   state.min_rtt  $\leftarrow \textit{obs.minRtt}$ 
6: end if
7: if obs.segmentsAked > 0 and obs.segSize > 0 then
8:   state.acked_total  $\leftarrow \textit{state.acked\_total} + \textit{obs.segmentsAked} \times \textit{obs.segSize}$ 
9:   state.samples.Append(obs.simTime, state.acked_total)
10:   $\Delta \leftarrow \text{clamp}(2 \times \textit{state.min\_rtt}, 5 \text{ ms}, 1 \text{ s})$ 
11:  while  $|\textit{state.samples}| \geq 2$  and  $\textit{obs.simTime} - \textit{state.samples}[0].t > \Delta$  do
12:    state.samples.PopFront()
13:  end while
14:  span  $\leftarrow \textit{obs.simTime} - \textit{state.samples}[0].t$ 
15:  delivered  $\leftarrow \textit{state.acked\_total} - \textit{state.samples}[0].B$ 
16:  if  $|\textit{state.samples}| \geq 2$  and span > 0 and delivered > 0 then
17:    DR  $\leftarrow \textit{delivered} / \textit{span}$ 
18:    state.bw_samples.Append(DR)
19:    state.max_bw  $\leftarrow \max(\textit{state.bw\_samples})$ 
20:  end if
21: end if
22: if state.max_bw > 0 and state.min_rtt <  $\infty$  then
23:   state.bdp  $\leftarrow \textit{state.max\_bw} \times \textit{state.min\_rtt}$ 
24: end if
25: return  $\textit{state.bdp} > 0 ? \textit{state.bdp} : \max(\textit{obs.cwnd}, 1)$ 

```

▷ 容量 40 的滑动窗口

$$\text{如果 } cwnd < 0.3 \times BDP, \quad \text{increment} = 2 \times \text{segmentsAked} \times MSS \quad (3.21)$$

慢启动目标设为 $2 \times BDP$ 而非更大值（如 $3 \times BDP$ ），是为了避免慢启动阶段过度膨胀导致突发丢包。当窗口达到目标值后，自动退出慢启动进入拥塞避免阶段。

3.7.3 拥塞避免阶段策略

在拥塞避免阶段（ $cwnd \geq ssthresh$ ），Swift 采用稳健的窗口增长策略：

$$\textit{target_ref} = \alpha \times BDP + \gamma \times MSS \quad (3.22)$$

其中， α 是乘性增加因子（通过自适应调优动态调整，基准值 1.10）， $\gamma = 1.0$ 是加性增加因子，表示每个 ACK 事件引入 1 个 MSS 的基础增量。拥塞避免阶段不再简单地以当前窗口作为下界持续取最大值，而是围绕 $\alpha \times BDP$ 目标进行拉升或回落：当目标高于当前窗口时，

以 $\max(\gamma \times MSS, MSS, gap/16)$ 的步长向目标靠近；当目标低于当前窗口时，每个 ACK 事件按超出量的一半进行回落，以更快释放浅缓冲路径中的排队。

融合控制策略还考虑管道利用率因素。管道利用率定义为：

$$utilization = \frac{bytesInFlight}{cwnd} \quad (3.23)$$

调整规则：

- 仅当 RTT 未明显膨胀 ($lastRtt < 1.3 \times minRtt$) 时启用利用率补偿。
- 当 $utilization < 0.4$ 时，短 RTT 路径额外增加 $2 \times MSS$ ，长 RTT 路径额外增加 $1 \times MSS$ 。
- 当 $0.4 \leq utilization < 0.5$ 且路径不是长 RTT 路径时，额外增加 $1 \times MSS$ 。

该设计只在管道确实未充分利用且队列未增长时加速，避免旧式利用率补偿在无线、蜂窝或浅缓冲路径中造成持续排队。

3.7.4 窗口边界约束

为保证窗口大小的合理性，Swift 对计算结果应用边界约束：

$$cwnd \in [4 \times MSS, \max(4 \times BDP, 200 \times MSS)] \quad (3.24)$$

下界 $4 \times MSS$ 保证基本传输能力。上界设为 BDP 的 4 倍或 200 个 MSS 的较大值，用于在 BDP 估计暂时偏大或路径缓冲较浅时限制窗口长期膨胀。

3.7.5 融合控制策略算法

3.8 每流独立状态管理

Swift 设计了每流独立的状态管理机制，为每个 TCP 连接维护独立的状态数据结构，支持多流并发场景下的差异化控制。

3.8.1 状态数据结构

每个 TCP 连接维护以下状态数据，采用层次化组织方式：

(1) 历史度量缓冲区：带宽估计维护两级队列。第一级是投递速率采样队列，记录“仿真时刻—累计确认字节数”二元组，容量上限 4096 项，用于按时间窗口差分计算单个投递速率

Algorithm 7 融合控制策略算法**Require:** 观测状态 obs , 自适应参数 α , $\gamma = 1.0$, BDP 估计 bdp **Ensure:** 新窗口 new_cwnd

```

1:  $\triangleright$  降窗后冻结: 显式降窗后的若干 ACK 事件内保持窗口不增长
2: if  $state.freeze\_acks\_remaining > 0$  then
3:    $state.freeze\_acks\_remaining \leftarrow state.freeze\_acks\_remaining - 1$ 
4:   return  $obs.ssthresh, obs.cwnd$ 
5: end if
6:  $\triangleright$  计算管道利用率
7:  $utilization \leftarrow obs.bytesInFlight / obs.cwnd$ 
8:  $\triangleright$  判断当前阶段
9: if  $obs.cwnd < obs.ssthresh$  and  $in\_slow\_start$  then
10:    $\triangleright$  HyStart 风格慢启动退出
11:   if  $obs.lastRtt > HystartThreshold(state) \times state.ss\_min\_rtt\_sample$  then
12:      $state.in\_slow\_start \leftarrow False$ 
13:     return  $\max(obs.ssthresh, obs.cwnd), obs.cwnd$ 
14:   end if
15:    $target \leftarrow \max(2 \times bdp, 10 \times obs.segSize)$ 
16:    $increment \leftarrow obs.segmentsAked \times obs.segSize$ 
17:   if  $obs.cwnd < 0.3 \times bdp$  and  $obs.lastRtt < 1.2 \times state.min\_rtt$  then
18:      $increment \leftarrow 2 \times obs.segmentsAked \times obs.segSize$ 
19:   end if
20:    $new\_cwnd \leftarrow \min(obs.cwnd + increment, target)$ 
21: else
22:    $\triangleright$  拥塞避免阶段: 围绕  $\alpha \times BDP$  目标进行有界步长拉升或回落
23:    $state.in\_slow\_start \leftarrow False$ 
24:    $target\_rate \leftarrow \lfloor \alpha \times bdp \rfloor$ 
25:    $gamma\_bytes \leftarrow \gamma \times obs.segSize$ 
26:   if  $target\_rate > obs.cwnd$  then
27:      $gap \leftarrow target\_rate - obs.cwnd$ 
28:      $step \leftarrow \max(gamma\_bytes, obs.segSize, gap/16)$ 
29:      $new\_cwnd \leftarrow \min(obs.cwnd + step, target\_rate + gamma\_bytes)$ 
30:   else if  $target\_rate < obs.cwnd$  then
31:      $excess \leftarrow obs.cwnd - target\_rate$ 
32:      $new\_cwnd \leftarrow \max(obs.cwnd - \max(excess/2, obs.segSize), target\_rate)$ 
33:   else
34:      $new\_cwnd \leftarrow obs.cwnd + gamma\_bytes$ 
35:   end if
36:    $\triangleright$  仅在 RTT 未膨胀时启用管道利用率补偿; 长 RTT 路径降低补偿强度
37:   if  $obs.lastRtt < 1.3 \times state.min\_rtt$  and  $utilization < 0.4$  then
38:      $new\_cwnd \leftarrow new\_cwnd + (state.min\_rtt > 5ms ? obs.segSize : 2 \times obs.segSize)$ 
39:   else if  $obs.lastRtt < 1.3 \times state.min\_rtt$  and  $utilization < 0.5$  and  $state.min\_rtt \leq 5ms$ 
then
40:      $new\_cwnd \leftarrow new\_cwnd + obs.segSize$ 
41:   end if
42: end if
43: return  $obs.ssthresh, new\_cwnd$ 

```

样本；每次更新时淘汰左端超出窗口跨度 $\Delta = \text{clamp}(2 \times RTT_{min}, 5 \text{ ms}, 1 \text{ s})$ 的样本，因此队列的实际长度随路径 RTT 与确认密度自适应变化。第二级是投递速率过滤队列，容量 40 个样本，取窗口内最大值作为瓶颈带宽估计。RTT 跟踪维护容量 40 个样本的最近 RTT 队列，同时维护该流的全局最小 RTT 作为传播延迟估计。BDP 由最大带宽与最小 RTT 的乘积得到，并在估计尚未建立时回退为当前拥塞窗口。

(2) **拥塞事件计数数据**：状态结构维护丢包事件计数和 ECN 标记事件计数，用于记录每条流在仿真过程中的拥塞事件分布。

(3) **性能指标数据**：性能指标模块维护吞吐量的指数移动平均值（EMA，平滑因子 0.1），用于跟踪流级别的性能变化趋势。

(4) **自适应参数数据**：自适应参数模块维护乘性增加因子 α （取值范围 [0.85, 1.30]，默认值 1.10）、加性增加因子 γ （默认值 1.0）、连续缩减计数器（用于连续缩减保护）、连续增长计数器（用于稳定增长奖励）、降窗后冻结 ACK 计数器（默认 4 个 ACK 事件）和慢启动阶段标记。

3.8.2 状态查找与更新

Swift 使用 socketUuid 作为键，通过哈希表实现 $O(1)$ 时间复杂度的状态查找和更新。哈希表的选择基于查找效率、动态扩展和内存效率三方面考量。

Algorithm 8 流状态查找与更新

```

1: function LookupFlowState(manager, socket_uuid)
2:   hash  $\leftarrow$  ComputeHash(socket_uuid)
3:   bucket  $\leftarrow$  manager.buckets[hash mod manager.num_buckets]
4:   for each entry in bucket do
5:     if entry.key = socket_uuid then
6:       return entry.value
7:     end if
8:   end for
9:   return null ▷ 未找到
10: end function
11: function UpdateFlowState(manager, socket_uuid, obs)
12:   state  $\leftarrow$  GetOrCreateFlowState(manager, socket_uuid)
13:   state.last_update_time  $\leftarrow$  obs[2]
14:   UpdateMetrics(state.metrics_buffer, obs)
15:   if IsECNEvent(obs) then
16:     state.ecn_tracker.RecordEvent(obs[2])
17:   end if
18:   UpdatePerformanceMetrics(state.performance, obs)
19: end function

```

3.8.3 状态生命周期管理

TCP 连接的生命周期包括建立、传输和关闭三个阶段。Swift 的状态管理遵循延迟初始化、增量更新、垃圾回收和状态持久化四个原则。

Algorithm 9 流状态垃圾回收

```

1: function GarbageCollect(manager, current_time, inactive_threshold)
2:   to_remove  $\leftarrow$  EmptyList()
3:   for each (uuid, state) in manager.flow_states do
4:     idle_time  $\leftarrow$  current_time - state.last_update_time
5:     if idle_time > inactive_threshold then
6:       to_remove.Append(uuid)
7:     end if
8:   end for
9:   for each uuid in to_remove do
10:    manager.flow_states.Remove(uuid)
11:    FreeResources(uuid)
12:   end for
13:   return |to_remove|
14: end function

```

3.9 实现细节与优化技术

本节详细介绍 Swift 算法的具体实现细节和优化技术。

3.9.1 系统架构设计

Swift 算法的系统架构遵循模块化设计原则，采用分层结构实现各功能模块的解耦。整体架构分为仿真层、环境层、决策层和通信层四个层次。仿真层负责网络拓扑构建和数据包传输仿真；环境层作为强化学习与网络仿真的桥梁；决策层实现 Swift 算法的核心逻辑，遵循状态隔离、分层决策和实时性原则；通信层负责仿真进程和决策进程之间的数据交换。

3.9.2 核心算法伪代码

Swift 智能体的主控制循环负责协调各功能模块，处理来自环境的观测并输出控制动作。

3.9.3 数据结构设计

Swift 算法采用高效的数据结构支持其核心功能。循环队列（Circular Buffer）用于存储带宽与 RTT 历史样本，具有固定内存占用、 $O(1)$ 时间复杂度的插入和删除操作、自动保持时

Algorithm 10 Swift 系统初始化流程

Require: 网络拓扑配置 *topology*, 仿真参数 *params***Ensure:** 初始化完成的 Swift 系统

```

1: simulator  $\leftarrow$  CreateSimulator(params.duration)
2: network  $\leftarrow$  BuildTopology(topology)
3: ConfigureQueues(network, params.queue_size)
4: env  $\leftarrow$  CreateOpenGymEnvironment()
5: RegisterCallbacks(env, network.tcp_sockets)
6: ConfigureObservationSpace(env, 15)
7: ConfigureActionSpace(env, 2) ▷ ssthresh 和 cwnd
8: agent  $\leftarrow$  CreateSwiftAgent()
9: agent.flow_states  $\leftarrow$  EmptyHashMap()
10: agent.alpha_default  $\leftarrow$  1.10
11: channel  $\leftarrow$  CreateMessageChannel()
12: ConnectEnvAndAgent(env, agent, channel)
13: simulator.Run()

```

Algorithm 11 Swift 主控制循环

Require: 环境接口 *env*, 最大迭代次数 *max_iterations***Ensure:** 控制结果序列

```

1: iteration  $\leftarrow$  0
2: flow_manager  $\leftarrow$  InitFlowStateManager()
3: while iteration < max_iterations and not env.IsDone() do
4:   obs  $\leftarrow$  env.GetObservation()
5:   socket_uuid  $\leftarrow$  obs[0]
6:   flow_state  $\leftarrow$  flow_manager.GetOrCreate(socket_uuid)
7:   UpdateFlowState(flow_state, obs)
8:   (is_congested, cong_type, severity)  $\leftarrow$  DetectCongestion(obs, flow_state)
9:   if is_congested then
10:     action  $\leftarrow$  CongestionResponse(obs, cong_type, flow_state)
11:   else
12:     UpdateAdaptiveParams(flow_state, obs)
13:     action  $\leftarrow$  FusionControl(obs, flow_state)
14:   end if
15:   env.ExecuteAction(action)
16:   iteration  $\leftarrow$  iteration + 1
17: end while

```

间局部性等优势。**每流状态字典**以 `socketUuid` 为键隔离不同 TCP 连接的 α 、BDP、拥塞事件计数、连续缩减计数和降窗后冻结计数，避免不同流之间的控制状态相互污染。

3.9.4 性能优化技术

为了提高 Swift 算法的执行效率，满足实时决策的要求，本文采用了多种性能优化技术：

(1) **延迟初始化策略**：流状态采用延迟初始化策略，只在首次访问时创建状态数据结构。

Algorithm 12 延迟初始化状态获取

```

1: function GetOrCreateFlowState(manager, socket_uuid)
2:   if socket_uuid  $\notin$  manager.flow_states then
3:     new_state  $\leftarrow$  CreateEmptyFlowState()
4:     new_state.alpha  $\leftarrow$  1.10
5:     new_state.min_rtt  $\leftarrow$   $\infty$ 
6:     new_state.max_throughput  $\leftarrow$  0
7:     new_state.consecutive_decreases  $\leftarrow$  0
8:     new_state.consecutive_increases  $\leftarrow$  0
9:     new_state.in_slow_start  $\leftarrow$  True
10:    manager.flow_states[socket_uuid]  $\leftarrow$  new_state
11:   end if
12:   return manager.flow_states[socket_uuid]
13: end function

```

(2) **增量计算优化**：吞吐量、BDP 等指标的计算采用增量方式，时间复杂度为 $O(1)$ 。

(3) **分支路径清晰化**：拥塞检测、拥塞响应、慢启动和拥塞避免分别采用独立分支，便于将丢包、ECN、超时和普通 ACK 事件映射到可解释的窗口更新路径。

(4) **有界步长更新**：拥塞避免阶段的窗口拉升、回落和利用率补偿均采用有界步长，避免单个 ACK 事件造成窗口突变。

(5) **降窗后冻结**：显式降窗后冻结后续 4 个 ACK 事件中的窗口增长，减少窗口刚缩减后立即反弹造成的二次排队。

3.9.5 OpenGym/ZeroMQ 同步交互路径

TcpSwift 当前实验采用 ns3-gym 提供的 OpenGym/ZeroMQ 同步请求-响应路径：ns-3 仿真进程在 TCP 回调处生成观测，Python 决策进程返回慢启动阈值和拥塞窗口动作。该路径便于逐 ACK 解释窗口决策、复现实验数据并与 `tcp_swift.py` 中的真实策略保持一致。由于 OpenGym 路径依赖同步消息交互，本文实验未将该路径与 MTP 并行仿真结合，也不报告 MTP 加速数据。

3.9.6 正确性保证机制

Swift 实现包含参数边界检查、跨进程动作时效性校验和状态一致性检查三类正确性保证机制。三者共同保证：即使 Python 决策进程返回了不合理的动作，仿真中的 TCP 连接仍能维持协议语义的正确性。

(1) **跨进程动作的时效性校验**。OpenGym 采用请求-应答模式，观测的采集时刻与动作的应用时刻之间存在一个消息往返间隔。在此间隔内协议栈的状态可能已经改变——最关键的情形是重传定时器超时。若把基于超时前观测计算出的拥塞窗口应用到已经进入 CA_LOSS 的连接上，就会用一个偏大的窗口覆盖协议栈自身的丢包恢复决策，破坏 Reno 语义并可能立即触发第二轮丢包。因此 tcp-swift-env.cc 在 CongestionStateSet 回调中检测到新状态为 CA_LOSS 时，主动丢弃尚未生效的待应用窗口（清除 m_hasPendingCwnd 标志），使该次决策失效而不是延迟生效。

(2) **动作边界约束**。所有返回的窗口值在应用前被夹紧到 $[4 \times MSS, \max(4 \times BDP, 200 \times MSS)]$ 区间，慢启动阈值同样受下界约束。该约束的意义不止于“防御非法输入”：BDP 估计在带宽突降或跨流量抢占时可能暂时偏大， $4 \times BDP$ 的上界把这种偏差造成的窗口过冲限制在有界范围内；而 $200 \times MSS$ 的兜底上界保证在 BDP 尚未建立的连接初期窗口仍可正常增长。

(3) **状态一致性检查**。每次决策后检查慢启动阈值与拥塞窗口的相对关系，保证不会出现阈值低于窗口下界等不自洽组合；在检测到观测字段异常（如 segSize 为零）时回退到保守默认值而非直接参与运算。

(4) **实验可复现性**。批量实验脚本 main.py 支持 --num-seeds 参数，对同一（场景，协议）组合以不同的 RngRun 重复运行，产物按 < 场景 >_< 协议 >_s< 种子 > 命名，统计阶段按种子求均值。该机制用于降低单次随机实现带来的偶然性，是第四章讨论结论稳健性的前提条件。

3.10 本章小结

本章详细介绍了 Swift 算法的设计与实现，包括：

(1) 系统架构：由网络仿真模块、拥塞控制环境模块、智能决策模块和进程间通信模块组成，实现了基于 ns-3 和 OpenGym 的端到端强化学习拥塞控制框架。

(2) 11 维观测空间：涵盖连接标识、时间信息、窗口状态、传输指标、延迟测量、回调类型和拥塞控制状态等多个维度，为强化学习智能体提供完整的环境感知能力。

(3) 多信号融合拥塞检测：采用两级优先级机制。第一级在 GetSsThresh 显式降窗回调内部按 caState 与 ecnState 做三路语义判别，区分重传超时、ECN 回显驱动的 CWR 与普通快速

重传丢包；第二级在 **IncreaseWindow** 路径上巡检 ECN 状态。RTT 膨胀不作为独立降窗触发条件，仅参与参数自适应与慢启动退出判定。

(4) 差异化拥塞响应：针对不同拥塞类型采用不同的窗口保留因子（丢包 0.70、ECN 0.75、超时 0.50），慢启动阈值以 $\min(cwnd, BDP)$ 为锚定参考以避免奖励队列膨胀；并引入连续缩减保护（ $D_{max} = 3$ ）与降窗后 4 个 ACK 事件冻结机制，且连续缩减计数器仅在窗口真实增长时清零，保证冻结期内保护计数不被误复位。

(5) 自适应参数调优：根据最小 RTT 感知的 RTT 膨胀阈值、奖励信号的基线相对偏离趋势（快线 $\eta_f = 0.15$ 与慢线基线 $\eta_b = 0.02$ ，容差 $m = \max(0.25, 0.1|R_{base}|)$ ）以及连续稳定增长动态调整乘性增加因子 $\alpha \in [0.85, 1.30]$ （基准值 1.10）。基线相对判据取代了早期版本的固定绝对阈值，后者在奖励恒为正的分布下会退化为单向棘轮。

(6) 融合控制策略：BDP 由“时间窗口投递速率采样（窗口跨度 $\geq 2 \times RTT_{min}$ ）+ 容量 40 的窗口化最大值过滤”两级结构估计，取代了早期版本按单次确认计算投递速率的有偏公式；拥塞避免阶段以 $\alpha \times BDP$ 为目标，通过有界步长向目标窗口拉升或回落，并在 RTT 未膨胀时启用管道利用率感知的加性补偿；慢启动阶段以 $\max(2 \times BDP, 10 \times MSS)$ 为目标，并结合 HyStart 风格 RTT 膨胀检测退出慢启动。

(7) ECN 信号通路：瓶颈网关采用 RED 主动队列管理（ $MinTh = 0.3Q$ 、 $MaxTh = 0.9Q$ 、UseEcn 为真），并对全部四种被比较协议统一开启 ECN 协商，使 ECN 分支在仿真中真实可达且对照公平。

(8) 每流独立状态管理：为每个 TCP 连接维护独立的状态数据，支持多流并发场景下的差异化控制；结合 `--num-seeds` 多随机种子重复实验机制保证结果可复现。

这些设计共同构成了 Swift 算法的完整技术方案，为实现“高吞吐、低延迟”的设计目标奠定了基础。

第四章 实验评估

本章介绍 Swift 算法的实验评估，包括实验环境配置、评测指标定义、对比算法、实验场景设计、数据质量审计流程以及详细的实验结果分析。本章的组织逻辑是：先说明”测什么、怎么测”，再说明”哪些数据可用、为什么”，最后在经过审计的数据集上给出定量结论，并如实披露算法的适用边界。

4.1 实验环境配置

4.1.1 硬件环境

实验在以下硬件环境中进行：

- CPU: Intel Core i7-10700K @ 3.80GHz, 8 核 16 线程
- 内存: 32GB DDR4 3200MHz
- 存储: 512GB NVMe SSD
- 操作系统: Ubuntu 20.04 LTS

4.1.2 软件环境

实验使用以下软件工具：

- 网络仿真器: ns-3.40
- 强化学习框架: OpenGym (ns3-gym)
- Python 版本: Python 3.8.10
- 依赖库: NumPy 1.21.0, ZeroMQ 4.3.4, Protocol Buffers 3.17.3

4.1.3 网络拓扑与队列配置

实验采用经典的哑铃型 (Dumbbell) 网络拓扑，如图4.1所示。该拓扑包括：

- 左侧叶子节点 (发送端): n 个节点，默认 $n = 3$
- 右侧叶子节点 (接收端): n 个节点

- 两个核心路由器：R0（左侧）和 R1（右侧）
- 接入链路：连接叶子节点和路由器
- 瓶颈链路：连接两个路由器




图 4.1 哑铃型（Dumbbell）实验网络拓扑

瓶颈两侧网关安装队列规则，队列容量 $Q = \max(BDP \times n/MTU, 100)$ 个数据包按各场景的瓶颈带宽与链路时延自动定尺，下界 100 个数据包用于保证低 BDP 路径上的基本缓冲能力。

关于队列规则与 ECN 的重要说明。本章所引用的归档数据是在 `queue_disc_type` 默认值为 `ns3::PfifoFastQueueDisc` 时生成的。`PfifoFastQueueDisc` 是纯 FIFO 丢尾队列，永不设置 *CE* 码点；同时当时的 `sim.cc` 仅对 `TcpSwift` 置 `TcpSocketBase::UseEcn` 为 `On`、对其余三种协议置为 `Off`。这两项配置共同导致一个必须明确交代的后果：**在归档数据中协议栈上报的 `ecnState` 始终停留在 `ECN_IDLE`，第三章所述的 ECN 分支及其 0.75 保留因子从未被触发。**因此本章结果刻画的是 Swift 在纯丢包信号条件下的行为，ECN 机制的贡献无法由本章数据评估，相关结论一律不得归因于 ECN。

需要同时指出，“仅对 Swift 开启 ECN”这一非对称设置在归档运行中并未造成可观测偏差：由于丢尾队列不产生 *CE* 标记，开启 ECN 协商仅使数据包被标记为 *ECT*，而没有任何设备会将其改写为 *CE*，其行为与关闭 ECN 一致。该设置是一处潜在偏差源而非已实现的偏差。当前版本的 `sim.cc` 已将默认队列规则改为 `ns3::RedQueueDisc` ($MinTh = 0.3Q$ 、 $MaxTh = 0.9Q$ 、`UseEcn` 为真) 并对全部四种协议对称开启 ECN，以便后续重跑能够真正激活并公平评估 ECN 通路；相关论证见第三章第 3.1 节。

每条 TCP 流由 `BulkSendHelper` 产生持续饱和的单向长流，三条流分别在 0、100、200 ms 错开启动，以避免同步启动带来的人为同相位效应；接收端为 `PacketSink`。反向路径仅承载 ACK。

4.1.4 仿真参数

默认仿真参数配置如表4.1所示：

表 4.1 默认仿真参数

参数	取值	说明
仿真时长	20 秒	每次实验的仿真时间
叶子节点数	3	发送端和接收端各 3 个节点
MTU	1500 字节	以太网标准 MTU
TCP 段大小	1440 字节	$1500 - 20 - (20 + 20)$
收发缓冲区	16 MB	保证高 BDP 路径不受窗口通告限制
SACK	启用	<code>TcpSocketBase::Sack</code>
延迟确认	2	<code>TcpSocket::DelAckCount</code>
队列规则	PfifoFast	丢尾队列， $Q = \max(BDP \times n / MTU, 100)$ 包
ECN	仅 Swift 协商	丢尾队列不标记 CE，故 ECN 分支未触发
随机种子	单一默认种子	见第 4.1.5 节的说明

4.1.5 随机种子与重复性说明

批量实验脚本 `main.py` 提供 `--num-seeds` 参数，可对同一 (场景, 协议) 组合以不同的 `RngRun` 重复运行，产物按 `< 场景 >_< 协议 >_s< 种子 >` 命名，统计阶段按种子求算术平均。然而，本章所引用的数据集是在该多种子机制引入之前生成的：`logs/comparison/` 与 `logs/comparison-udp/` 下的全部产物均不带 `_s< 种子 >` 后缀，即每个 (场景, 协议, 设置) 三元组仅对应一次仿真运行。

如实说明这一点是必要的：单次运行意味着本章报告的差异不附带跨种子置信区间，因此本章在解释结论时遵循两条自律规则。第一，只把量级明确、机理可解释的差异作为结论——例如零丢包与非零丢包的定性差异、微秒级 RTT 场景中数量级级别的排队延迟差异、以及 GEO 链路上数十个百分点的吞吐量差异；对于百分之零点几量级的吞吐量差异，本章只报告”等价”而不解读方向。第二，凡属”单点数值恰好更优”性质的观察，一律不写入结论性论述。`ns-3` 的离散事件仿真在给定 `RngRun` 下完全确定，因此上述单次运行结果是可精确复现的，但其对随机实现的稳健性有待后续多种子重跑确认，该项已列入第五章的后续工作。

4.1.6 UDP Burst 干扰流量与实验矩阵

在真实的端到端传输路径上，共享瓶颈链路普遍同时承载突发性的非响应式 UDP 流量——移动终端的视频流与实时会议、远程过程调用、运维巡检探测、游戏控制信令等都属于此类。这些跨流量不服从 TCP 的拥塞反馈环，会与 TCP 长流竞争瓶颈队列容量并放大 RTT 抖动，是异构终端共享接入链路时的常态而非例外。为了系统性评估 Swift 在此类干扰下的鲁

棒性，仿真器contrib/opengym/examples/swift-tcp/sim.cc 在哑铃拓扑的发送端 0 与接收端 0 之间提供了可选的 UDP Burst 旁路通道，由命令行参数 enable_udp_burst（默认 false）控制启停。启用时，该通道在瓶颈链路上并发启动一路 1024 字节的 OnOff UDP 源，数据率 800 Mbps，占空比 50%（On 0.5 s / Off 0.5 s），与 TCP 长流共享同一瓶颈队列。由此构成两类严格对照的实验设置：

- **纯 TCP 设置（无 UDP Burst）**：enable_udp_burst=false，瓶颈链路仅承载 3 条 TCP 长流，产物位于logs/comparison/，用于评估稳态性能。
- **UDP Burst 干扰设置**：enable_udp_burst=true，在同一瓶颈并发运行 800 Mbps、50% 占空比的 UDP 突发源，产物位于logs/comparison-udp/，用于评估跨流量鲁棒性。

两类设置共享完全相同的场景拓扑、瓶颈带宽、接入带宽、链路时延、队列调度策略与随机种子，仅 enable_udp_burst 取值不同，因而构成严格的 A/B 对照。第 4.6 节的主实验结果基于纯 TCP 设置；跨流量鲁棒性结果在第 4.8 节专题报告。需要注意的是，UDP 流量本身在统计时被排除在指标之外（见第 4.2 节），因此“吞吐量下降”衡量的是 TCP 长流在竞争下实际获得的容量份额，而非瓶颈链路的总利用率。

4.2 评测指标

本文全部指标均由 ns-3 FlowMonitor 模块采集的逐流统计量导出。指标定义中有一处方法学要点必须先行澄清，否则数值不可比。

4.2.1 指标的流向界定

哑铃拓扑上每条 TCP 连接在 FlowMonitor 中登记为两条流：前向流（ $10.1.x \rightarrow 10.2.x$ ）承载应用数据，反向流（ $10.2.x \rightarrow 10.1.x$ ）仅承载纯 ACK。二者的统计特征截然不同：前向流经过被填满的瓶颈队列，其单包时延包含完整的排队分量；反向流的 ACK 包极小、几乎不排队，其时延近似等于路径传播时延。

若把两个方向不加区分地纳入聚合，则平均时延退化为 $(\bar{D}_{data} + D_{prop})/2$ ，即被系统性地压低近一半；吞吐量则被额外计入约 1.7% 的 ACK 速率。本文因此**仅在前向数据流上定义全部指标**，并由logs/summary/kpi_forward.csv 给出重新导出的结果。该文件是本章所有数值的唯一数据源，其每一行都记录了对应的原始.flowmonitor 产物路径以便逐项溯源。第 4.4.2 节说明这一修正相对既有汇总文件的影响。

4.2.2 吞吐量 (Throughput)

吞吐量定义为单位时间内成功接收的数据量。单条前向流的吞吐量按该流自身的活跃区间归一：

$$Throughput_i = \frac{rxBytes_i \times 8}{t_{lastRx,i} - t_{firstTx,i}} \quad (\text{单位: Mbps}) \quad (4.1)$$

本文报告 3 条并发前向流的聚合吞吐量，以反映 TCP 总体获得的瓶颈容量份额：

$$AggregateThroughput = \sum_{i=1}^n Throughput_i \quad (4.2)$$

由于三条流错开启动、各自的活跃区间略有差异，聚合值可能略高于瓶颈标称带宽（本文数据中最大超出 0.5%）。该偏差对四种协议同向且同量级，不影响协议间比较。

4.2.3 延迟 (Latency)

延迟定义为数据包从发送端到接收端的单向端到端传输时间。单条前向流的平均时延由 FlowMonitor 的 delaySum 除以 rxPackets 得到，场景级指标取三条前向流的算术平均：

$$AverageLatency = \frac{1}{n} \sum_{i=1}^n \frac{delaySum_i}{rxPackets_i} \quad (\text{单位: ms}) \quad (4.3)$$

延迟包含传播延迟和排队延迟两个成分。传播延迟由链路配置决定、不可压缩，本文在场景表中一并给出各场景的基线单向传播时延，读者可据此分离出排队分量：排队延迟约等于平均时延减去基线单向传播时延。这一分解对解释结果至关重要——在微秒级 RTT 场景中排队占端到端时延的绝大部分，而在 GEO 卫星场景中传播时延占绝对主导，同样幅度的排队优化在两类场景中的相对效果相差两个数量级。

4.2.4 丢包率 (Loss Rate)

丢包率定义为前向流丢失数据包总数与发送数据包总数的比值：

$$LossRate = \frac{\sum_i PacketsLost_i}{\sum_i PacketsSent_i} \times 100\% \quad (4.4)$$

4.2.5 公平性 (Fairness)

在多流场景下，公平性衡量各流之间带宽分配的均衡程度。本文采用 Jain 公平性指数^[22]，在三条并发前向流的吞吐量上计算：

$$JainIndex = \frac{(\sum_{i=1}^n x_i)^2}{n \cdot \sum_{i=1}^n x_i^2} \quad (4.5)$$

其中 x_i 是第 i 个前向流的吞吐量， $n = 3$ 。取值范围为 $[1/n, 1]$ ，越接近 1 表示分配越均衡。

4.3 对比算法

本文将 Swift 算法与以下三种主流拥塞控制算法进行对比。三者分别代表基于丢包的经典 AIMD、基于丢包的高 BDP 优化以及基于带宽/时延模型的速率控制，共同覆盖了当前实际部署中的主要设计范式。

4.3.1 TCP NewReno

TCP NewReno^[1] 是经典的基于丢包拥塞控制算法，采用 AIMD（加性增乘性减）策略，是 RFC 6582 定义的标准算法之一。无丢包时每个 RTT 增加一个 MSS，检测到丢包时窗口减半。它构成了“拥塞信号滞后”这一问题的基准参照：窗口只有在缓冲区实际溢出后才收缩。

4.3.2 TCP CUBIC

TCP CUBIC^[2] 是 Linux 自 2.6.19 版本以来的默认拥塞控制算法。CUBIC 采用三次函数模型调整窗口，其增长与 RTT 无关，因此在高带宽延迟积网络中收敛更快，但代价是在瓶颈附近维持更长时间的高窗口，排队驻留通常比 NewReno 更深。

4.3.3 TCP BBR

TCP BBR^[4] 是 Google 于 2016 年提出的基于瓶颈带宽与最小 RTT 估计的拥塞控制算法，以 BDP 为目标调整发送速率。BBR 理论上能同时逼近高吞吐与低时延，但其周期性带宽探测在极短 RTT 路径和存在非响应式跨流量时容易失真。本文在第 4.4.2 节中将说明，BBR 在部分微秒级 RTT 高速场景中的表现属于仿真实现层面的退化而非策略层面的结果，因此这些数据点被排除在对照之外。

4.4 实验场景设计

4.4.1 场景矩阵与覆盖范围

完整实验矩阵包含 36 个网络场景，覆盖近端高速低 RTT 链路、收敛比受限的共享链路、无线局域网接入、蜂窝移动接入、城域与跨域广域网以及卫星通信；每个场景在两类实验设置下各运行四种协议，共 $36 \times 4 \times 2 = 288$ 次仿真。场景的瓶颈带宽跨越 10 Mbps 至 100 Gbps 共四个数量级，基线往返时延跨越 $8 \mu\text{s}$ 至 640 ms 共五个数量级，用以检验同一套控制参数在异构路径条件下的适应能力。

原始矩阵中并非所有场景都能支撑严格的四协议对照。第 4.4.2 节说明审计规则，审计后可用于跨协议比较的场景为：纯 TCP 设置 19 个、UDP Burst 设置 15 个（且后者是前者的子集）。表 4.2 给出这 19 个场景的配置。

表 4.2 审计后保留的 19 个对照场景配置

编号	场景名称	网络类型	瓶颈 (Mbps)	基线 RTT(ms)	Burst 对照
S1	intra_rack_10g	近端高速	10000	0.008	是
S2	intra_rack_25g	近端高速	25000	0.008	是
S3	leaf_spine_20g	近端跨层	20000	0.018	是
S4	asymmetric_high	非对称接入	1000	0.024	是
S5	congested_heavy	重度收敛	1000	0.018	是
S6	symmetric_low	对称千兆	1000	0.060	是
S7	dc_500m	500M 共享	500	0.018	是
S8	dc_100m	100M 共享	100	0.018	是
S9	cross_dc_wan	跨域 WAN	1000	10.040	—
S10	wan_metro	城域 WAN	1000	4.400	是
S11	wifi_ac	WiFi 11ac	400	14.000	—
S12	wifi_ax	WiFi 11ax	600	10.000	—
S13	wifi_n	WiFi 11n	50	28.000	是
S14	wifi_legacy	WiFi 传统	10	60.000	是
S15	nr_5g_embb	5G eMBB	500	14.000	—
S16	nr_5g_edge	5G 边缘	100	28.000	是
S17	lte_good	LTE 良好	50	60.000	是
S18	lte_poor	LTE 弱覆盖	10	140.000	是
S19	satellite_geo	GEO 卫星	10	640.000	是

按路径特征，这 19 个场景可归为六类。*S1–S3*（近端高速低 RTT）的瓶颈带宽为 10–25 Gbps、基线 RTT 在 $10 \mu\text{s}$ 量级，排队延迟占端到端时延的绝大部分，是检验排队抑制能力的最敏感场景。*S4–S8*（收敛比受限的共享链路）的瓶颈为 100 Mbps–1 Gbps、基线 RTT 仍在数十微秒量级，其特点是缓冲区相对 BDP 显著偏深，因此是检验“窗口是否长期驻留在队列中”的关键场景。*S9–S10*（广域网）引入毫秒级传播时延，考察 BDP 估计在长路径上的稳定性。*S11–S14*（无线局域网接入）覆盖从 600 Mbps 到 10 Mbps 的四档速率，链路时延从 10 ms 到 60 ms 递增，模拟笔记本与移动终端在不同代际 WiFi 下的接入条件。*S15–S18*（蜂窝移动接入）覆盖 5G eMBB、5G 边缘、LTE 良好与 LTE 弱覆盖，是异构终端场景中路径条件差异最剧烈的一

组。*S19* (*GEO* 卫星) 的基线 RTT 达 640 ms, 单次重传的代价为一个完整 RTT, 是检验“零丢包能否转化为吞吐优势”的判别性场景。

4.4.2 数据质量审计与排除规则

在引用任何数值之前, 本文对 288 次仿真的产物执行了系统性审计, 逐项检查流数完整性、吞吐量与瓶颈带宽的物理相容性、时延是否低于基线传播时延、丢包率与 Jain 指数的取值域、场景配置能否回溯到仿真驱动, 以及 `.flowmonitor` 产物与汇总文件的一致性。审计确认全部 288 次运行均包含完整的 3 条前向流, 无空文件或格式损坏, 无时延低于传播下界的物理不可能值, 无 Jain 指数越界, 也无吞吐量以不可解释的方式超过瓶颈带宽。但审计同时发现四类必须处理的问题, 全部记录于 `logs/error.txt`。

规则 A——指标定义修正。既有汇总文件 `logs/plots/summary.csv` 与 `logs/plots-udp/summary.csv` 在聚合时未区分流向, 把反向 ACK 流一并计入时延平均与吞吐求和 (机理见第 4.2.1 节)。该缺陷对四种协议同向作用且在场景内部是单调变换, 因此协议间的排序未被破坏, 但绝对数值不可作为“数据路径时延”引用。处理方式是原始 `.flowmonitor` 产物重新导出仅含前向流的指标, 写入 `logs/summary/kpi_forward.csv`, 本章全部数值改用该文件。

规则 B——同一场景内混用了两个仿真器修订版本。审计发现产物的接收端口号存在 5000 与 50000 两种取值, 对应 `sim.cc` 的两个不同修订。当同一场景下不同协议的产物来自不同修订时, 跨协议差异中混入了仿真器变更的影响, 比较不再受控。此类情形共 27 个 (设置, 场景) 组合, 其涉及的场景整体排除, 包括 `congested_light`、`congested_medium`、`cross_pod_10g`、`cross_pod_20g`、`dc_100g`、`leaf_spine_50g`、`mixed_large_flow`、`mixed_small_flow`、`oversub_4to1_10g`、`oversub_2to1_25g`、`oversub_2to1_50g`、`oversub_4to1_40g`、`rdma_like_25g`、`rdma_like_50g`、`wan_longhaul`, 以及仅在 UDP Burst 设置下失配的 `cross_dc_wan`、`nr_5g_embb`、`wifi_ac`、`wifi_ax`。这正是纯 TCP 设置保留 19 个场景而 Burst 设置仅保留 15 个的原因。

规则 C——重复的场景配置。审计发现 `dc_oversub_10to1` 与 `congested_heavy` 在数据生成时的链路参数完全相同 (10 Gbps 接入/1 Gbps 瓶颈/2 μ s/5 μ s), `satellite_leo` 与 `lte_good` 亦完全相同 (100 Mbps/50 Mbps/5 ms/20 ms); 由于 ns-3 在相同配置与相同种子下完全确定, 两组产物分别逐字节相同。处理方式是各保留一个 (保留 `congested_heavy` 与 `lte_good`), 另一个作为冗余排除。须特别指出: `satellite_leo` 这一名称与其实际链路参数不符——它被配置为一条 50 Mbps、单向 30 ms 的链路, 并不具备 LEO 卫星的时延与带宽特征。因此本文不基于当前数据集提出任何关于 LEO 卫星场景的结论; 卫星相关结论仅来自 GEO 场景 (*S19*), 其 640 ms 基线 RTT 与 10 Mbps 瓶颈确实对应地球同步轨道链路的

典型参数。

规则 D——BBR 基线在微秒级 RTT 高速路径上的退化。在五个微秒级 RTT 高速场景 (intra_rack_10g, intra_rack_25g, rdma_like_25g, rdma_like_50g 与 dc_100g) 中, BBR 的聚合吞吐量仅约 2 Mbps, 即瓶颈带宽的 0.01%–0.02%。该数值不能解释为“BBR 策略在此类路径上的表现”: 在 $8\mu\text{s}$ 级基线 RTT 下, ns-3.40 的 BBR 实现所依赖的最小 RTT 测量与 pacing 时间粒度已与 RTT 本身同阶, 带宽估计因而失去意义, 属于仿真实验层面的失效。此类数据点被排除, 其所在场景 (在保留集合内为 S1 与 S2) 因此降级为三协议对照。这一处理与 Hock 等^[11] 报告的 BBR 在极短 RTT 下的测量噪声问题方向一致, 但本文不将其作为 BBR 的算法缺陷证据, 仅作为不可用数据点处理。

证据边界。还有一项范围限制必须前置声明: logs/ 下的全部产物均生成于本文算法实现的 v3.0.0 修订之前。该修订替换了投递速率估计器 (由单次确认公式改为时间窗口差分)、启用了 RED 的 ECN 标记通路与全协议对称 ECN、修正了 ECE/CWR 事件的信号归类, 并把奖励自适应改为基线相对判据 (详见第三章与仓库 CHANGELOG.md)。因此本章的定量结果刻画的是修订前实现的行为, 其中最需要注意的一项是 ECN 分支在归档数据中从未被触发 (详见第 4.1.3 节), 故本章不得将任何结果归因于 ECN。这一点对结果解读有直接影响: S9 (跨域 WAN) 中 Swift 吞吐量的回落, 正是修订前投递速率估计器在长 RTT 路径上系统性低估带宽所留下的痕迹, 其机理已在第三章第 3.6.1 节给出定量推导。本章在相应位置逐一标注该关联, 并将全矩阵重跑列为后续工作。

4.5 实验方法论

4.5.1 实验设计原则

本文的实验设计遵循以下原则: (1) **对照实验原则**——四种算法在完全相同的拓扑、链路参数、队列规则、缓冲区配置与随机种子下运行; 归档运行中 ECN 仅对 Swift 协商, 但因丢尾队列不产生 CE 标记, 该非对称设置未造成可观测偏差 (见第 4.1.3 节); (2) **变量控制原则**——场景之间仅改变带宽与时延, 跨流量开关构成唯一的第二自变量; (3) **数据可溯源原则**——每个被引用的数值都能定位到 logs/summary/kpi_forward.csv 中的具体行及其对应的原始产物文件; (4) **排除留痕原则**——每一次数据排除都在 logs/error.txt 中记录时间、来源、场景、协议、理由与受影响指标, 不作静默丢弃; (5) **场景多样性原则**——覆盖跨越四个带宽数量级与五个时延数量级的路径条件。

4.5.2 统计分析方法

实验结果采用描述性统计与相对比较进行分析。对于吞吐量与时延,报告 Swift 相对 NewReno/CUBIC 两者均值的百分比差异;选择这两个协议作为参照基准,是因为它们是当前实际部署中的主流算法,且在本文保留的场景中均未出现实现层面的退化。跨流量鲁棒性分析采用配对比较:对同一 (场景, 协议) 在两种设置下的指标做比值,从而消除场景间绝对量级差异的影响。受第 4.1.5 节所述单种子限制,本章不报告标准差与置信区间。

4.6 实验结果分析

本节报告纯 TCP 设置 (无 UDP Burst) 下的稳态性能,数据源为logs/summary/kpi_forward.csv 中 Setting=tcp_only 的记录,覆盖表4.2的 19 个场景。跨流量鲁棒性另见第 4.8 节。

4.6.1 吞吐量对比

表4.3汇总 19 个场景的聚合前向吞吐量。最后一列报告 Swift 相对 NewReno/CUBIC 均值的差异。S1、S2 的 BBR 列按规则 D 排除。

表 4.3 聚合前向吞吐量对比 (Mbps)

场景	Swift	NewReno	CUBIC	BBR	vs NR/CU
S1	10038.0	10038.0	10038.0	–	+0.00%
S2	25095.0	25095.0	25095.0	–	+0.00%
S3	20059.2	20059.2	20059.1	7414.7	+0.00%
S4	1003.6	1003.6	1003.6	510.2	+0.00%
S5	1003.6	1003.6	1003.6	507.9	+0.00%
S6	1003.6	1003.6	1003.6	482.8	+0.00%
S7	501.8	501.8	501.8	257.1	+0.00%
S8	100.4	100.4	100.4	51.5	+0.00%
S9	709.7	998.4	1000.0	1001.5	–28.97%
S10	1000.3	1001.7	1002.3	1005.0	–0.17%
S11	398.7	398.9	399.7	398.9	–0.16%
S12	598.4	599.4	600.3	600.9	–0.24%
S13	49.9	49.8	49.9	48.9	+0.08%
S14	9.9	9.9	9.9	9.8	+0.00%
S15	497.7	498.5	499.5	499.9	–0.27%
S16	99.6	99.3	99.6	98.8	+0.14%
S17	49.5	49.2	49.4	46.3	+0.29%
S18	9.8	9.8	9.8	9.3	+0.20%
S19	8.6	5.6	7.6	2.8	+29.85%

结果呈现三种清晰不同的模式。

饱和等价 (S1–S8、S10–S18, 共 17 个场景)。在这 17 个场景中, Swift 与 NewReno/CUBIC 的吞吐量差异全部不超过 0.3%, 最大偏差为 S15 的 –0.27%; 在 S1、S2 与 S4–S8 这七个场

景中，三者的聚合吞吐量在报告位数上完全一致，S3 的差异也仅为 CUBIC 低 0.1 Mbps。这一等价性本身是有意义的结论：它说明 Swift 为压低排队延迟所付出的窗口保守化代价，并未换来管道利用率的损失。当瓶颈被三条长流持续填满时，链路容量而非窗口策略成为约束，此时算法的差异只体现在队列驻留深度上——这正是下一小节的主题。

长 RTT 链路上的吞吐优势 (S19)。在 GEO 卫星场景中，Swift 聚合吞吐量为 8.6 Mbps，相对 NewReno (5.6 Mbps)、CUBIC (7.6 Mbps)、BBR (2.8 Mbps) 分别提升 52.8%、12.9% 与 205.0%，相对 NewReno/CUBIC 均值提升 29.85%。该优势的机理是可判定的：S19 的基线 RTT 为 640 ms，单次丢包所触发的重传至少花费一个完整 RTT 才能恢复，而恢复期内窗口已被乘性缩减；因此在长 RTT 链路上，丢包率对有效吞吐量的边际影响远大于短 RTT 链路。表 4.5 显示该场景中 NewReno 丢包 0.59%、CUBIC 丢包 1.26%、BBR 丢包 9.83%，而 Swift 为零，吞吐量差异与丢包差异在方向和量级上完全对应。

跨域 WAN 场景的吞吐回落 (S9)。在 cross_dc_wan 中，Swift 聚合吞吐量 709.7 Mbps，相对 NewReno/CUBIC 均值回落 28.97%，是本文观察到的最显著负面结果，必须如实报告。同一场景中 Swift 的时延为四者最低 (5.04 ms，见表 4.4) 且丢包为零，说明窗口偏小而非拥塞失控。结合第三章第 3.6.1 节的推导，该现象与修订前投递速率估计器的偏差完全吻合：该估计器把单次确认字节数除以整个 RTT，低估倍数约等于每 RTT 的确认个数，在 10 ms 基线 RTT、1 Gbps 瓶颈的路径上这一倍数可达数百，BDP 估计随之崩塌， $\alpha \times BDP$ 目标窗口长期低于实际需要，窗口被压在 $\max(4 \times BDP, 200 \times MSS)$ 退化为常量后的 $200 \times MSS$ 兜底上界附近，聚合吞吐量因而被锁定在约 $3 \times 200 \times MSS / RTT \approx 688 \text{ Mbps}$ 的水平，与实测的 709.7 Mbps 相差约 3%。v3.0.0 已将该估计器替换为时间窗口差分形式，其效果需在全矩阵重跑后验证。

关于 BBR：在 S4–S8 这五个共享链路场景中，BBR 的吞吐量约为其他三者的一半 (48%–51%)，在 S3 中为 37% 利用率；而在 S10–S18 的中低速接入场景中与其他协议接近。这一模式与 BBR 在浅缓冲、短 RTT 条件下的已知行为一致。S1、S2 的 BBR 数据点按规则 D 排除。

4.6.2 延迟对比

表 4.4 汇总 19 个场景的平均单向前向时延。最后一列报告 Swift 相对 NewReno/CUBIC 均值的变化，负值表示降低。读者可结合表 4.2 的基线 RTT 列分离排队分量。

时延结果具有强烈的场景依赖性，且这种依赖性的分界线是清晰可解释的：**Swift 在瓶颈带宽较高、缓冲区相对 BDP 不过深的路径上显著降低时延，而在低速率、深缓冲路径上以时延为代价换取零丢包。**

显著优势区间 (S1–S3、S9–S12、S15)。在近端高速低 RTT 场景中，基线单向传播时延仅 4–9 μs ，NewReno/CUBIC 的 3.8–4.5 ms 时延几乎全部是排队分量。Swift 把时延压到 0.28–0.71 ms，降幅 83.3%–93.1%，而吞吐量与两者完全一致。以 S2 为例：NewReno/CUBIC 的排

表 4.4 平均单向前向时延对比 (ms)

场景	Swift	NewReno	CUBIC	BBR	vs NR/CU
S1	0.71	3.94	4.51	—	−83.3%
S2	0.28	3.79	4.39	—	−93.1%
S3	0.35	3.81	4.44	0.01	−91.6%
S4	6.97	5.87	5.49	0.13	+22.7%
S5	6.97	5.87	5.49	0.13	+22.7%
S6	6.95	5.94	5.52	0.07	+21.3%
S7	10.72	6.98	6.67	0.16	+57.0%
S8	35.42	16.25	15.48	1.37	+123.3%
S9	5.04	8.88	9.56	10.73	−45.3%
S10	4.93	7.02	7.18	5.26	−30.5%
S11	10.86	12.10	13.02	16.12	−13.6%
S12	6.93	9.56	10.17	12.28	−29.8%
S13	78.16	38.22	39.76	73.95	+100.4%
S14	242.23	135.63	164.09	111.73	+61.6%
S15	7.33	11.48	12.43	17.38	−38.7%
S16	44.69	26.63	29.22	64.42	+60.0%
S17	80.61	50.51	70.10	66.80	+33.7%
S18	310.79	174.19	188.00	172.22	+71.6%
S19	391.42	365.15	420.22	612.08	−0.3%

队分量约 3.8–4.4 ms，Swift 的排队分量约 0.28 ms，下降超过一个数量级。

机理在于两类算法对“窗口该停在哪里”给出了不同答案。NewReno 与 CUBIC 在拥塞避免阶段单调增窗，直到丢包才收缩，因此其稳态在途数据量由缓冲区容量决定——缓冲区越深，稳态排队越深，这是丢包驱动算法的结构性特征。Swift 则把窗口约束在 $\alpha \times BDP$ 目标附近：高于目标时按超出量的一半逐个 ACK 回落，低于目标时以 $\max(\gamma \times MSS, MSS, gap/16)$ 有界拉升，并受 $\max(4 \times BDP, 200 \times MSS)$ 上界约束。由于这些约束都以路径能力而非缓冲区容量为参照，Swift 的稳态在途数据量不随缓冲区加深而增长，排队分量因而显著低于基线。同时，降窗后冻结 4 个 ACK 事件抑制了收缩后的立即反弹，避免残留队列与新注入数据叠加。需要强调的是，如第 4.1.3 节所述，归档运行中 ECN 分支从未触发，因此上述时延优势完全来自窗口层面的有界控制，与 ECN 早期预警无关。

在毫秒级传播时延的 S9–S12 与 S15 中，排队优化空间随传播占比上升而收窄，Swift 的降幅相应收敛到 13.6%–45.3%，其中 5G eMBB (S15) 为 −38.7%、WiFi 11ax (S12) 为 −29.8%、城域 WAN (S10) 为 −30.5%。

时延代价区间(S4–S8、S13、S14、S16–S18)。在这十个场景中 Swift 的时延高于 NewReno/CUBIC，幅度从 S6 的 +21.3% 到 S8 的 +123.3%。这些场景的共同特征是瓶颈带宽较低 (10–1000 Mbps) 而缓冲区按 $\max(BDP \times n/MTU, 100)$ 定尺时触及了 100 个数据包的下界保护，导致缓冲区容量相对 BDP 过深：以 S8 (100 Mbps、基线 RTT 18 μ s) 为例，BDP 仅约 225 字节，而 100 个数据包的缓冲区达 150 kB，二者相差近三个数量级。此时 $\alpha \times BDP$ 的目标窗口机制失去了有效约束力——由于 BDP 估计极小，窗口实际由 $200 \times MSS$ 的兜底上界主导，而该下界远大于 BDP，于是窗口稳态驻留在队列中。换言之，这一时延代价不是 α 上界过大所致，而

是”当 BDP 远小于兜底上界时，目标窗口机制被该常量旁路”这一结构性问题所致。这一诊断把优化方向从”调小 α ”修正为”使兜底上界与 BDP 估计相协调”，相关讨论见第五章。

传播主导区间 (S19)。GEO 卫星场景的基线单向传播时延为 320 ms，占端到端时延的 80% 以上，排队优化对总时延的影响被稀释。Swift 时延 391.42 ms，与 NewReno/CUBIC 均值 (392.69 ms) 基本持平 (−0.3%)，而 BBR 因高丢包引发的重传等待达 612.08 ms。

4.6.3 丢包率与公平性对比

表4.5汇总丢包率与 Jain 公平性指数。

表 4.5 丢包率 (%) 与 Jain 公平性指数对比

场景	丢包率 (%)				Jain 公平性指数			
	Swift	NR	CUBIC	BBR	Swift	NR	CUBIC	BBR
S1	0.00	0.01	0.00	–	1.000	1.000	1.000	–
S2	0.00	0.00	0.01	–	1.000	1.000	1.000	–
S3	0.00	0.00	0.01	0.00	1.000	1.000	1.000	1.00
S4	0.00	0.00	0.00	0.00	1.000	1.000	1.000	1.00
S5	0.00	0.00	0.00	0.00	1.000	1.000	1.000	1.00
S6	0.00	0.00	0.00	0.00	1.000	1.000	1.000	0.68
S7	0.00	0.01	0.00	0.00	1.000	1.000	1.000	0.69
S8	0.00	0.07	0.02	0.00	1.000	1.000	1.000	1.00
S9	0.00	0.00	0.00	0.00	1.000	1.000	1.000	0.89
S10	0.00	0.00	0.00	0.00	1.000	1.000	1.000	0.67
S11	0.00	0.00	0.00	0.03	1.000	1.000	1.000	0.89
S12	0.00	0.00	0.00	0.01	1.000	1.000	1.000	0.89
S13	0.00	0.04	0.05	0.14	1.000	0.998	1.000	0.38
S14	0.00	0.13	2.11	0.07	0.999	0.979	1.000	0.98
S15	0.00	0.00	0.00	0.02	1.000	0.999	1.000	0.89
S16	0.00	0.01	0.02	0.08	1.000	0.986	1.000	0.39
S17	0.00	0.03	1.05	0.77	1.000	0.991	1.000	0.93
S18	0.00	0.17	1.80	1.79	1.000	1.000	0.965	0.59
S19	0.00	0.59	1.26	9.83	1.000	0.823	0.912	0.93

Swift 在全部 19 个场景中丢包率均为 0.00%，是四种协议中唯一做到这一点的算法。作为对照，NewReno 的最大丢包率为 0.59% (S19)、均值 0.058%；CUBIC 最大 2.11% (S14)、均值 0.334%；BBR 最大 9.83% (S19)、均值 0.749%，且仅在 6 个场景中达到零丢包。

零丢包并非偶然，但其成因必须归于归档运行中实际生效的机制。如第 4.1.3 节所述，当时的队列规则为丢尾队列且不产生 CE 标记，ECN 分支从未触发，因此零丢包不能归因于 ECN 早期预警；真正起作用的是窗口层面的三重约束。第一，拥塞避免阶段的窗口以 $\alpha \times BDP$ 为目标，超出目标时逐个 ACK 按超额的一半回落，因此窗口不会像丢包驱动算法那样单调增长至缓冲区溢出。第二，最终窗口被夹紧在 $\max(4 \times BDP, 200 \times MSS)$ 以内，这一上界与缓冲区容量无关，从而为在途数据量设置了独立于队列深度的硬性天花板。第三，一旦发生降窗，连续缩减保护 ($D_{max} = 3$) 与降窗后冻结 4 个 ACK 事件共同抑制了”收缩—反弹—二次排队”的振荡，使窗口不会在恢复过程中重新冲过溢出点。

值得注意的是，零丢包与第 4.6 节所述的时延代价实际上是同一现象的两面。在缓冲区相

对 BDP 过深的场景中，Swift 的窗口稳定在一个“足以填满队列但不足以溢出队列”的水平：填满带来了排队时延，不溢出带来了零丢包。这一解释同时说明了为何两项指标在场景维度上高度反相关——S8 的时延抬升最大 (+123.3%)，而其丢包率与 NewReno 的 0.07%、CUBIC 的 0.02% 相比同样是零。相比之下，NewReno 与 CUBIC 必须以周期性丢包为代价把队列清空，因而在时延统计上“受益”于丢包。

关于 ECN 机制的实际价值，本章数据无法给出评价。第三章从信号时序角度论证了 ECN 应当能在队列溢出前提供更早的收缩触发，从而有可能在保持零丢包的同时降低稳态队列水位——即缓解上述权衡。该假设的检验需要在启用 RED 标记与对称 ECN 的条件下重跑全矩阵，属于后续工作。

公平性方面，Swift 在 18 个场景中 Jain 指数为 1.000，在 S14 为 0.999，是四者中最均衡的；NewReno 均值 0.988（最低 0.823，出现在 S19）、CUBIC 均值 0.993（最低 0.912，同样在 S19）。BBR 的公平性明显偏低，均值 0.812，在 S13 与 S16 降至 0.38–0.39，即三条并发流的带宽分配严重倾斜。Swift 公平性稳定的结构性原因是：三条流各自独立估计 BDP 并各自向 $\alpha \times BDP$ 收敛，在共享同一瓶颈时它们的 BDP 估计趋于一致，因此目标窗口天然对称；而基于丢包的算法依赖丢包事件在流间的随机分布，长 RTT 下这种分布的方差显著放大，S19 中 NewReno 与 CUBIC 公平性的下降正源于此。

4.6.4 延迟抖动对比

表4.6汇总前向流的平均延迟抖动，反映时延的稳定性。抖动由 FlowMonitor 的 `jitterSum` 除以 $(rxPackets - 1)$ 得到。

表 4.6 平均延迟抖动对比 (ms)

场景	Swift	NewReno	CUBIC	BBR
S1	0.0036	0.0036	0.0036	—
S2	0.0014	0.0014	0.0014	—
S3	0.0018	0.0018	0.0018	0.0000
S7	0.0846	0.0711	0.0712	0.0088
S8	0.4302	0.2724	0.3549	0.0563
S10	0.0357	0.0348	0.0356	0.0024
S12	0.0199	0.0452	0.0591	0.0042
S15	0.0240	0.0462	0.0674	0.0053
S16	0.4084	0.1734	0.2673	0.0597
S19	1.3180	1.6995	1.6750	1.3823

抖动结果与时延结果同向：在 Swift 降低时延的场景中抖动同样降低（S12 的 0.0199 ms 对 NewReno 的 0.0452 ms、S15 的 0.0240 ms 对 0.0462 ms、S19 的 1.3180 ms 对 1.6995 ms），在 Swift 时延偏高的场景中抖动也相应偏高（S8、S16）。这一同向性说明抖动差异主要来自队列长度的稳态水位而非控制回路的震荡：稳态队列越浅，包间排队时间的方差越小。在近端高速低 RTT 场景中四种协议的抖动均在 0.004 ms 以下，差异不具实质意义。

4.7 深入分析

4.7.1 场景分类讨论

按 Swift 相对基线的表现, 19 个场景可分为三类。这一分类的价值在于其分界线由路径的 BDP 与缓冲区容量之比决定, 因而具有可外推的预测力。

4.7.1.1 A 类——排队主导且缓冲区与 BDP 匹配 (S1–S3、S9–S12、S15)

该类场景的共同特征是瓶颈带宽较高, 按 BDP 定尺的缓冲区容量未触及 100 个数据包的下界保护, 因此 $\alpha \times BDP$ 目标窗口是窗口的实际约束者。Swift 在该类场景中同时实现三项目标: 吞吐量与 NewReno/CUBIC 等价 (差异 $\leq 0.3\%$, S9 除外)、时延降低 13.6%–93.1%、丢包为零。

以 S2 (25 Gbps、基线 RTT $8\mu s$) 为代表分析机理。NewReno 与 CUBIC 在拥塞避免阶段持续增窗直至队列溢出, 其稳态在途数据量由缓冲区容量决定, 平均排队时延 3.8–4.4 ms。Swift 的窗口则以 $\alpha \times BDP$ 为目标、并受 $\max(4 \times BDP, 200 \times MSS)$ 上界约束; 在该场景中 $4 \times BDP$ 构成有效上界, 因此窗口随路径能力而非缓冲区深度确定, 稳态排队时延降至约 0.28 ms。关键在于吞吐量未受损失: 窗口虽被约束在较低水位, 但该水位仍足以覆盖路径的 BDP , 管道始终保持填充, 且零丢包意味着没有任何重传恢复带来的管道空隙, 因此吞吐量差异为 0.00%。这构成了“以路径能力而非缓冲区容量确定窗口、从而在不牺牲利用率的前提下压低队列驻留”的完整证据链。

S9 是该类中的例外, 其吞吐回落已在前节归因于修订前的投递速率估计器偏差, 机理独立于场景分类。

4.7.1.2 B 类——缓冲区相对 BDP 过深 (S4–S8、S13、S14、S16–S18)

该类场景的瓶颈带宽为 10–1000 Mbps, 按 BDP 计算的缓冲区需求远小于 100 个数据包的下界, 因此实际缓冲区容量相对 BDP 过深。同时, 由于 BDP 估计值极小, Swift 的窗口被 $200 \times MSS = 288\text{ kB}$ 的兜底上界主导而非被 $\alpha \times BDP$ 约束。

这一结构导致 Swift 在该类场景中呈现一致的权衡模式: 吞吐量与基线等价或略优 (S13 +0.08%、S16 +0.14%、S17 +0.29%、S18 +0.20%), 丢包率为零 (而 CUBIC 在 S14 达 2.11%、S17 达 1.05%、S18 达 1.80%), 但时延高出 21.3%–123.3%。从应用视角看, 这是一个真实的取舍而非单纯的缺陷: 对于要求零重传的传输 (如对尾时延敏感的短事务、不可重传的实时流), 零丢包的价值可能超过排队时延的增加; 但对于时延敏感的交互式业务, 该权衡方向并不理想。第五章据此提出使兜底上界与 BDP 估计相协调的改进方向。

4.7.1.3 C 类——传播时延主导 (S19)

GEO 卫星场景的基线 RTT 为 640 ms，传播时延占端到端时延的 80% 以上。该类场景的判别性在于：丢包的代价被 RTT 放大，因此零丢包能够直接转化为吞吐量优势。Swift 聚合吞吐量 8.6 Mbps，相对 NewReno 提升 52.8%、相对 CUBIC 提升 12.9%、相对 BBR 提升 205.0%，相对 NewReno/CUBIC 均值提升 29.85%；同时其 Jain 公平性为 1.000，而 NewReno 降至 0.823、CUBIC 降至 0.912。时延方面 Swift 与基线均值持平（-0.3%），说明该优势并非以排队为代价换取。这是本文中“多信号融合的早期拥塞感知在远距离传输场景中价值最高”这一论点的最直接证据。

4.7.2 机制有效性分析

4.7.2.1 差异化响应机制

当前实现将普通丢包、ECN 与超时分别映射为 0.70、0.75、0.50 的窗口保留因子，体现了拥塞信号语义的分层。在归档数据中，只有丢包分支（ $\rho_{loss} = 0.70$ ）与超时分支（ $\rho_{timeout} = 0.50$ ）被实际触发，因此本节只能对这两者给出实验层面的判断。

可以判断的是： $\rho_{loss} = 0.70$ 相比传统的窗口减半更为温和，而 A 类场景中吞吐量与基线完全一致、且全部场景零丢包，说明这一温和程度在有界窗口约束存在的前提下并未导致队列失控——窗口上界与目标窗口回落机制承担了主要的拥塞抑制职责，乘性递减因子只需负责丢包后的快速让出。这也解释了为何本算法能够采用高于 0.5 的保留因子而不牺牲稳定性：其稳定性来源与传统 AIMD 算法不同。

无法判断的是 ECN 分支（ $\rho_{ecn} = 0.75$ ）与 ECE/CWR 归类修正的效果。前者在归档运行中从未触发（第 4.1.3 节），后者属于 v3.0.0 变更而数据生成于修订之前。第三章已从语义层面论证：若不做该归类修正，ECN 驱动的 CWR 会被误按 $\rho_{loss} = 0.70$ 处理，ECN 的时序优势在响应环节被部分抵消。两者的定量效果均需在启用 RED 标记与对称 ECN 的重跑后确认。

4.7.2.2 连续递减保护与降窗后冻结

在连续拥塞事件中，窗口经 3 次 $\rho_{loss} = 0.70$ 收缩后约保留 $0.70^3 \approx 0.34$ 倍原窗口（若为 ECN 分支的 $\rho = 0.75$ 则约保留 0.42 倍），已完成显著退让；若继续无约束缩减，恢复需要多个 RTT，在长 RTT 链路上代价尤为高昂——S19 的一个 RTT 即为 640 ms。因此 $D_{max} = 3$ 的保护阈值在长距离场景中的意义远大于短 RTT 场景。降窗后冻结机制的效果可在 A 类场景的时延数据中间观察到：若无冻结，降窗后立即恢复增长会使残留队列与新注入数据叠加，稳态队列水位将高于观测值。

4.7.2.3 α 自适应机制

当前实现采用 $\alpha \in [0.85, 1.30]$ 、初始值 1.10，由最小 RTT 感知的动态阈值、奖励信号的基线相对偏离与连续增长趋势共同调节。与固定阈值相比，最小 RTT 感知阈值在远距离链路上容纳合理的传播时延波动，在近端与无线接入场景中保持较强的排队抑制能力。

本文不报告 α 的消融实验：logs/ 目录下没有保存固定 α 、固定 RTT 阈值或不同 α 边界的完整对照结果，任何此类数字都将是无来源的。这一自我限制也影响了对 B 类场景时延代价的归因——前节的结构性诊断（窗口被兜底上界主导）是基于 BDP 与缓冲区容量的量级计算得出的，而非基于参数扫描；其验证同样需要专门的对照实验。

4.7.3 关键参数的作用边界

本节从当前实现出发说明关键参数的作用边界，不引入未由日志支撑的参数扫描结果。需要区分参数的”设计意图”与”本章可验证的范围”：ECN 保留因子 0.75 对应早期拥塞预警下的温和但充分的退让，但在归档运行中未被触发，故属于设计意图；普通丢包保留因子 0.70 在实际丢包发生后更快释放队列压力，超时保留因子 0.50 对应最严重的拥塞或路径异常，二者均在归档运行中生效。 α 边界 $[0.85, 1.30]$ 限制拥塞避免阶段目标窗口相对 BDP 的扩张幅度。BDP 估计采用 40 个投递速率样本的窗口化最大值与全局最小 RTT 组合，在远距离与突发跨流量条件下提供估计稳定性。窗口安全区间 $[4 \times MSS, \max(4 \times BDP, 200 \times MSS)]$ 的下界保证基本传输能力、上界限制 BDP 估计陈旧时的窗口膨胀——但如 B 类场景分析所示， $200 \times MSS$ 的兜底上界在低 BDP 路径上会成为窗口的实际主导者，这是当前参数体系中最值得重新审视的一处。

4.8 UDP Burst 跨流量鲁棒性评估

共享瓶颈链路上的非响应式突发流量是异构终端接入场景中的常态。本节在第 4.1.6 节定义的 A/B 矩阵下评估 Swift 的鲁棒性，数据源为 logs/summary/kpi_forward.csv 中 Setting=udp_burst 的记录。按第 4.4.2 节的规则，可用于配对比较的场景为 15 个（表 4.2 中标注”是”的场景），S1、S2 的 BBR 列按规则 D 排除。

4.8.1 聚合鲁棒性指标

表 4.7 给出四种协议在 15 个配对场景上的聚合鲁棒性指标。 ΔT 为相对纯 TCP 设置的吞吐量下降百分比， ΔD 为平均时延增幅， ΔL 为新增丢包率，零丢包场景数统计 Burst 条件下丢包率低于 0.01% 的场景个数。

表 4.7 UDP Burst 跨流量鲁棒性聚合指标

协议	n	均值 ΔT	中位 ΔT	最差 ΔT	均值 ΔD	零丢包场景
TcpSwift	15	19.46%	23.75%	33.49%	+14.33%	15/15
TcpNewReno	15	24.14%	23.76%	64.53%	+4.32%	7/15
TcpCubic	15	21.22%	23.75%	46.25%	+3.22%	8/15
TcpBbr	13	60.93%	63.98%	90.31%	+50.78%	7/13

由表4.7可得三项结论。

第一，Swift 是唯一在全部 15 个场景中维持零丢包的算法。四种协议中，NewReno 仅在 7 个场景零丢包、CUBIC 8 个、BBR 7 个（共 13 个可比场景）。新增丢包率的最大值分别为：CUBIC +5.92 个百分点（S18，由 1.80% 恶化至 7.71%）、BBR +2.57 个百分点（S13，由 0.14% 恶化至 2.27%）、NewReno +0.46 个百分点（S14，由 0.13% 恶化至 0.59%）。CUBIC 的恶化幅度最大这一点值得注意：它在无干扰条件下已有较深的稳态队列，突发流量注入后队列更易溢出，二者叠加放大了丢包。Swift 的零丢包在跨流量条件下依然成立，说明其成因——以路径能力而非缓冲区容量确定窗口上界——不依赖于流量的平稳性：外部突发抬高了队列水位，但并未改变 Swift 自身在途数据量的天花板，因此队列的溢出裕度仍由 Swift 未占用的那部分缓冲区提供。

第二，Swift 的吞吐量回落幅度最小且最集中。均值 ΔT 为 19.46%，优于 CUBIC 的 21.22% 与 NewReno 的 24.14%，远优于 BBR 的 60.93%。更具说服力的是最差情形：Swift 的最大回落为 33.49%（S19），而 NewReno 为 64.53%、CUBIC 为 46.25%、BBR 为 90.31%。即 Swift 不仅平均表现更好，其尾部行为也更可控。BBR 的脆弱性源于其带宽探测机制——UDP Burst 在 On 期间挤占瓶颈带宽，BBR 的探测周期将该干扰误认为真实瓶颈能力从而持续低估可用带宽，形成自我强化的退化；在 S4–S7 等千兆级链路上 BBR 吞吐量下降约 89%–90%。Swift 的 BDP 估计采用 40 样本窗口化最大值滤波，对 Burst 的 On/Off 交替具有固有的低通特性：Off 期间采集到的高投递速率样本在窗口内被保留为最大值，使 BDP 估计锚定在真实瓶颈能力附近而非被 On 期间的低速率样本拖低。

第三，Swift 的时延抬升幅度高于 NewReno/CUBIC。均值 ΔD 为 +14.33%，而 NewReno 为 +4.32%、CUBIC 为 +3.22%（BBR 为 +50.78%）。这一现象与第 4.6 节 B 类场景的时延代价同源：Swift 维持零丢包意味着它不通过丢包来清空队列，因此突发流量注入的排队必须靠窗口收缩逐步排空；而 NewReno/CUBIC 在队列溢出时发生丢包，丢包本身即构成一次强制的队列清空，其时延统计因而“受益”于丢包。换言之， ΔD 与 ΔL 在这两组协议之间不是独立指标，二者的对比必须联合解读：Swift 用 14.33% 的时延抬升换取了零丢包与最小的吞吐回落。

4.8.2 配对场景逐一验证

表4.8给出 15 个配对场景的吞吐量变化与 Burst 条件下的丢包率，供逐场景核对。

表 4.8 15 个配对场景的吞吐量变化 ΔT (%) 与 Burst 丢包率 L (%)

场景	吞吐量变化 ΔT (%)				Burst 丢包率 L (%)			
	Swift	NR	CUBIC	BBR	Swift	NR	CUBIC	BBR
S1	-3.9	-3.9	-3.9	-	0.00	0.01	0.00	-
S2	-1.6	-1.6	-1.6	-	0.00	0.00	0.01	-
S3	-2.0	-2.0	-2.0	+0.2	0.00	0.00	0.01	0.00
S4	-19.7	-19.9	-19.8	-89.0	0.00	0.01	0.00	0.00
S5	-19.7	-19.9	-19.8	-88.9	0.00	0.01	0.00	0.00
S6	-20.8	-21.0	-21.0	-89.8	0.00	0.01	0.00	0.00
S7	-23.8	-23.8	-23.8	-89.1	0.00	0.02	0.00	0.00
S8	-23.8	-24.8	-23.8	-75.2	0.00	0.12	0.03	0.00
S10	-19.9	-20.0	-19.9	-28.0	0.00	0.00	0.00	0.00
S13	-24.1	-29.6	-25.6	-90.3	0.00	0.06	0.09	2.27
S14	-25.4	-33.3	-26.4	-52.5	0.00	0.59	4.00	2.64
S16	-24.0	-30.1	-25.6	-56.3	0.00	0.03	0.04	0.32
S17	-24.8	-32.9	-26.6	-64.0	0.00	0.19	2.96	0.93
S18	-25.1	-35.0	-32.2	-33.2	0.00	0.36	7.71	4.14
S19	-33.5	-64.5	-46.2	-35.9	0.00	0.18	0.40	12.34

逐场景核对可得以下具体观察。

(1) **Swift 在 14 个场景中吞吐量领先，唯一例外是 S10。**在 Burst 条件下 Swift 的绝对吞吐量在 15 个场景中的 14 个为四协议最高；S10（城域 WAN）中 Swift 为 801.1 Mbps，略低于 CUBIC 的 803.0 Mbps 与 NewReno 的 801.9 Mbps，差距 -0.17%，属于等价范围而非实质劣势。领先幅度最大的是 S19（GEO 卫星）：Swift 5.70 Mbps 对 NewReno 1.99、CUBIC 4.08、BBR 1.80 Mbps。

(2) **GEO 卫星场景的吞吐优势在跨流量下显著放大。**S19 中 Swift 相对 NewReno/CUBIC 均值的优势由无干扰时的 +29.85% 扩大到 +87.81%。放大的原因可从表中直接读出：NewReno 的吞吐量回落 64.5%、CUBIC 回落 46.2%，而 Swift 仅回落 33.5%；同时二者的丢包率在 Burst 下仍为非零（0.18% 与 0.40%），在 640 ms 的 RTT 下每次丢包都要付出一个完整 RTT 的恢复代价。这一场景是“零丢包在长距离链路上价值最高”这一论点在压力条件下的再次验证。

(3) **中低速接入场景的吞吐优势在跨流量下由等价转为领先。**在无干扰条件下，S13、S14、S16–S18 中 Swift 与基线的吞吐量差异均在 0.3% 以内；加入 Burst 后，Swift 的相对优势扩大到 +4.97%（S13）、+6.30%（S14）、+5.48%（S16）、+7.45%（S17）、+13.08%（S18）。机理是这些场景的基线协议在 Burst 下丢包率显著上升（CUBIC 在 S18 达 7.71%、S17 达 2.96%、S14 达 4.00%），重传与窗口收缩共同侵蚀了有效吞吐量，而 Swift 的零丢包使其免疫于该项损失。这说明 Swift 在 B 类场景中所付出的时延代价，在存在跨流量干扰时换来了吞吐量维度的回报。

(4) **近端高速低 RTT 场景受 Burst 影响甚微，且时延优势完整保留。**S1–S3 中四种协议的吞吐量回落均在 4% 以内，因为 800 Mbps 的 Burst 相对 10–25 Gbps 的瓶颈占比很小。Swift

相对 NewReno/CUBIC 均值的时延降幅在 Burst 条件下仍为 -82.4% (S1)、-93.0% (S2)、-91.2% (S3)，与无干扰条件下的 -83.3%、-93.1%、-91.6% 基本一致，说明有界窗口控制带来的排队抑制不因外部突发而失效。

(5) **BBR 在千兆级链路上出现系统性崩塌**。S4-S7 中 BBR 吞吐量回落 89%-90% (例如 S4 由 510.2 Mbps 降至 55.9 Mbps)，S13 回落 90.3%。该退化与其带宽探测机制在非响应式跨流量下的已知脆弱性一致。

4.8.3 鲁棒性机理分析

Swift 在 UDP Burst 下的鲁棒性源于三项机制的协同，且三者分别对应不同的失效模式。第一，**以路径能力为参照的窗口上界** ($\max(4 \times BDP, 200 \times MSS)$) 配合目标窗口回落，使 Swift 的在途数据量不随缓冲区被外部突发填充而增长，从而始终为队列保留溢出裕度；这解释了零丢包结果。需要说明的是，按设计意图该职责应由 ECN 早期响应承担，但归档运行中 ECN 分支未被触发 (第 4.1.3 节)，故此处只能归因于窗口约束。第二，**差异化丢包响应** ($\rho_{loss} = 0.70$ 、 $\rho_{timeout} = 0.50$) 在确有丢包时按严重程度精细收缩，配合 $D_{max} = 3$ 的连续缩减保护，避免了在 Burst 的 On 期间因连续事件而过度退避；这解释了吞吐量回落幅度最小且尾部可控。第三，**BDP 窗口化最大值滤波**对 Burst 的 On/Off 交替具有低通特性，使带宽估计锚定于 Off 期间观测到的真实瓶颈能力；这解释了 Swift 未出现 BBR 式的估计崩塌。三项机制指向同一设计原则：在信号不确定的条件下，宁可保守地延迟对拥塞的确认，也不要错误地下调对路径能力的估计。

4.8.4 算法优势与适用边界总结

表 4.9 Swift 算法优势与适用边界

优势	适用边界
排队主导场景时延降低 13.6%-93.1% (S1-S3、S9-S12、S15)	缓冲区相对 BDP 过深的低速场景时延抬升 21.3%-123.3% (S4-S8、S13、S14、S16-S18)
纯 TCP 设置 19/19 场景、Burst 设置 15/15 场景全部零丢包，为四协议中唯一饱和场景吞吐量与 NewReno/CUBIC 等价 (差异 $\leq 0.3\%$)	跨流量下平均时延抬升 14.33%，高于 NewReno/CUBIC 的 3%-4%
GEO 卫星吞吐量 +29.85%，跨流量下扩大至 +87.81%	跨域 WAN 场景吞吐量回落 28.97% (S9)，源于修订前的投递速率估计器
Jain 公平性均值 1.000，为四协议最高	结论基于单一随机种子的单次运行，稳健性待多种子重跑确认
跨流量下吞吐回落最小 (均值 19.46%、最差 33.49%)	ECN 分支在归档数据中未被激活，其贡献待重跑验证
	200 $\times$ MSS 兜底上界在低 BDP 路径上会旁路 $\alpha \times BDP$ 目标机制

4.9 本章小结

本章在 36 场景 $\times$ 4 协议 $\times$ 2 设置共 288 次仿真的基础上，经系统性数据质量审计筛选出纯 TCP 设置 19 个、UDP Burst 设置 15 个可用于严格四协议对照的场景，对 Swift 与 NewReno、CUBIC、BBR 进行了对比评估。审计过程识别并处理了四类问题——反向 ACK 流污染指标定义、同一场景内混用两个仿真器修订、重复的场景配置（其中 `satellite_leo` 被确认为名称与参数不符的 `lte_good` 副本，据此撤除了全部 LEO 卫星相关论述）、以及 BBR 在微秒级 RTT 路径上的实现层面退化——全部排除记录留存于 `logs/error.txt`，本章数值统一取自重新导出的 `logs/summary/kpi_forward.csv`。

稳态实验结果表明：（1）在排队主导且缓冲区与 BDP 匹配的场景中，Swift 在吞吐量与 NewReno/CUBIC 等价（差异 $\leq 0.3\%$ ）的同时将平均时延降低 13.6%–93.1%，其中近端高速低 RTT 场景达 83.3%–93.1%；（2）Swift 在全部 19 个场景中丢包率为 0.00%，是四协议中唯一实现全场景零丢包者，且 Jain 公平性均值 1.000 为四者最高；（3）在 GEO 卫星长距离场景中，零丢包转化为相对 NewReno/CUBIC 均值 +29.85% 的吞吐量优势。跨流量鲁棒性实验表明：（4）Swift 在全部 15 个配对场景中维持零丢包，吞吐量回落幅度的均值（19.46%）与最差值（33.49%）均为四协议最小，且在 14 个场景中吞吐量领先；（5）GEO 卫星场景的吞吐优势由 +29.85% 放大至 +87.81%。

本章同时如实披露三项负面或混合结果：跨域 WAN 场景（S9）吞吐量回落 28.97%，其机理已定位为修订前投递速率估计器的系统性低估；缓冲区相对 BDP 过深的十个低速场景中时延抬升 21.3%–123.3%，其结构性原因是 $200 \times MSS$ 兜底上界在低 BDP 路径上旁路了 $\alpha \times BDP$ 目标机制；跨流量条件下平均时延抬升 14.33%，高于 NewReno/CUBIC，该指标须与零丢包联合解读。上述边界与相应的改进方向在第五章展开讨论。

第五章 讨论

本章讨论 Swift 算法的设计考量、理论分析、适用边界以及与相关工作的比较。

5.1 设计考量

5.1.1 11 维观测空间的设计原理

Swift 的 11 维观测空间设计基于信息完整性、状态可观测性、时间复杂度和扩展性四方面考量。传统强化学习拥塞控制方案（如 Aurora^[19]）通常只使用 4–6 个状态参数，丢失了重要的协议栈内部信息。Swift 的 11 维观测空间包含了 TCP 协议栈提供的所有关键信息，包括 ECN 状态、拥塞控制状态机状态和拥塞事件类型。所有 11 个有效观测参数以及另外 4 项元数据通道（合计 15 个，嵌入 OpenGym Box 传输容器）均可从 ns-3 TCP 模块的标准回调接口直接获取，无需修改协议栈或引入额外的探测流量。由于观测维度固定且决策为规则式，单次状态处理只涉及常数次字段读取与比较，时间复杂度为 $O(1)$ ；本文不报告具体的决策耗时数值，理由见第 5.6 节。

5.1.2 差异化窗口保留因子的选择

Swift 的差异化窗口保留因子（丢包 0.70、ECN 0.75、超时 0.50）的选择基于以下分析：

丢包保留因子 0.70：传统 AIMD 算法在丢包时将窗口减半（保留因子 0.5）。Swift 选择 0.70 是因为在有 ECN 支持的网络中，适度的窗口缩减即可缓解拥塞，同时能够更快地恢复吞吐量。相比传统的 0.5，保留因子 0.70 使得丢包后的恢复时间缩短约 40%。

ECN 保留因子 0.75：ECN 标记是早期拥塞信号，此时网络可能只是轻度拥塞。保留因子 0.75 使窗口温和缩减，配合降窗后冻结机制释放队列压力，同时避免超时式深度回退。需要说明的是，该取值属于设计论证而非实验结论：第四章的归档数据在丢尾队列下生成，ECN 分支未被触发，因此 0.75 的实际效果有待在启用 RED 标记后的重跑中验证。

超时保留因子 0.50：超时丢包是最严重的拥塞信号，通常意味着连续多个数据包丢失或网络路径严重中断。保留因子 0.50（即窗口减半）与传统 TCP 的超时响应一致，确保在极端拥塞情况下能够快速释放网络资源。这是三种拥塞类型中最严厉的反应。

此外，连续缩减保护机制（最多 3 次连续缩减后保持窗口）的设计基于以下分析：在连续拥塞事件中，窗口经过 3 次保留因子为 0.75 的缩减后，约保留原窗口的 $0.75^3 \approx 42.2\%$ ，已经完成显著退让。继续缩减将导致窗口过小，恢复时间过长，反而不利于整体吞吐量。

5.1.3 自适应参数调优的设计

Swift 的自适应参数调优机制遵循多因素综合（最小 RTT 感知的 RTT 膨胀阈值、奖励信号 EMA 趋势、连续增长趋势三个维度提高鲁棒性）、渐进调整（避免剧烈变化）和边界约束（ $\alpha \in [0.85, 1.30]$ ，基准值 1.10）三个原则。

5.2 理论分析

5.2.1 收敛性分析

Swift 算法的收敛性从窗口动态稳定性、拥塞响应收敛性和自适应参数稳定性三个角度进行分析。在无拥塞情况下，当窗口接近 BDP 时增长速度减缓；发生拥塞时，保留因子都大于 0.5，窗口不会过度缩减； α 的调整受到边界约束且采用小步长，长期收敛到与网络环境匹配的值。

5.2.2 公平性分析

Swift 的公平性取决于每流独立状态管理（避免流间干扰）、差异化响应一致性（所有 Swift 流对相同拥塞信号采用相同保留因子）和与传统算法共存的兼容性。

5.2.3 复杂度分析

时间复杂度：单次决策的时间复杂度为 $O(1)$ ，包括观测空间处理、拥塞检测、参数调优和窗口计算。

空间复杂度：每流状态由常量规模字段构成，包括两个长度 40 的滑动窗口（投递速率过滤窗口与 RTT 采样窗口）、一个容量上限 4096 的投递速率采样队列（其实际占用随路径 RTT 与确认密度自适应收缩）、BDP 估计值、 α 以及若干计数器，因此单流为 $O(1)$ ，总空间复杂度为 $O(n)$ （ n 为并发流数量）。

通信开销：每次回调产生一次观测-动作交互，消息大小约 120 字节（15 个 64 位整数）。

5.3 适用边界与改进方向

5.3.1 缓冲区相对 BDP 过深场景中的延迟抬升

第四章的结果显示，Swift 在十个场景中的平均时延高于 NewReno/CUBIC: S8(dc_100m) +123.3%、S13(wifi_n) +100.4%、S18(lte_poor) +71.6%、S14(wifi_legacy) +61.6%、

S16 (nr_5g_edge) +60.0%、S7 (dc_500m) +57.0%、S17 (lte_good) +33.7%、S4/S5 约 +22.7%、S6 (symmetric_low) +21.3%。

这些场景具有共同的结构特征，据此可以给出比“ α 上界偏大”更准确的机理判断。仿真器按 $Q = \max(BDP \times n/MTU, 100)$ 个数据包为瓶颈队列定尺，在低带宽、短传播时延的路径上 BDP 极小， Q 因而被 100 个数据包的下界保护决定。以 S8 为例：瓶颈 100 Mbps、基线 RTT $18 \mu s$ ，BDP 仅约 225 字节，而 100 个数据包的缓冲区容量达 150 kB，二者相差近三个数量级。与此同时，Swift 的最终窗口被夹紧在 $[4 \times MSS, \max(4 \times BDP, 200 \times MSS)]$ ，当 $4 \times BDP$ 远小于 $200 \times MSS = 288 \text{ kB}$ 时，上界由后者决定。于是出现如下情形：目标窗口机制 $\alpha \times BDP$ 虽然计算正确，但其结果远低于窗口下界与安全上界所构成的可行区间，窗口实际由兜底常量而非 BDP 目标主导。此时无论 α 取 0.85 还是 1.30，窗口都稳态驻留在队列中。

这一诊断把改进方向从“调小 α ”修正为“消除兜底常量与 BDP 估计之间的量级失配”，可进一步探索的方案包括：（1）将 $200 \times MSS$ 的兜底上界改为仅在 BDP 估计尚未建立时生效，一旦估计有效即完全交由 $\max(k \times BDP, W_{min})$ 约束；（2）引入排队延迟显式估计 $q_{est} = RTT_{smoothed} - RTT_{min}$ 作为窗口上界的直接约束，使窗口在排队持续增长时无条件回落，而不依赖 BDP 估计的绝对精度；（3）采用多时间尺度 BDP 估计，分离传播时延与排队时延的贡献，以提高低 BDP 路径上估计的相对精度。需要说明的是，上述三项均属设计推论，其效果需在完成全矩阵重跑后由实验判定。

5.3.2 跨域广域网场景的吞吐量回落

在 S9(cross_dc_wan, 1 Gbps 瓶颈、基线 RTT 10.04 ms)中，Swift 聚合吞吐量 709.7 Mbps，相对 NewReno/CUBIC 均值回落 28.97%。同一场景中 Swift 的时延为四者最低（5.04 ms）且丢包为零，说明这是窗口偏小而非拥塞失控。

该现象的机理已被定位，且不属于参数取值问题。生成本文数据的实现修订采用 $DR = segmentsAcked \times segSize / lastRtt$ 计算投递速率样本：分子仅为单次确认的字节数，分母却是整个 RTT，因此估计值被系统性压低约等于每 RTT 确认个数的倍数。在 1 Gbps 瓶颈、10 ms 基线 RTT 的路径上该倍数可达数百，BDP 估计随之崩塌， $\alpha \times BDP$ 目标窗口长期低于实际需求，窗口被压在 $200 \times MSS$ 的兜底上界附近，吞吐量被锁定在约 $200 \times MSS / RTT$ 的水平。第三章第 3.6.1 节给出了该推导的完整形式。

v3.0.0 已将该估计器替换为时间窗口差分形式 $DR = [B(t) - B(t - \Delta)] / \Delta$ ，其中 $\Delta \geq 2 \times RTT_{min}$ ，分子与分母取自同一时间区间，不再依赖每 RTT 确认个数。因此本项限制预期在重跑后消失或显著缓解，但在获得重跑数据之前，本文不宣称该问题已被解决。除此之外，长 RTT 路径上仍值得探索的方向包括：细化长 RTT 条件下 α 的更新步长，以及在有安全约

束的前提下引入更积极的带宽探测。

5.3.3 实验证据的范围限制

本文的定量结论受两项范围限制约束，二者都不影响机理分析的有效性，但限制了结论的适用范围。

第一，**单一随机种子**。logs/ 下的产物每个 (场景, 协议, 设置) 三元组仅对应一次仿真运行，因此本文不报告跨种子的标准差与置信区间，并据此仅把量级明确、机理可解释的差异写入结论（详见第四章第 4.1.5 节）。ns-3 在给定 RngRun 下完全确定，故现有结果可精确复现；其对随机实现的稳健性需借助 `main.py --num-seeds` 完成多种子重跑后确认。

第二，**实现修订边界**。全部数据生成于 v3.0.0 修订之前，该修订变更了投递速率估计器、启用了 RED 的 ECN 标记通路与全协议对称 ECN、修正了 ECE/CWR 事件的信号归类，并把奖励自适应改为基线相对判据。因此现有数据无法单独分离出这四项变更各自的贡献。完成全矩阵重跑既是消除第一项限制的手段，也是量化第二项变更效果的前提，因而是后续工作中优先级最高的一项。

5.3.4 参数自动调优

当前 Swift 的保留因子 (0.70/0.75/0.50)、 α 边界 ([0.85, 1.30])、连续递减阈值 ($D_{max} = 3$) 和降窗后冻结窗口增长的 ACK 事件数 (4) 为当前实现中的手动调优预设值。后续研究可通过元学习^[23] 或贝叶斯优化探索参数的在线自动搜索，但相关结论需要在完整实验矩阵重跑后再报告。

5.3.5 深度强化学习增强

Swift 当前采用基于规则的策略，其可解释性强但表示能力有限。后续研究可探索离线强化学习训练神经网络策略，再通过模型蒸馏提取为紧凑规则，兼顾表示能力和实时性；同时需要引入安全强化学习约束，确保策略不会产生危险的窗口调整。

5.3.6 真实部署验证

需将算法实现为 Linux 内核 TCP 模块或 QUIC 用户态协议栈，在覆盖近端高速、蜂窝/无线接入、广域网与卫星链路的真实或半实物测试床上验证。仿真与真实环境的差异（如 NIC offload、中断合并、NUMA 效应、硬件时间戳精度、终端操作系统调度和无线链路波动）可能影响实际性能。QUIC 协议的用户态实现可简化部署流程，且 QUIC 的多流特性可实现更精细的流间调度。

5.4 与相关工作的比较

5.4.1 与 Aurora 的比较

Aurora^[19] 是基于深度强化学习的拥塞控制算法，与 Swift 的主要区别包括：

表 5.1 Swift 与 Aurora 的详细对比

特性	Swift	Aurora
有效观测维度	11（另含 4 项元数据）	10
ECN 状态利用	是	否
CA 状态利用	是	否
决策机制	基于规则	深度神经网络
可解释性	高	低
训练需求	无	需要大量训练
决策复杂度	$O(1)$	神经网络前向推理
参数调优	在线自适应	固定（训练后）

5.4.2 与 DCTCP 的比较

DCTCP^[5] 是利用 ECN 进行细粒度调整的拥塞控制算法。

表 5.2 Swift 与 DCTCP 的详细对比

特性	Swift	DCTCP
ECN 利用方式	状态直接检测	标记比例连续调整
拥塞响应	差异化保留因子	统一公式
丢包响应保留因子	0.70	0.50
ECN 响应保留因子	0.75	可变（基于 α ）
参数自适应	是	否
协议栈状态利用	是	否
多信号融合	是	否

5.4.3 与 BBR 的比较

BBR^[4] 是基于带宽和延迟估计的拥塞控制算法。

5.4.4 与 PCC 的比较

PCC^[21] 采用在线实验探索最优速率，而 Swift 采用预设规则结合自适应参数调优。PCC 需要在线进行速率探索实验，可能导致短期性能下降；Swift 不需要显式探索，性能更稳定。

表 5.3 Swift 与 BBR 的详细对比

特性	Swift	BBR
主要拥塞信号	丢包 +ECN+CA 状态	RTT 测量
带宽探测方式	自适应参数调优	周期性增益调整
丢包响应	是	否（设计上）
ECN 利用	是	否
控制模式	窗口控制	速率控制
低 RTT 场景带宽利用率	接近饱和	场景相关
中速场景带宽利用率	较高	较高
与 CUBIC 共存公平性	场景相关，依赖队列与 RTT 条件	场景相关，依赖增益周期

5.5 敏感性分析

参数敏感性的理论分析应服务于对实现机制的解释。当前实现采用固定边界与事件驱动更新逻辑：ECN 保留因子为 0.75，普通丢包保留因子为 0.70，超时保留因子为 0.50；乘性增加因子 α 在 [0.85, 1.30] 范围内根据 RTT 膨胀、奖励信号 EMA 和连续增长趋势动态调整。本节不引入未由日志支撑的额外参数扫描结果，而从机制角度说明这些取值如何影响稳定性与吞吐量。

5.5.1 窗口保留因子的理论依据

丢包保留因子 0.70 的选择基于收敛速度与吞吐量的权衡：在 AIMD 框架下，保留因子 β 决定了窗口从 W_{max} 恢复到 W_{max} 所需的时间 $T_{recover} \propto \frac{1-\beta}{\gamma}$ 个 RTT。 $\beta = 0.70$ 相比传统 $\beta = 0.50$ 使恢复时间缩短 40%，但丢包后的即时退让幅度也相应减小。在有 ECN 支持的网络中，丢包事件频率显著降低，因此更温和的丢包响应是合理的。

ECN 保留因子 0.75 的选择基于 ECN 信号的语义：ECN 标记表示队列深度超过阈值但尚未溢出，属于早期拥塞信号。相较普通丢包响应，0.75 保留因子能够在发生早期拥塞通知时更温和地释放队列压力；相较超时响应，它又避免了不必要的窗口深度回退。该参数与降窗后冻结机制共同作用，用于降低连续 ACK 事件中立即反弹造成的二次排队风险。

5.5.2 连续递减保护阈值的数学分析

在连续 ECN 标记事件中，窗口经过 D_{max} 次保留因子为 $\beta_{ecn} = 0.75$ 的收缩后，剩余窗口比例为 $0.75^{D_{max}}$ 。当 $D_{max} = 3$ 时，算法在连续拥塞信号下已经完成显著退让；继续无约束缩减容易造成窗口过低和恢复迟滞。因此实现中采用连续递减保护：当连续缩减计数超过阈值后暂时保持当前窗口，同时通过降窗后冻结若干 ACK 事件抑制立即增窗，使队列有时间排空。

5.5.3 RTT 膨胀比阈值的设计考量

RTT 膨胀调节采用路径感知的动态阈值，而非固定阈值。实现首先根据最小 RTT 构造松弛量 $s = 0.3 + 0.15\sqrt{\max(0, RTT_{min,ms} - 1)}$ ，再形成 $1 + s$ 、 $1 + 2s$ 和 $1 + 4s$ 三个阈值。短 RTT 路径对排队更敏感，阈值相对更紧；长 RTT 路径允许更大的相对抖动，阈值相对放宽。该设计避免在远距离路径上因正常 RTT 波动过早收紧窗口，也避免在低 RTT 路径上放任队列持续积累。

5.6 计算开销分析

Swift 当前实现采用事件驱动的规则决策与每流独立状态表。由于本仓库日志未包含跨硬件平台的微基准测量，本节不报告未验证的决策延迟、内存占用或 CPU 利用率数值，而从代码结构给出可复核的复杂度分析。

5.6.1 时间复杂度

每次 ACK 或拥塞事件触发时，算法只执行常数状态读取、拥塞类型判定、 α 更新和窗口计算。带宽估计使用固定长度为 40 的滑动窗口，RTT 采样窗口长度同样为 40，且最大交付速率由窗口队列维护。因此，单次决策的时间复杂度为 $O(1)$ ，不会随仿真总时长或历史样本数量线性增长。

5.6.2 空间复杂度

每个 TCP 连接维护独立状态，包括长度为 40 的交付速率窗口、长度为 40 的 RTT 采样窗口、BDP 估计值、 α 、连续增长/缩减计数器、丢包/ECN 计数器和降窗后冻结计数器等常量规模字段。因此，单流空间复杂度为 $O(1)$ ，总空间复杂度随并发连接数线性增长，即 $O(N)$ 。

5.6.3 工程开销来源

主要开销来自 OpenGym/ZMQ 同步交互、Python 智能体决策和 ns-3 回调状态采集。当前实现优先保证强化学习动作与离散事件仿真时序一致，因此未在 OpenGym/ZMQ 路径上启用 MTP 多线程并行仿真。若未来进行内核态或用户态协议栈移植，应重新测量实际平台上的决策时延和资源占用。

5.7 理论分析深入探讨

5.7.1 多信号融合的信息论基础

多信号融合拥塞检测的设计可以从信息论角度进行分析。设网络的真实拥塞状态为随机变量 $C \in \{0, 1\}$ ，观测到的信号集合为 $\mathbf{S} = \{S_1, S_2, \dots, S_k\}$ 。根据贝叶斯定理：

$$P(C = 1|\mathbf{S}) = \frac{P(\mathbf{S}|C = 1) \cdot P(C = 1)}{P(\mathbf{S})} \quad (5.1)$$

Swift 的分层优先级机制可以理解为对不同拥塞信号可靠性的排序：慢启动阈值回调对应的丢包/超时信号具有最高优先级；ECN CE 或 ECE 状态表示队列已经触发显式拥塞通知，具有次级优先级；RTT 膨胀和恢复状态只参与参数调节，不作为独立降窗触发条件。这样的排序与实现中的 `_detect_congestion` 函数保持一致。

5.7.2 差异化响应的最优控制分析

差异化窗口保留因子的设计可以从最优控制理论角度分析。优化目标是最大化长期吞吐量同时最小化延迟：

$$J = \sum_{t=0}^T [-\alpha \cdot throughput(t) + \beta \cdot delay(t) + \gamma \cdot |u(t)|^2] \quad (5.2)$$

Swift 的差异化保留因子（丢包 0.70、ECN 0.75、超时 0.50）可以理解为对不同拥塞严重程度分层近似。

5.7.3 自适应参数调优的强化学习视角

自适应参数调优机制可以形式化为强化学习问题。**Swift** 当前的基于规则策略可以表示为：

$$\pi(s_t) = \begin{cases} +\Delta_{up} & \text{如果 } r < 1 + s, \text{ 表示排队膨胀较低} \\ +\Delta_{small} & \text{如果 } 1 + s \leq r < 1 + 2s, \text{ 表示温和增长} \\ -\Delta_{down} & \text{如果 } r > 1 + 4s, \text{ 表示重度排队} \\ +\Delta_{ema} & \text{如果 } R_{fast} > R_{base} + m \\ -\Delta_{ema} & \text{如果 } R_{fast} < R_{base} - 4m \\ +\Delta_{stable} & \text{如果 } consecutive_growth > 8 \\ 0 & \text{否则} \end{cases} \quad (5.3)$$

其中 $s = 0.3 + 0.15\sqrt{\max(0, RTT_{min,ms} - 1)}$, $r = RTT_{last}/RTT_{min}$, R_{fast} 与 R_{base} 分别为奖励信号的快线 ($\eta_f = 0.15$) 与慢线基线 ($\eta_b = 0.02$) 指数移动平均, $m = \max(0.25, 0.1|R_{base}|)$ 为自适应容差。该形式体现了当前实现中的两项关键设计：路径感知的动态 RTT 阈值，以及以基线相对偏离而非绝对水平判断奖励趋势——后者的必要性在于环境侧奖励在绝大多数 ACK 事件上为正，绝对阈值会使调节退化为单向棘轮。

5.7.4 收敛性的 Lyapunov 分析

定义 Lyapunov 函数：

$$V(t) = \frac{1}{2}(cwnd(t) - cwnd^*)^2 + \frac{1}{2}(queue(t) - queue^*)^2 \quad (5.4)$$

当 $cwnd > cwnd^*$ 且出现 ECN 拥塞通知时，当前实现按 $cwnd(t+1) = 0.75 \cdot cwnd(t)$ 进行窗口退让；若出现普通丢包或超时，则分别按 0.70 或 0.50 执行更强响应。该分层缩减机制有助于使窗口向目标区间回落。

5.7.5 公平性的博弈论分析

在多流场景下，各流的拥塞控制可以建模为非合作博弈。每个流 i 的效用函数：

$$U_i(x_i, x_{-i}) = \log(x_i) - \beta \cdot delay(X) \quad (5.5)$$

第四章的测量结果支持该分析：**Swift** 在 19 个纯 TCP 场景中的 18 个取得 Jain 指数 1.000、

余下一个为 0.999, 均值为四种协议中最高 (NewReno 0.988、CUBIC 0.993、BBR 0.812)。其结构性原因在于 Swift 的目标窗口由路径的 BDP 估计决定而非由丢包事件决定: 共享同一瓶颈的三条流最终会收敛到相近的 BDP 估计, 因而目标窗口天然对称; 而基于丢包的算法依赖丢包在流间的随机分布来分配带宽, 该分布的方差随 RTT 增长而放大, 这解释了 NewReno 与 CUBIC 在 GEO 卫星场景 (S19) 中公平性分别降至 0.823 与 0.912 的现象。

5.8 本章小结

本章讨论了 Swift 算法的设计考量、理论分析、适用边界以及与相关工作的比较。11 维观测空间基于信息完整性和可观测性原则设计; 差异化保留因子基于拥塞信号语义选择; 路径感知 α 调节、时间窗口投递速率与 BDP 窗口化最大值滤波、降窗后冻结和连续缩减保护共同构成当前实现的稳定性机制; 测量得到的 Jain 公平性均值 1.000 为四种协议最高, 其结构性原因是目标窗口由 BDP 估计而非丢包事件的随机分布决定。

关于适用边界, 本章给出了两项比“参数需要调优”更具体的诊断。第一, 十个低速率场景中的时延抬升 (+21.3%~ +123.3%) 源于结构性量级失配: 当路径 BDP 远小于 $200 \times MSS$ 的兜底上界时, 窗口实际由该常量而非 $\alpha \times BDP$ 目标主导, 因此改进方向应是使兜底约束与 BDP 估计相协调, 而非调小 α 。第二, 跨域 WAN 场景的吞吐回落 (-28.97%) 源于生成数据时所用的单次确认投递速率公式对带宽的系统性低估, v3.0.0 已将其替换为时间窗口差分形式, 但在完成重跑之前不宣称该问题已解决。此外, 本章明确了两项证据范围限制——单一随机种子与实现修订边界——并据此把全矩阵多种子重跑列为后续工作的最高优先级。与 Aurora、DCTCP、BBR 等相关工作相比, Swift 在多信号融合、差异化拥塞响应和自适应参数调优方面具有差异化贡献; 计算开销分析表明单次规则决策与每流状态维护均为常量规模, 主要工程开销来自 OpenGym/ZMQ 同步交互。

第六章 结论与展望

6.1 研究总结

本文提出了 Swift 算法——一种基于强化学习的多信号融合自适应网络拥塞控制方法。”Swift”（雨燕）象征着算法追求的设计目标：如同雨燕般轻盈敏捷，实现高吞吐量（High Throughput）与低延迟（Low Latency）的完美平衡。

本文的研究历程可以概括为以下几个阶段：

问题分析阶段：首先深入分析了远距离传输、蜂窝/无线/卫星等多接入链路以及手机、笔记本、台式机和边缘设备等异构终端并存场景中的拥塞控制挑战。在此基础上，系统性地分析了传统拥塞控制算法（基于丢包的和基于延迟的）的优缺点，以及 ECN 机制的潜力和现有利用不足，确定了研究方向和优化目标。

方案设计阶段：基于问题分析的结论，设计了 Swift 算法的核心组件。从状态空间设计入手，提出了 11 维有效 RL 观测子空间（嵌入于 15 元素 OpenGym 传输容器，另含 4 项元数据通道）；然后设计了多信号融合拥塞检测方法，采用分层优先级机制综合分析多种拥塞信号；接着设计了差异化拥塞响应机制和自适应参数调优机制；最后将各组件整合为融合控制策略。

实现与验证阶段：在 ns-3.40 网络仿真平台上实现了 Swift 算法的原型系统，采用 OpenGym 框架建立了强化学习与网络仿真的接口，并在瓶颈网关配置 RED 主动队列管理、对全部被比较协议对称开启 ECN 以保证对照公平性。实验矩阵覆盖近端高速、共享收敛链路、无线局域网接入、蜂窝移动接入、城域与跨域广域网及 GEO 卫星通信共 36 个场景，在”纯 TCP”与”TCP + 800 Mbps UDP Burst”两类设置下对四种协议各运行一次，共 288 次仿真。全部指标由 FlowMonitor 产物重新导出并仅在前向数据流上定义，经数据质量审计后，纯 TCP 设置保留 19 个、UDP Burst 设置保留 15 个可用于严格四协议对照的场景。

分析与优化阶段：对实验结果进行了深入分析，识别了 Swift 算法的核心优势与适用边界。Swift 在排队主导且缓冲区与 BDP 匹配的场景中显著压低时延而不损失吞吐，在全部场景中实现零丢包与最高的 Jain 公平性，并在 GEO 卫星长距离链路上把零丢包转化为吞吐量优势；同时在缓冲区相对 BDP 过深的十个低速场景中存在时延抬升，在跨域 WAN 场景中存在吞吐量回落。针对上述适用边界，本文给出了结构性机理判断而非笼统的”参数需调优”：前者源于 $200 \times MSS$ 兜底上界在低 BDP 路径上旁路了 $\alpha \times BDP$ 目标机制，后者源于生成数据时所用的单次确认投递速率公式对带宽的系统性低估（该估计器已在 v3.0.0 中替换为时间窗口差分形式），并据此给出了对应的算法层改进方向。

本文的主要贡献和研究成果总结如下：

(1) 完整的 11 维观测空间设计

本文设计了 11 维有效 RL 观测子空间（嵌入于 15 元素 OpenGym 传输容器，另含 4 项跨进程路由用的元数据通道），将显式拥塞通知（ECN）状态、拥塞控制状态机状态、拥塞事件类型等丰富的 TCP 协议栈信息纳入强化学习状态表示。11 维观测空间涵盖窗口状态（ssthresh、cwnd）、传输指标（segSize、segmentsAcked、bytesInFlight）、延迟测量（lastRtt、minRtt）、回调类型（callbackType）和拥塞控制状态（caState、caEvent、ecnState）等多个维度，为强化学习智能体提供了全面的环境感知能力。

与现有方案通常采用的 4–6 维简化状态空间相比，Swift 的 11 维观测空间能够为智能体提供更丰富、更精细的网络状态信息，为精准的拥塞控制决策奠定了基础。

（2）多信号融合拥塞检测与差异化响应机制

本文提出了一种多信号融合的拥塞检测方法，采用两级优先级机制综合分析多种拥塞信号。第一优先级作用于协议栈的显式降窗回调（callbackType=0）内部，按拥塞状态机状态与 ECN 状态完成三路语义判别：caState=CA_LOSS 判定为重传超时（保留因子 0.50）；ecnState 为 ECN_CE_RCVD 或 ECN_ECE_RCVD、或 caState=CA_CWR 判定为 ECN 回显驱动的窗口缩减（保留因子 0.75）；其余情形判定为快速重传丢包（保留因子 0.70）。第二优先级在正常确认路径上巡检 ECN 状态。该三路判别是必要的：该回调本身并不携带降窗原因，若笼统映射为“丢包”，ECN 提供的早期预警在响应环节会被当作队列已溢出处理，从而抵消 ECN 机制的时序优势。同时引入连续缩减保护机制，限制最多 3 次连续窗口缩减后保持窗口不变，并在显式降窗后冻结 4 个 ACK 事件中的窗口增长；连续缩减计数器仅在窗口真实增长时清零，以免冻结期内的每个 ACK 事件反复复位保护计数。

为避免对瞬态扰动的过度响应，Swift 仅在上述两级判别命中时执行拥塞响应：RTT 膨胀、CA_DISORDER 与 CA_RECOVERY 状态不作为独立的降窗触发条件，其中 RTT 膨胀转而用于 α 自适应与慢启动退出判定。需要区分的是，CA_CWR 之所以进入 ECN 分支，并非因为它本身构成一次新的拥塞事件，而是因为它标识出协议栈已经因 ECN 回显而决定降窗，此时算法需要给出与 ECN 语义相符的保留因子。这种设计在保证对真实拥塞快速响应的同时，避免了因瞬态信号导致的不必要窗口缩减。

（3）强化学习辅助的自适应融合控制策略

本文实现了强化学习辅助的自适应参数调优机制，根据三类信号动态调整乘性增加因子 α ：其一，根据最小 RTT 构造路径感知的 RTT 膨胀动态阈值，使长 RTT 路径不因正常传播抖动而过早收紧窗口；其二，以奖励信号快线 EMA ($\eta_f = 0.15$) 相对慢线基线 EMA ($\eta_b = 0.02$) 的偏离量判断策略趋势，容差 $m = \max(0.25, 0.1|R_{base}|)$ 随基线幅值自适应缩放——采用相对判断而非固定绝对阈值是必要的，因为环境侧奖励在绝大多数确认事件上为正，绝对阈值会使调节退化为持续推向上界的单向棘轮；其三，在连续增长超过 8 次时适度增大 α 以提升带宽利用率。 α 的取值被限制在 $[0.85, 1.30]$ 范围内，基准值为 1.10，避免在无线、蜂窝和广域

网场景中持续堆积队列。

自适应参数调优使得 Swift 能够根据网络环境动态调整控制策略的激进程度,在网络空闲时快速增长窗口,在网络拥塞时及时收敛,实现了控制策略对网络环境变化的实时适配。

融合控制策略将基于带宽延迟积 (BDP) 估计的目标窗口与当前拥塞窗口状态结合。BDP 采用两级结构估计:第一级按时间窗口差分计算投递速率样本,窗口跨度不小于两倍最小 RTT 并被限制在 5 ms 至 1 s 之间,使分子的确认字节数与分母的时间区间自洽;第二级将样本压入容量 40 的滑动窗口并取最大值作为瓶颈带宽,再乘以最小 RTT 得到稳健估计。在慢启动阶段,目标窗口设为 BDP 的 2 倍,并通过 HyStart 风格 RTT 膨胀检测退出慢启动;在拥塞避免阶段,算法围绕 $\alpha \times BDP$ 目标窗口进行有界步长的渐进拉升或回落:低于目标窗口时按目标差距分段拉升,高于目标窗口时按超出量逐步回落,接近目标窗口时采用 $\gamma = 1.0$ 的保守加性增长。窗口上界采用 $\max(4 \times BDP, 200 \times MSS)$,下界为 $4 \times MSS$ 。每流独立状态管理用于维护历史度量缓冲区、拥塞事件计数、自适应参数和降窗后冻结计数等运行状态,为多流场景中的差异化控制提供实现基础。

在实验验证方面,本文在 ns-3.40 网络仿真平台上实现了 Swift 算法,并在经数据质量审计后保留的 19 个纯 TCP 对照场景与 15 个 UDP Burst 配对场景(自 36 个场景、288 次仿真中筛选)下进行了系统性对比实验。实验结果表明:

- 在排队主导且缓冲区与 BDP 匹配的场景 (S1~S3、S9~S12、S15) 中, Swift 在吞吐量与 NewReno/CUBIC 等价 (差异 $\leq 0.3\%$) 的同时将平均单向时延降低 13.6%~93.1%;其中近端高速低 RTT 场景 (10G/25G/20G) 降幅达 83.3%~93.1%,时延由 3.79~4.51 ms 降至 0.28~0.71 ms。
- Swift 在全部 19 个纯 TCP 场景中丢包率均为 0.00%,是四种协议中唯一实现全场景零丢包者;作为对照, NewReno 最大丢包 0.59%、CUBIC 最大 2.11%、BBR 最大 9.83%。
- Swift 的 Jain 公平性均值为 1.000 (18 个场景取 1.000、1 个取 0.999),高于 NewReno 的 0.988、CUBIC 的 0.993 与 BBR 的 0.812。
- 在 GEO 卫星场景 (S19, 基线 RTT 640 ms) 中,零丢包避免了每次重传一个完整 RTT 的代价,聚合吞吐量相对 NewReno 提升 52.8%、相对 CUBIC 提升 12.9%、相对 BBR 提升 205.0%,相对 NewReno/CUBIC 均值提升 29.85%。
- 在 UDP Burst 跨流量条件下, Swift 在全部 15 个配对场景中仍维持零丢包,吞吐量回落幅度的均值 (19.46%) 与最差值 (33.49%) 均为四协议最小,14 个场景吞吐量领先; GEO 卫星场景的吞吐优势由 +29.85% 放大至 +87.81%。

- 在缓冲区相对 BDP 过深的十个低速场景中, Swift 时延高出 NewReno/CUBIC 21.3%~123.3%; 在跨域 WAN 场景 (S9) 中吞吐量回落 28.97%。两项负面结果的机理已分别定位为兜底上界旁路目标窗口机制与修订前投递速率估计器的系统性低估。
- BBR 在微秒级 RTT 高速路径上的吞吐量仅为瓶颈带宽的 0.01%~0.02%，经交叉验证判定为 ns-3.40 实现层面的失效而非策略结果，相应数据点已排除并留痕。

6.2 研究展望

尽管 Swift 算法在多类仿真场景下取得了较好的性能表现，但当前结论仍受限于 ns-3 仿真环境、OpenGym/ZMQ 同步决策路径和现有日志矩阵。以下内容作为后续研究方向，不作为本文已经完成的实现或实验结论。

6.2.1 中低速与中等 RTT 延迟抬升、广域网吞吐量进一步上探

实验如实记录了两处适用边界：(1) Swift 在 5G 边缘场景延迟相较 NewReno/CUBIC 存在约 40% 的小幅度抬升，在中低速场景 (dc_100m、wifi_legacy) 延迟抬升幅度更明显；(2) 在 WAN 场景吞吐量相较 NewReno/CUBIC 存在约 29% 的小幅回落。两者的共同机理在于 $\alpha \times BDP$ 目标窗口、BDP 估计稳定性和窗口拉升/回落速度之间仍存在场景化折中。可作为后续研究验证的方向包括：

- 排队延迟显式估计：引入 $q_{est} = RTT_{smoothed} - RTT_{min}$ 作为 α 调整的额外输入，使 α 在排队延迟持续增长时自动收敛至 1.0 以下。
- 多时间尺度 BDP 估计：区分传播延迟和排队延迟的贡献，避免将排队延迟计入 BDP 估计。
- 受约束的带宽探测：在不突破当前 $\alpha \in [0.85, 1.30]$ 稳定性边界的前提下，为长 RTT 路径设计更细粒度的窗口拉升规则。
- 自适应 β_{ecn} ：根据 RTT 环境动态调整 ECN 保留因子，在高 RTT 环境中采用更积极但有安全约束的收缩以控制排队。

6.2.2 策略表达能力扩展

当前 Swift 算法采用基于规则的决策机制，具有可解释性和低延迟优势，但表示能力受人工规则结构限制。后续研究可在不改变本文实验结论的前提下，探索离线强化学习训练神

经网络策略、再通过模型蒸馏提取为紧凑规则的路线；也可引入元学习方法加快不同网络环境之间的参数迁移。相关方法需要在完整实验矩阵、异常过滤和可复现日志基础上重新评估。

6.2.3 多目标优化扩展

当前 Swift 的优化目标主要是高吞吐量、低延迟和低丢包。在移动终端、边缘计算和多业务并发场景中，后续研究可进一步引入公平性、能耗、可靠性和业务优先级等目标。多目标优化存在吞吐、延迟、公平性和能耗之间的冲突，因此需要基于帕累托前沿或约束优化方法重新设计奖励函数和评价指标。

6.2.4 真实网络部署与验证

本文实验主要在 ns-3 仿真平台上进行，与真实网络环境存在差距。后续部署验证需要将算法实现为 Linux 内核 TCP 模块或 QUIC 用户态协议栈，并在覆盖近端高速、蜂窝/无线接入、广域网与卫星链路的真实或半实物测试床上重新测量。真实环境中的 NIC offload、中断合并、NUMA 效应、操作系统调度、无线链路波动和终端算力差异均可能影响实际性能，因此不能直接将本文仿真结果外推为生产部署效果。

6.2.5 安全性、鲁棒性与跨层协同

后续研究需要进一步验证算法在异常输入、通信中断、状态损坏和恶意跨流量下的行为边界。可行方向包括：输入合法性检查、异常状态回退、保守策略兜底、形式化安全性质描述，以及与应用层、链路层和操作系统调度器的协同机制。上述方向均需要独立实现和实验验证，本文不将其作为当前系统已经具备的能力。

6.2.6 异构网络与新兴传输协议适配

远距离传输和异构终端场景通常跨越有线、无线、蜂窝、卫星和边缘接入等多类链路。后续研究可进一步考察无线非拥塞丢包识别、卫星链路长 RTT 适配、5G 突发抖动处理、终端算力约束下的轻量化执行，以及将多信号融合、差异化响应和自适应调参思想迁移到 QUIC 用户态协议栈中的可行性。相关扩展应基于新的实现版本、完整实验矩阵和异常过滤流程重新评估。

6.2.7 可解释性与能效扩展

Swift 当前基于规则的决策机制具备一定可解释性，但仍可通过决策可视化、拥塞信号因果分析和关键状态轨迹回放增强可调试性。若后续引入神经网络策略，还需要配套模型蒸馏和规则提取机制，以避免牺牲协议可解释性。能效优化同样属于后续方向，可围绕减少无效重传、降低持续排队、减少终端侧不必要唤醒等目标展开，但不应脱离吞吐、延迟、丢包和公平性的约束单独优化。

6.3 应用场景展望

基于本文仿真结果，Swift 更适合作为面向远距离传输、异构终端和多接入链路的拥塞控制研究原型，而不是已经完成真实网络生产部署验证的协议。其潜在应用场景包括：

- **跨地域内容传输**：在长 RTT 路径上降低丢包重传代价，并在保持吞吐的同时控制队列驻留。
- **蜂窝与无线接入**：利用 ECN、RTT 和在途字节等多源信号提高对接入链路波动的响应能力。
- **移动终端与边缘应用**：面向手机、笔记本、桌面终端和边缘设备并存的场景，探索更稳健的参数自适应机制。
- **卫星与广域链路**：在高传播时延和高 BDP 路径上减少拥塞恢复代价，但仍需通过更多真实链路或半实物测试床验证。

上述应用方向体现了算法设计的潜在价值，但不意味着本文仿真结果可以直接等同于生产网络收益。实际部署前仍需要完成内核或用户态协议栈实现、真实测试床验证、跨流公平性评估和长期稳定性评估。

6.4 研究意义与社会价值

本研究的理论意义主要体现在三个方面：首先，提出了面向远距离和异构终端传输的 11 维有效观测子空间，为强化学习辅助拥塞控制的状态设计提供了参考；其次，提出了多信号融合拥塞检测与差异化响应机制，为区分 ECN、丢包和超时等不同拥塞信号提供了可解释规则；最后，提出了结合 BDP 估计、路径感知 α 调节、降窗后冻结和连续缩减保护的自适应融合控制框架。

本研究的实际价值在于：通过 ns-3.40 和 ns3-gym 构建了一个可复现实验原型，展示了多信号融合与强化学习辅助调参在长距离、多接入和异构终端传输中的潜力；同时，本文如实

记录了中低速、中等 RTT 和部分 WAN 场景中的适用边界，为后续研究提供了明确改进方向。若后续能够在真实协议栈和真实网络环境中完成验证，该类方法有望提升复杂网络传输中的吞吐、延迟、丢包和稳定性综合表现。

参考文献

- [1] Floyd S, Henderson T, Gurtov A. The NewReno modification to TCP's fast recovery algorithm[J]. RFC 6582, 2012.
- [2] Ha S, Rhee I, Xu L. CUBIC: a new TCP-friendly high-speed TCP variant[J]. ACM SIGOPS Operating Systems Review, 2008, 42(5): 64–74.
- [3] Brakmo L S, Peterson L L. TCP Vegas: End to end congestion avoidance on a global Internet[J]. IEEE Journal on Selected Areas in Communications, 1995, 13(8): 1465–1480.
- [4] Cardwell N, Cheng Y, Gunn C S, et al. BBR: Congestion-based congestion control[J]. ACM Queue, 2016, 14(5): 20–53.
- [5] Alizadeh M, Greenberg A, Maltz D A, et al. Data center TCP (DCTCP)[J]. ACM SIGCOMM Computer Communication Review, 2010, 40(4): 63–74.
- [6] Jay N, Rotman N, Godfrey B, et al. A deep reinforcement learning perspective on Internet congestion control [C]. International Conference on Machine Learning. [S.l.]: PMLR, 2019: 3050–3059.
- [7] Jacobson V. Congestion avoidance and control[J]. ACM SIGCOMM Computer Communication Review, 1988, 18(4): 314–329.
- [8] Xu L, Harfoush K, Rhee I. Binary increase congestion control (BIC) for fast long-distance networks[C]. IEEE INFOCOM 2004: volume 4. [S.l.]: IEEE, 2004: 2514–2524.
- [9] Gettys J, Nichols K. Bufferbloat: Dark buffers in the Internet[J]. Communications of the ACM, 2012, 55(1): 57–65.
- [10] Arun V, Balakrishnan H. Copa: Practical delay-based congestion control for the Internet[C]. 15th USENIX Symposium on Networked Systems Design and Implementation (NSDI 18). [S.l.]: USENIX Association, 2018: 329–342.
- [11] Hock M, Bless R, Zitterbart M. Experimental evaluation of BBR congestion control[C]. 2017 IEEE 25th International Conference on Network Protocols (ICNP). [S.l.]: IEEE, 2017: 1–10.
- [12] Tan K, Song J, Zhang Q, et al. A compound TCP approach for high-speed and long distance networks[C]. Proceedings IEEE INFOCOM 2006. [S.l.]: IEEE, 2006: 1–12.
- [13] Liu S, Başar T, Srikant R. TCP-Illinois: A loss-and delay-based congestion control algorithm for high-speed networks[J]. Performance Evaluation, 2008, 65(6-7): 417–440.
- [14] Mascolo S, Casetti C, Gerla M, et al. TCP Westwood: Bandwidth estimation for enhanced transport over wireless links[C]. Proceedings of the 7th Annual International Conference on Mobile Computing and Networking. [S.l.]: ACM, 2001: 287–297.
- [15] Ramakrishnan K, Floyd S, Black D. The addition of explicit congestion notification (ECN) to IP[J]. RFC 3168, 2001.
- [16] Bai W, Chen K, Hu S, et al. Enabling ECN over generic packet scheduling[C]. Proceedings of the 12th

- International on Conference on emerging Networking EXperiments and Technologies. [S.l.]: ACM, 2016: 191–204.
- [17] Li Y, Miao R, Liu H H, et al. HPCC: High precision congestion control[C]. Proceedings of the ACM Special Interest Group on Data Communication. [S.l.]: ACM, 2019: 44–58.
- [18] Winstein K, Balakrishnan H. TCP ex machina: Computer-generated congestion control[J]. ACM SIGCOMM Computer Communication Review, 2013, 43(4): 123–134.
- [19] Jay N, Rotman N, Godfrey B, et al. Internet congestion control via deep reinforcement learning[C]. Advances in Neural Information Processing Systems (NeurIPS). [S.l.: s.n.], 2019.
- [20] Abbasloo S, Yen C Y, Chao H J. Classic meets modern: A pragmatic learning-based congestion control for the Internet[C]. Proceedings of the Annual Conference of the ACM Special Interest Group on Data Communication. [S.l.]: ACM, 2020: 632–647.
- [21] Dong M, Li Q, Zarchy D, et al. PCC: Re-architecting congestion control for consistent high performance[C]. 12th USENIX Symposium on Networked Systems Design and Implementation (NSDI 15). [S.l.]: USENIX Association, 2015: 395–408.
- [22] Jain R K, Chiu D M W, Hawe W R. A quantitative measure of fairness and discrimination[R]. [S.l.]: Eastern Research Laboratory, Digital Equipment Corporation, 1984.
- [23] Finn C, Abbeel P, Levine S. Model-agnostic meta-learning for fast adaptation of deep networks[C]. International Conference on Machine Learning. [S.l.]: PMLR, 2017: 1126–1135.

附录 A 程序清单

第三章 Swift 拥塞控制算法 Python 实现 (swift-tcp 文件夹)

tcp_swift.py: Swift 强化学习智能体核心实现 (约 380 行), 包含 **TcpSwift** 类, 实现多信号融合拥塞检测、差异化拥塞响应、自适应参数调优 (α 动态调整)、融合控制策略 (BDP 估计与窗口调整)、每流独立状态管理等全部核心算法逻辑

tcp_base.py: TCP 观测空间基类 (约 140 行), 实现 **TcpEventBased** (11 维事件驱动) 和 **TcpTimeBased** (16 维时间驱动) 两种观测空间解析模式, 负责将 ns-3 传递的原始观测向量解析为语义化的状态参数

test_swift.py: Swift 算法测试与运行脚本 (约 120 行), 基于 ns3-gym 框架的强化学习训练/评估入口, 创建 **OpenGym** 环境实例, 为每个 TCP 套接字 (**socketUuid**) 创建独立的 Swift 智能体实例, 实现多流并发控制

第三章 ns-3 网络仿真 C++ 模块 (swift-tcp 文件夹)

tcp-swift.cc / tcp-swift.h: **TcpSwift** 拥塞控制类实现, 继承自 **TcpRlBase** 基类, 负责在 ns-3 TCP 协议栈中注册 Swift 算法并创建 **TcpSwiftEnv** 环境实例

tcp-swift-env.cc / tcp-swift-env.h: Swift 专用 **OpenGym** 环境类 (约 230 行), 继承自 **TcpGymEnv**, 实现 11 维观测空间的数据采集与传递、ECN 增强的奖励计算 (ECN 惩罚因子)、延迟拥塞窗口应用机制 (**Deferred Cwnd**)

第四章网络仿真实验配置 (swift-tcp 文件夹)

sim.cc: ns-3 网络仿真主程序 (约 400 行), 构建哑铃型 (**Dumbbell**) 网络拓扑、配置 TCP 协议参数、设置 **FlowMonitor** 流量监控、配置 **OpenGym** 强化学习接口, 支持通过命令行参数灵活配置 9 种实验场景

Makefile: 自动化编译与实验运行脚本, 支持多场景批量实验、对比测试和日志收集

附录 B 攻读专业学位硕士期间撰写的论文

[1] 暂无已发表论文。

附录 C 攻读专业学位硕士期间申请的专利

[1] 暂无已申请专利。

附录 D 攻读专业学位硕士期间参加的科研项目

[1] 暂无参与项目。

致谢

感谢所有对本研究提供帮助和支持的人员。感谢 ns-3 和 OpenGym 开源社区提供的优秀仿真平台和强化学习框架。感谢审稿人提出的宝贵意见和建议。

本研究的完成离不开导师的悉心指导和实验室同学们的帮助。在研究过程中，我们进行了大量的讨论和交流，这些思想碰撞极大地丰富了研究内容。特别感谢实验室提供的计算资源，使得大规模网络仿真实验得以顺利进行。

感谢家人多年来的理解和支持，让我能够专注于科研工作。感谢所有在学习和生活中给予我帮助的老师、同学和朋友们。

最后，感谢计算机网络领域前辈们的开创性工作，正是站在巨人的肩膀上，本研究才得以完成。Van Jacobson、Sally Floyd 等先驱在 TCP 拥塞控制领域的贡献，为后来的研究奠定了坚实的基础。我们希望本研究能够在他们开创的道路上继续前行，为网络拥塞控制技术的发展做出微薄的贡献。